NEURON

Relatório didático de arquitetura e evolução do protótipo (versão atualizada)

Projeto	Plataforma acadêmica com Monitor Virtual baseado em IA
Escopo atual	Disciplinas do 1º ao 4º período
Foco deste relatório	Arquitetura, ingestão de materiais e RAG
Stack definida	React + Spring Boot/Java + serviço Python de IA

Objetivo: explicar de forma simples o que já foi construído, por que certas decisões foram tomadas e quais são os próximos passos.

O que mudou nesta versão: o monitor humano saiu do escopo atual; entrou a prática com questões e provas dos professores (apenas em disciplinas com prova); entrou a seção de feedback da plataforma. As mudanças estão resumidas na seção 12 e refletidas nas seções 6, 8, 9 e 11.

1. Visão geral do projeto

O NEURON é uma aplicação web voltada a estudantes de Ciência da Computação. A organização principal segue a sequência Período → Disciplina → Assunto → Material. O estudante consulta materiais, utiliza um Monitor Virtual e, nas disciplinas com prova, pratica com questões; a administração cuida do cadastro e publicação dos conteúdos.

A ideia central do Monitor Virtual não é simplesmente responder perguntas com conhecimento geral. Ele deve localizar primeiro os materiais acadêmicos da disciplina e usar esses materiais como contexto para produzir uma resposta mais alinhada ao conteúdo estudado.

Explicando RAG sem termos técnicos

RAG pode ser entendido como uma consulta a uma biblioteca antes de responder. O aluno faz uma pergunta; o sistema procura os trechos mais relacionados nos materiais; depois a IA recebe a pergunta junto com esses trechos e elabora a resposta, mantendo referência ao material de origem.

Pergunta do aluno → Busca nos materiais → Trechos relevantes → IA responde

2. Arquitetura definida

A equipe decidiu separar responsabilidades. O front-end será desenvolvido em React; o back-end principal em Java com Spring Boot; e a parte de IA fica em um serviço Python independente. Essa separação facilita manutenção, testes e evolução do projeto.

Camada	Tecnologia / papel
Interface	React - telas e interação com o estudante
Back-end	Java + Spring Boot - regras da aplicação e integração dos serviços
Banco	PostgreSQL - dados da aplicação; pgvector previsto para busca vetorial

Camada	Tecnologia / papel
IA	Python + FastAPI + LangChain - processamento dos materiais, Monitor Virtual e prática com questões
LLM	DeepSeek via OpenRouter - geração de respostas; modelo multimodal para páginas/slides visuais

3. O que já está funcionando

Componente	Status	Resultado
Ambiente Python isolado (.venv)	Concluído	Dependências da IA separadas do restante do computador.
FastAPI + Uvicorn	Concluído	Serviço neuron-ai executando localmente e documentação Swagger acessível.
LangChain	Concluído	Camada preparada para orquestrar o fluxo de IA.
OpenRouter + DeepSeek	Concluído	Primeira chamada real ao LLM executada com sucesso.
Leitura de PDF	Testado	PyPDF/PyMuPDF conseguem extrair texto convencional.
Análise multimodal	Testado	Página com fórmulas, exercícios e gráfico foi interpretada pelo modelo visual.
Leitura de PPTX	Testado	Texto e estrutura de slides de Teoria dos Grafos foram extraídos.

4. Estudo de caso 1 - Cálculo para Computação I

O primeiro material utilizado foi um PDF de Limites com 134 páginas e exercícios. Esse teste revelou um problema importante: ler apenas o texto interno de um PDF não garante que todo o conteúdo acadêmico seja recuperado.

O que aconteceu?

Na página 2, tabelas e texto foram extraídos de forma razoável. Entretanto, na página 3, parte da notação matemática desapareceu. Nas páginas de exercícios, o extrator chegou a recuperar apenas títulos como “Exercícios”, embora visualmente existissem expressões matemáticas e um gráfico.

Decisão tomada

Foi adotada uma estratégia híbrida: páginas simples podem ser processadas por extração textual; páginas em que fórmulas, gráficos ou diagramas são essenciais podem ser renderizadas como imagem e analisadas por um modelo multimodal.

Teste	Resultado
Extração textual	Rápida e adequada para páginas predominantemente textuais.
Página matemática complexa	Perda de fórmulas na extração convencional.
DeepSeek multimodal	Recuperou enunciado, 16 expressões de limites e informações do gráfico da página de exercícios.

Teste	Resultado
Conclusão	Não aplicar IA visual em todas as páginas; selecionar somente as que realmente precisam.

5. Estudo de caso 2 - Teoria dos Grafos

O segundo teste mudou o formato: os materiais de Teoria dos Grafos estão em PowerPoint (.pptx). Foi escolhida a Aula 02 - Conceitos Básicos, com 59 slides, como primeiro caso de teste, pois a Aula 01 é uma apresentação da disciplina.

O processador de PPTX conseguiu extrair diretamente títulos, definições e textos dos slides. Também passou a contar imagens, gráficos e outros objetos. Isso é especialmente relevante em Teoria dos Grafos, porque vértices e arestas podem estar desenhados como círculos, linhas e setas, sem aparecer no texto extraído.

Detector inicial

Foi criado um detector barato, que não chama a API de IA. Ele procura sinais como pouco texto com imagem, muitos elementos visuais, gráficos nativos ou texto muito curto. No primeiro teste, 28 dos 59 slides foram marcados como candidatos multimodais.

Esse número ainda é alto. Por isso, a decisão foi não enviar automaticamente os 28 slides para a IA. Primeiro o detector será calibrado visualmente para reduzir chamadas desnecessárias e manter o custo de processamento controlado.

6. Pipeline de ingestão planejado

O termo “ingestão” significa preparar um material acadêmico para que ele possa ser pesquisado pelo Monitor Virtual. O fluxo planejado é o seguinte:

Etapa	Descrição
1 Receber material	PDF ou PPTX original do professor: aulas e, nas disciplinas com prova, listas de exercícios e provas.
2 Extrair conteúdo	Texto, estrutura e metadados como disciplina, assunto, página ou slide.
3 Detectar complexidade visual	Verificar se fórmulas, diagramas ou grafos exigem análise visual.
4 Enriquecer quando necessário	Usar modelo multimodal apenas nos casos selecionados.
5 Dividir em trechos (chunks)	Criar unidades menores e pesquisáveis sem perder a origem. Em listas e provas, a divisão deve respeitar a estrutura de questões (a validar).
6 Gerar embeddings	Transformar o significado dos trechos em representações numéricas.
7 Armazenar no pgvector	Permitir busca semântica no PostgreSQL.
8 Recuperar contexto	Encontrar os trechos mais relacionados à pergunta do aluno (ou, na prática, as questões do assunto escolhido).
9 Gerar resposta	DeepSeek recebe pergunta + contexto e responde com referência à fonte.

7. Metadados e rastreabilidade

Cada trecho indexado deve manter informações de origem. Isso permite que a resposta não fique desconectada do material acadêmico e ajuda a mostrar ao estudante de onde veio o conteúdo. Na prática com questões, a origem também aparece como selo em cada questão (por exemplo, a lista e o número da questão).

Exemplo de metadado	Valor
período	4
disciplina	teoria_dos_grafos
assunto	conceitos_basicos
arquivo	Aula 02 - TG - Conceitos Basicos.pptx
slide	18
tipo_extracao	textual ou multimodal

8. Principais decisões já tomadas

1. Separar front-end, back-end e serviço de IA.
2. Usar React no front-end e Spring Boot/Java no back-end principal.
3. Manter a IA em Python com FastAPI e LangChain.
4. Usar DeepSeek por meio do OpenRouter para os testes de LLM.
5. Planejar PostgreSQL com pgvector para a busca semântica.
6. Preservar os materiais originais; PPTX não precisa ser convertido manualmente para PDF.
7. Usar processamento multimodal de forma seletiva, não em todas as páginas/slides.
8. Guardar página/slide, disciplina, assunto, arquivo e tipo de extração como metadados.
9. Validar cada camada isoladamente antes de construir o RAG completo.
10. **Novo:** o monitor humano fica fora do escopo atual; por enquanto só o Monitor Virtual.
11. **Novo:** questões e provas apenas em disciplinas que têm prova; disciplinas só de projetos não oferecem a prática.
12. **Novo:** incluir uma seção de feedback da plataforma.

9. O que ainda não está pronto

O projeto de IA já possui provas de conceito importantes, mas o RAG completo ainda não foi finalizado. Ainda faltam: calibrar o detector multimodal; criar o splitter definitivo; escolher e integrar o modelo de embeddings; configurar o pgvector; implementar o retriever; montar a cadeia final de pergunta e resposta; integrar o serviço Python ao Spring Boot; e testar a resposta com diferentes disciplinas.

Novo: também faltam, em etapa posterior à dos materiais, a ingestão de listas de exercícios e provas e a prática com questões (incluindo a decisão sobre gerar ou não questões novas por IA).

10. Próximo marco recomendado

O próximo marco técnico é concluir o processamento de materiais: primeiro calibrar a detecção de slides visuais de Teoria dos Grafos; depois transformar o conteúdo processado em chunks com metadados. A partir daí, a equipe pode entrar na etapa de embeddings e pgvector. A prática com questões só entra depois que o RAG básico, com as aulas, estiver funcionando.

11. Resumo para apresentar ao professor

Em termos simples: o NEURON já consegue conversar com um modelo de IA e já consegue ler materiais acadêmicos em PDF e PowerPoint. Os testes mostraram que materiais universitários nem sempre são apenas texto: fórmulas, gráficos e diagramas podem desaparecer em uma leitura convencional. Por isso, a arquitetura foi ajustada para combinar extração tradicional, que é mais barata, com análise visual apenas quando necessária. O objetivo agora é transformar esse conteúdo em uma base pesquisável, permitindo que o Monitor Virtual encontre o material correto antes de responder ao estudante. Nesta versão do escopo, o MVP também prevê a prática com questões no padrão dos professores, nas disciplinas com prova, e um canal de feedback dos estudantes sobre a plataforma.

12. Atualização de escopo (outubro/2026)

Item	Antes	Agora
Monitor humano	Podia permanecer no protótipo.	Fora do escopo atual; fase futura.
Prática com questões	Não previsto.	Prevista, apenas em disciplinas com prova.
Feedback da plataforma	Não previsto (o protótipo tinha avaliação de monitores).	Seção própria para estudantes e administrador.
Ingestão de materiais	Aulas em PDF e PPTX.	Aulas, listas de exercícios e provas.

Estado atual: arquitetura definida + serviço de IA operacional + LLM conectado + ingestão PDF/PPTX em validação.
Próxima fase: chunks → embeddings → pgvector → busca semântica → RAG completo → prática com questões.