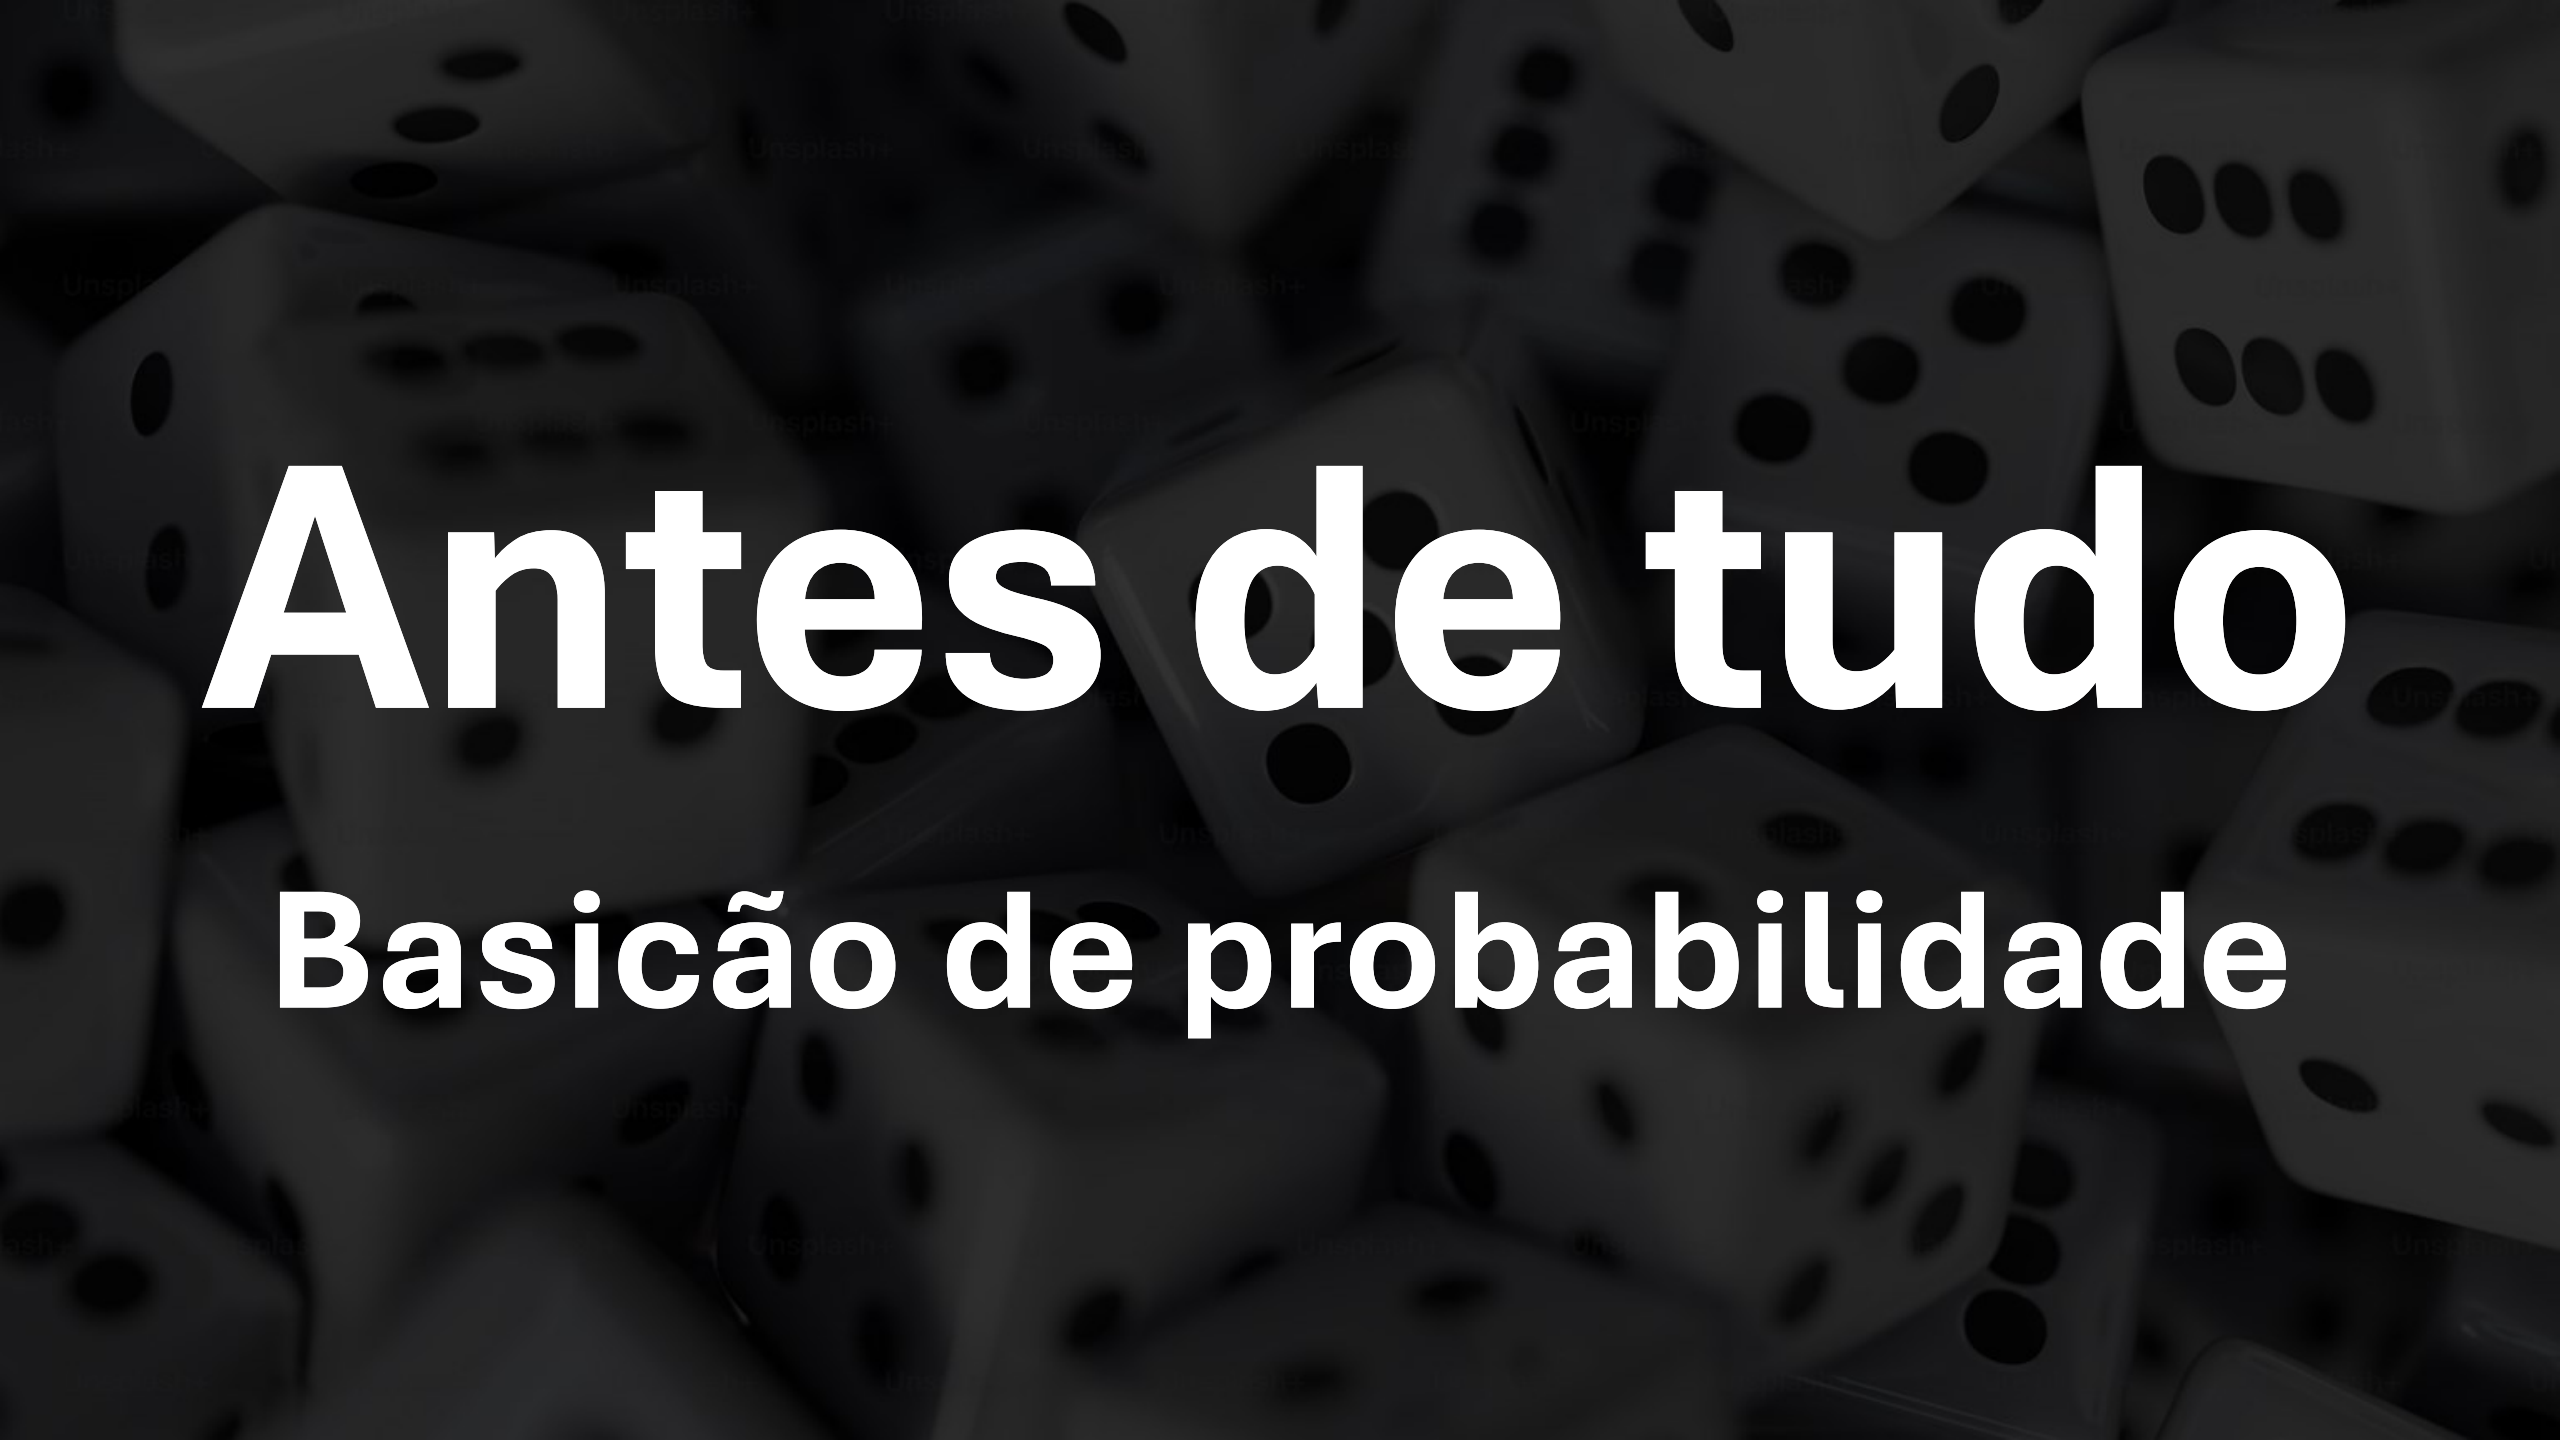
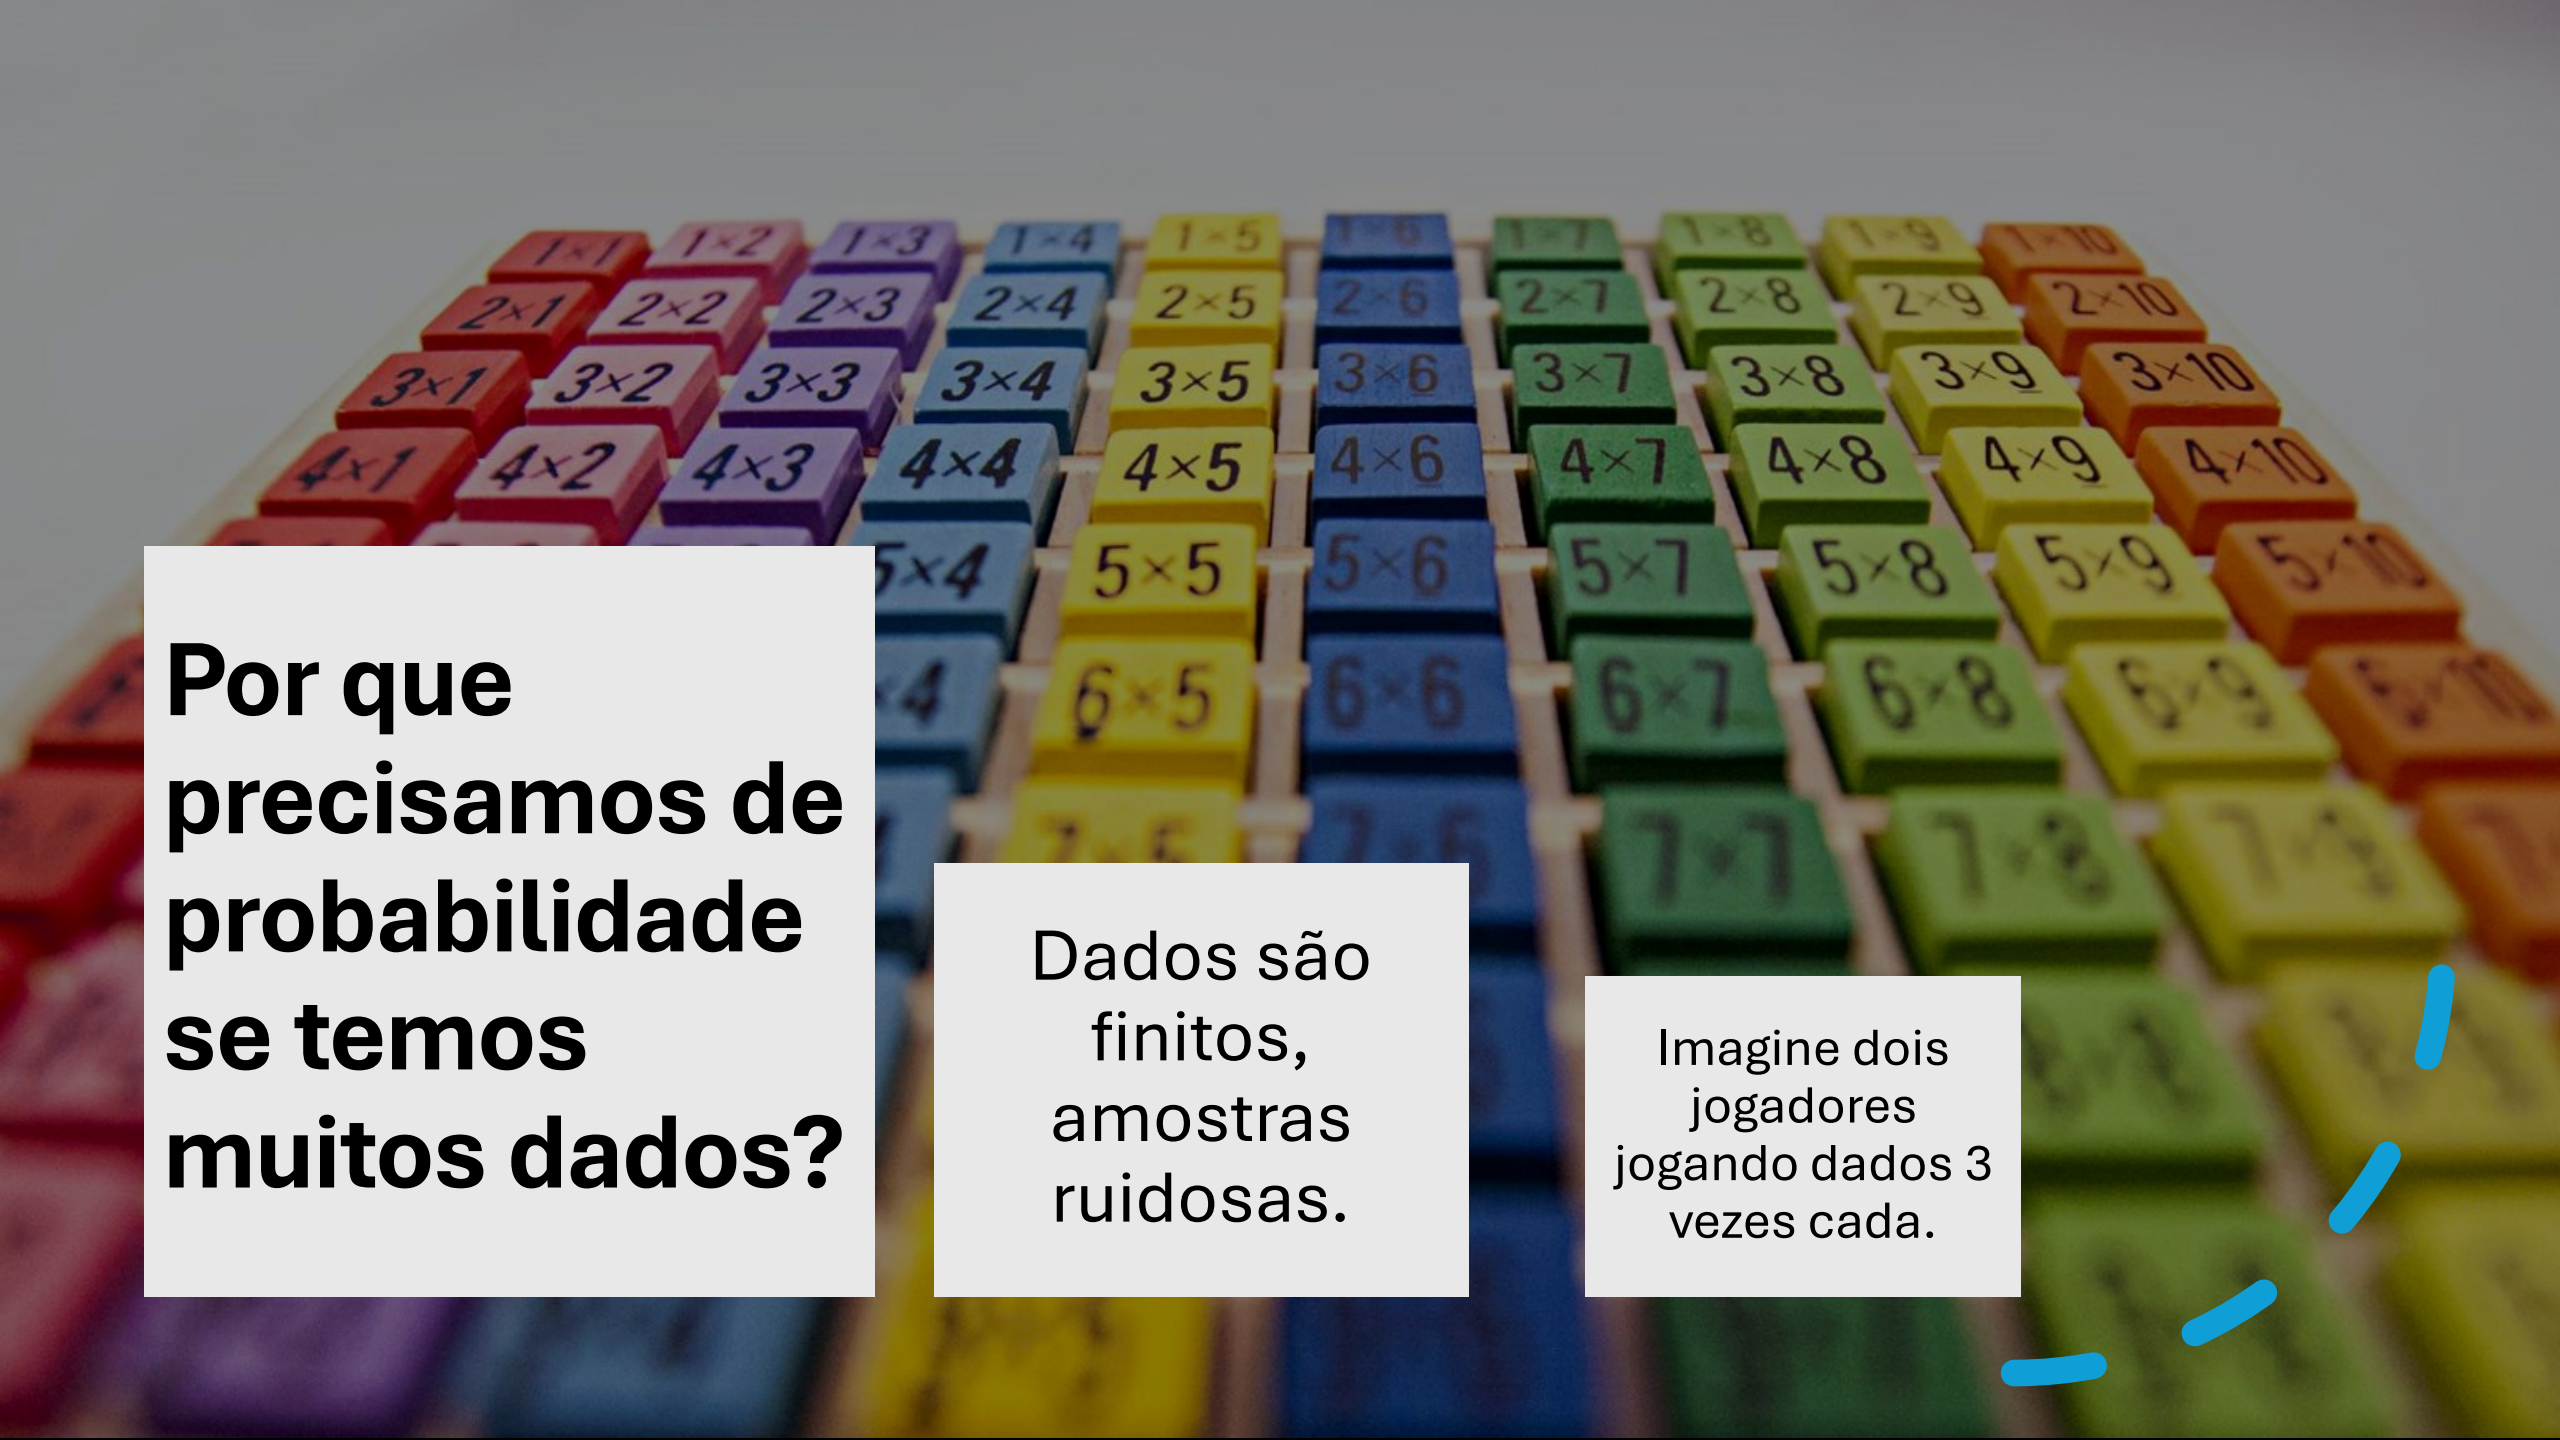


Antes de tudo

Basicão de probabilidade



Por que precisamos de probabilidade se temos muitos dados?

Dados são finitos, amostras ruidosas.

Imagine dois jogadores jogando dados 3 vezes cada.

Introdução à Probabilidade

- Dados são amostras de um processo aleatório
- Modelos fazem inferência sobre populações desconhecidas
- Lida com ruído, falta de dados, outliers
- Permite medir incerteza (intervalos, variâncias, distribuições preditivas)
- Sustenta decisões: classificação, recomendação, detecção de anomalias



Probabilidade: Eventos e Independência

Experimento de probabilidade	• Ação, ou tentativa, através da qual resultados específicos (contagens, medidas ou respostas) são obtidos.
Resultado	• Resultado de um único teste em um experimento de probabilidade.
Espaço de amostra	• Conjunto de todos os possíveis resultados de um experimento de probabilidade.
Evento	• Um ou mais resultados e é uma divisão do espaço de amostra. • Simples: um único resultado. Se houver mais de um, será um evento não simples.

Princípio fundamental da contagem

- Se um evento pode ocorrer de m maneiras e um segundo evento pode ocorrer de n maneiras, o número de maneiras que os dois eventos podem ocorrer em sequência é m*n.
- Pode ser estendido para qualquer número de eventos ocorrendo em sequência.
- Podemos usar o diagrama de árvore, para ajudar a calcular.

Tipos de probabilidade

- **Probabilidade clássica**
- Cada resultado em uma amostragem é igualmente provável.
  - $P(E) = \frac{nº\ de\ resultados\ no\ evento\ E}{nº\ total\ de\ resultados\ no\ espaço\ amostral}$
- **Probabilidade empírica (estatística)**
- Baseado nas observações obtidas de experimentos de probabilidade
- Frequência relativa de um evento:
- $P(E) = \frac{frequência\ do\ evento\ E}{frequência\ total} = \frac{f}{n}$

Um pouco mais de probabilidade

- **Lei dos grandes números**
  - Conforme um experimento é repetido, a probabilidade empírica de um evento se aproxima da probabilidade teorética (real) do evento.
- **Regra da amplitude das probabilidades**
  - A probabilidade de um evento E ocorrer é entre 0 e 1
  - $0 \leq P(E) \leq 1$
- **Complemento do evento E**
  - O conjunto de todos os resultados em um espaço de amostra que os resultados não estão incluídos no evento E.
  - Denotado E ' (E prime).

União de dois eventos

- **Fórmula geral:**

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Significado: A probabilidade de ocorrer **A ou B** (ou ambos) é a soma das probabilidades de A e B, **menos** a interseção (para não contar duas vezes).

  - **Exemplo**: Se 60% gostam de futebol, 50% gostam de vôlei, e 30% gostam dos dois:

$$P(A \cup B) = 0{,}6 + 0{,}5 - 0{,}3 = 0{,}8$$

União de dois eventos

- **Se A e B são disjuntos (não ocorrem juntos):**

$$P(A \cup B) = P(A) + P(B)$$

  - **Exemplo**: Jogar um dado. A = sair 1, B = sair 2. Como não podem ocorrer juntos:

$$P(A \cup B) = 1/6 + 1/6 = 2/6$$

Probabilidade condicional

- **Fórmula:**

$$P(A|B)=P(A\cap B)/P(B), \text{ com } P(B)>0$$

Significado: Probabilidade de A acontecer **sabendo que B aconteceu**.

- **Exemplo**: Em uma turma, 40% são meninas, e 10% são meninas que usam óculos. Qual a chance de uma pessoa usar óculos **sabendo que é menina**?

$$P(\text{óculos}|\text{menina})=0,10/0,40=0,25$$

Regra do produto

- **Fórmula:**

$$P(A \cap B) = P(A|B) \cdot P(B)$$

Significado: Probabilidade de A e B acontecerem juntos.

- **Exemplo**: Se 40% são meninas e 25% das meninas usam óculos:

$$P(\text{menina} \cap \text{óculos}) = 0{,}25 \cdot 0{,}40 = 0{,}10$$

Independência

- **Fórmulas equivalentes:**

$$P(A \cap B) = P(A) \cdot P(B)$$

$$P(A|B) = P(A)$$

Significado: A ocorrência de B **não afeta** a chance de A.

- **Exemplo**: Jogar dois dados. A = sair 6 no primeiro, B = sair 3 no segundo. Como são independentes:

$$P(A \cap B) = 1/6 \cdot 1/6 = 1/36$$

Arranjo, Permutação e Combinação

- Formas de contar de quantas maneiras podemos selecionar e (opcionalmente) ordenar elementos de um conjunto.
- A diferença entre elas se resume a dois pontos:

Quantos elementos escolhemos?

Todos os elementos do conjunto, ou

Apenas parte deles (um número k menor que n).

A ordem importa ou não?

Importa: mudar a sequência conta como algo novo, ou

Não importa: só importa quem está no grupo, não a ordem.

Arranjo

- Quando usar:

  você quer selecionar k elementos dentre n e ordená-los.

- Ordem importa?

  Sim.

Fórmula:

$$A_k^n = \frac{n!}{(n-k)!}$$

Permutação Simples (Tipo especial de arranjo)

- Quando usar:

  reordenar **todos** os n elementos, e **toda** ordem é distinta.

- Ordem importa?

  Sim.

Fórmula:

$$P_n^n = \frac{n!}{(n-n)!} = \frac{n!}{0!} = \frac{n!}{1} = n!$$

Permutação com Repetição

- Quando usar:

  Quando há **elementos repetidos** no conjunto.

- Ordem importa?

  Sim.

Fórmula:

$$P^{n}_{a,b,c\ldots} = \frac{n!}{a!\,b!\,c!\,\ldots}$$

Permutação Circular

- Quando usar:

  Quando os elementos são organizados em círculo, como em uma mesa redonda.

- Ordem importa?

  Sim.

Fórmula:

$$P_{circular}(n) = (n-1)!$$

Por quê?:

Porque uma rotação completa não muda a ordem relativa dos elementos.

Permutação Colar

- Quando usar:

  dispor contas em um colar onde refletir (virar de fora para dentro) também não cria disposição nova.

- Ordem importa?

  Sim, mas rotações e reflexões são equivalentes.

Fórmula:

$$P_{Colar}(n) = \frac{(n-1)!}{2}$$

Combinação

- Quando usar:

  você quer selecionar k elementos dentre n sem se importar com a ordem.

- Ordem importa?

  Não.

Fórmula:

$$A_k^n = \frac{n!}{k!\,(n-k)!}$$



Estatística

Análise Exploratória de Dados

Ver código

Estatística: Descritiva x Inferencial

- *Descritiva* conta a história do que **já temos**;
- *Inferencial* projeta essa história para além, sempre carregando um “rodapé” de incerteza.





Tipo de Dados

Estruturados

- Tabelas (linhas = registros, colunas = variáveis).
- Exemplo: DataFrames no pandas.

Não estruturados

- Texto, imagens, vídeos, logs.

- **Tipo de Dados:**
  Quantitativos x Qualitativos
    Discretos x Contínuos
    Nominais x Ordinais x Binários

Tipo de Dados

Dados Numéricos

- **Contínuos** (nº de campeonatos, peso)
- **Discretos** (contagem de eventos)

Dados Categóricos

- **Nominais** (estado, cor)
- **Ordinais** (classificação 1º–5º)
- **Binários** (0/1, verdadeiro/falso)

Variáveis Aleatórias: Discretas e Contínuas

Variável Aleatória:

- Resultado numérico de um experimento aleatório.

Discreta:

- Assume valores específicos (contáveis). Ex: número de filhos.

Contínua:

- Assume qualquer valor em um intervalo. Ex: altura, peso.

Variáveis Aleatórias Discretas

- Assume valores específicos e isolados.
- Probabilidade dada pela função de probabilidade de massa (PMF):
  - $P(X = x) = p(x)$
- Exemplo: lançar um dado justo (cada face com probabilidade 1/6).

Variáveis Aleatórias Contínuas

Assume valores em intervalos contínuos.

Probabilidade dada pela função densidade de probabilidade (PDF):

- $P(a \leq X \leq b) = \int f(x)\,dx$ (área sob a curva)

Exemplo: tempo necessário para concluir uma tarefa.

Função Massa e Função Densidade de Probabilidade (PDF)

PMF (Probability Mass Function) - Discreta:

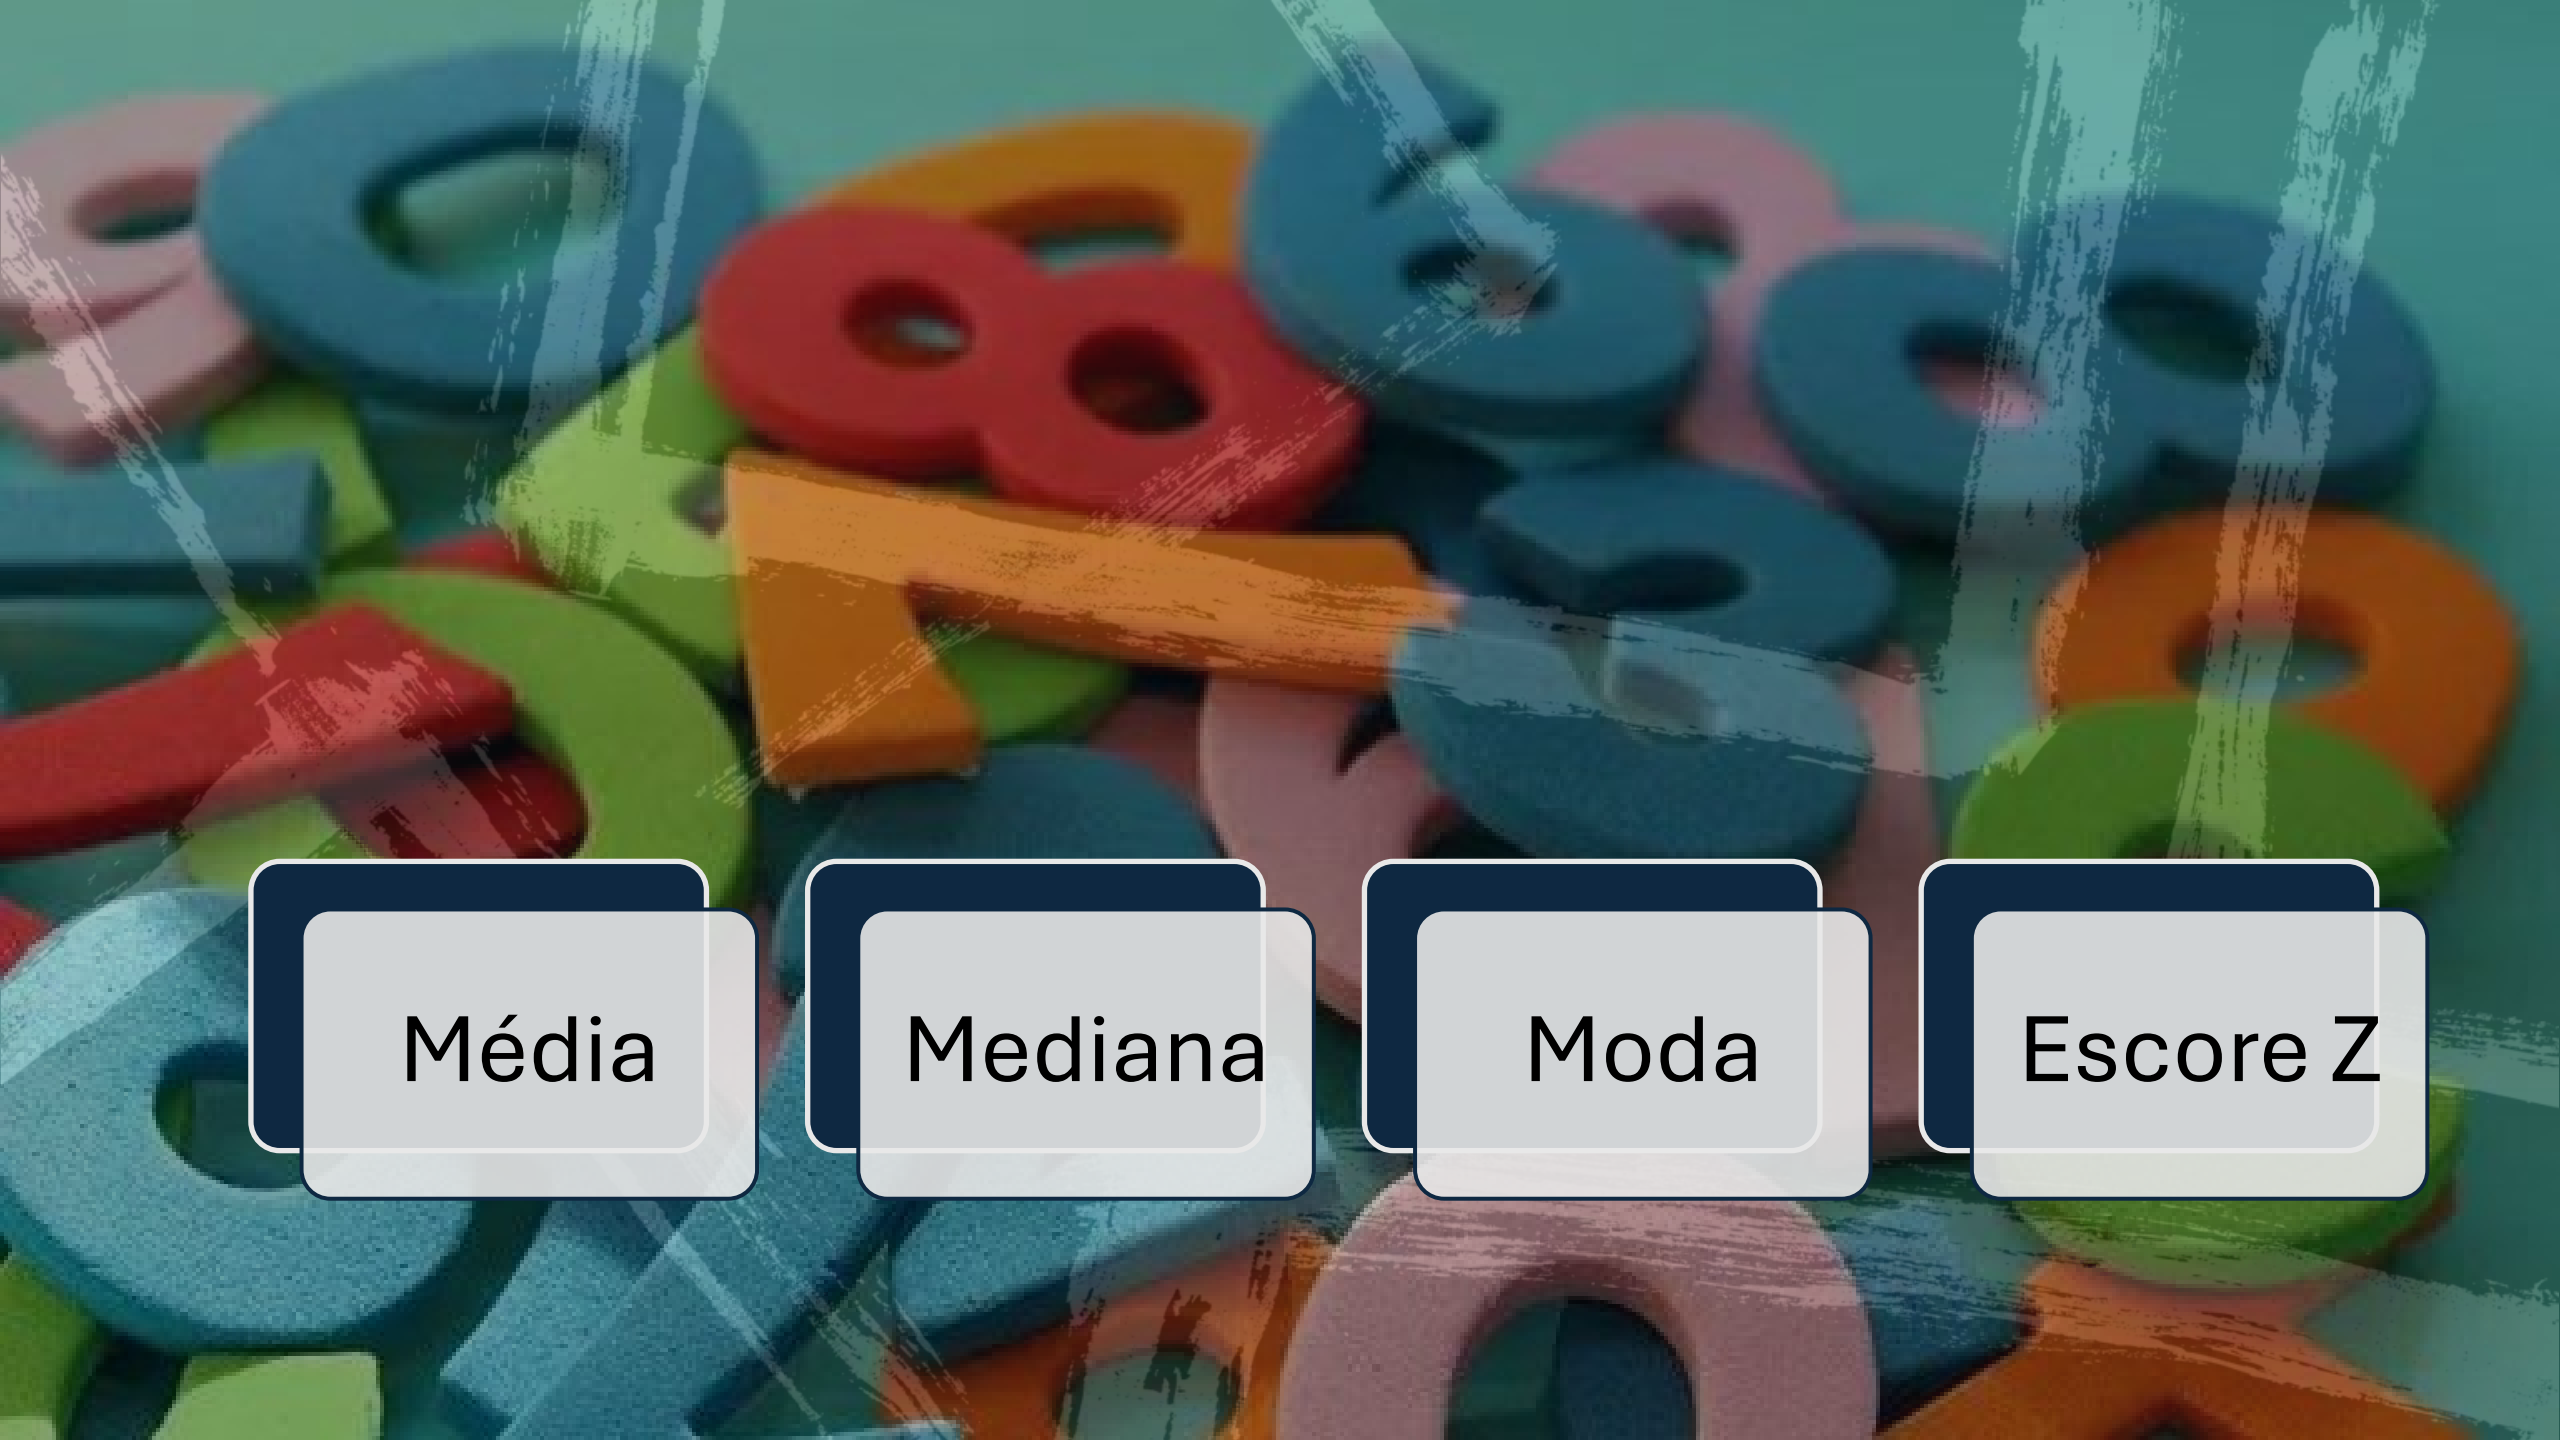
- Variáveis discretas (contáveis)
- Probabilidade atribuída a valores específicos
- Soma das probabilidades é igual a 1: $\Sigma\ p(x) = 1$
- Exemplo: Lançamento de um dado

PDF (Probability Density Function) - Contínua:

- Variáveis contínuas (intervalos)
- Probabilidade atribuída a intervalos (área sob curva)
- Área total sob a curva é igual a 1: $\int f(x)\ dx = 1$
- Probabilidade em ponto específico é 0
- Exemplo: Altura de pessoas



Medidas de tendência central


Média
Mediana
Moda
Escore Z

Medidas de tendência central

- **Média**
  - **O que é?**
    "Valor médio" – soma dos valores dividida pela quantidade.
  - Dá uma ideia de “centro” dos dados.
  - Cuidado: sensível a valores muito extremos (outliers).
- **Mediana**
  - **O que é?**
    Valor que fica no meio quando ordenamos os dados.
  - Melhor quando há **outliers** ou distribuição muito assimétrica.

Medidas de tendência central

- **Média Ponderada**
  - **O que é?**
    Média que dá mais peso para certos valores.
  - Ajustar a importância de cada valor.
- **Média Aparada (Trimmed Mean)**
  - **O que é?**
    Média calculada **removendo valores extremos**.
  - Útil quando queremos média menos sensível a outliers.

Medidas de tendência central

- **Média Geométrica**
  - **O que é?**
    Taxa de crescimento média de algo que muda de forma multiplicativa (como juros ou retornos percentuais)..

    Para um conjunto de n números x1,x2,...,xn, a Média Geométrica (MG) é calculada como a raiz n-ésima do produto de todos os números.
- **Moda**
  - **O que é?**

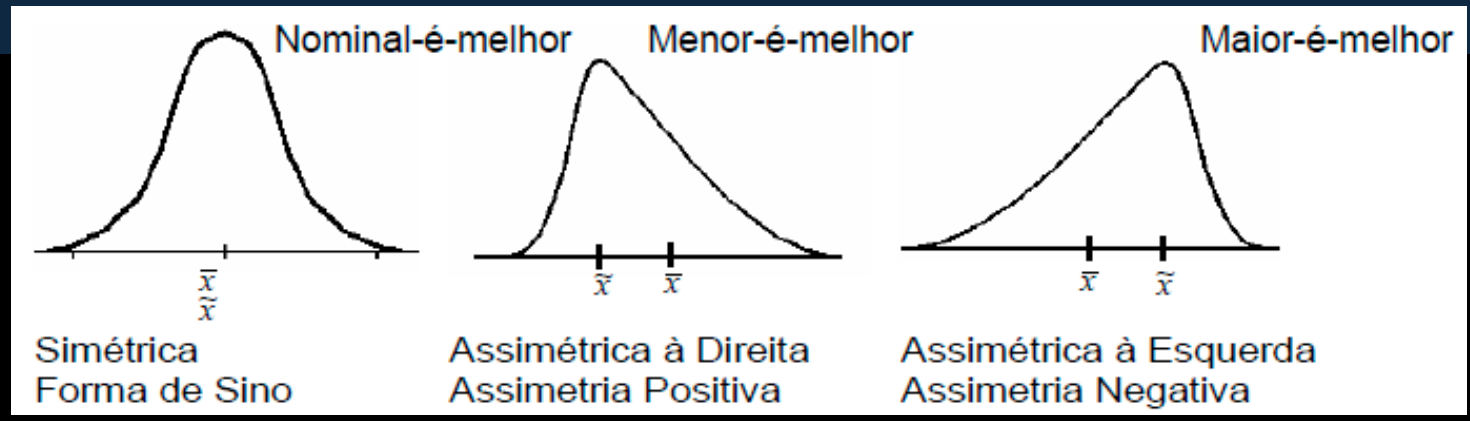
    valor mais frequente em um conjunto de dados.
  - Pode existir nenhuma moda, uma moda (unimodal), duas modas (bimodal) ou várias modas (multimodal).
  - Pode ser usada tanto em dados numéricos quanto categóricos.
  - Pode ser **única, múltipla ou inexistente.**
  - Útil para **dados numéricos e categóricos.**

Medidas de tendência central que depende de dispersão

- **Escore Z**
  - **O que é?**
    Medida de posição relativa.
  - Indica quantos desvios-padrão um valor está acima ou abaixo da média.

Medidas de tendência central

Média < Mediana → Distribuição assimétrica à esquerda





Medidas de dispersão


Amplitude
Variância
Desvio Padrão
Fractis
IRQ

Medidas de Variabilidade

- **Variância e Desvio-Padrão**
  - Ideia: o quanto os valores se afastam da média.
  - Variância = média dos quadrados dos desvios em relação à média.
  - Desvio-Padrão = raiz quadrada da variância.
  - Medida mais comum de dispersão.
  - Quanto maior, mais espalhados os dados.

Medidas de Variabilidade

- **Desvio Absoluto Médio (MAD)**
  - O que é?
    Média das distâncias absolutas em relação à média.
  - Menos sensível a outliers que variância.

- **Amplitude (Range)**
  - O que é?
    Diferença entre maior e menor valor.
  - Simples, mas muito sensível a outliers.

Medidas de Variabilidade

- **Fractis**
  - O que é?

    são números que particionam (dividem) um conjunto de dados ordenados em partes iguais.
  - Ex: Quartis dividem dados ordenados em quatro partes aproximadamente iguais.
  - Mediana = 50º percentil.
  - Indice = (n-1)* Q_n **(mas lembre que o indice inicia do zero)**
- **IQR (Intervalo Interquartil)**
  - **O que é?**

    Diferença entre 75º e 25º percentil.
  - Mede a "caixa" central dos dados.
  - Mais robusto a outliers.



Outras medidas

Outras medidas

- **Valor Esperado (Expected Value)**
  - **O que é?**

    média ponderada dos possíveis resultados, onde os **pesos são as probabilidades** de cada resultado acontecer.
- Muito usado para prever **quanto se pode esperar ganhar (ou perder) em média** em situações de incerteza: investimentos, vendas, projetos, jogos, etc.
- **Como calcular?**
- Multiplica-se cada valor possível pelo sua probabilidade.
- Soma-se todos esses resultados.





Outras medidas

- **Probabilidade**
  - **O que é?**

    Probabilidade é o **quanto esperamos que um evento ocorra, em média**, se repetíssemos o experimento muitas vezes.
- Pode ser apresentada como fração, decimal ou porcentagem.
- Exemplo: Se as chances de vitória de um time são “2 para 1”, a probabilidade é $2/(2+1)=2/3\approx66,7\%$ 2/(2+1) = 2/3 \approx 66,7\%2/(2+1)=2/3≈66,7%.

Outras medidas

- **Coeficente de correlação**
  - Mede força e direção da relação linear entre duas variáveis numéricas.
- Intervalo:
  - –1 = relação negativa perfeita
  - 0 = sem relação linear
  - +1 = relação positiva perfeita
- Fórmula:

$$r = \frac{\sum(x - \bar{x})(y - \bar{y})}{(n-1)S_x S_y}$$



Outras medidas

- **Matriz de Correlação**
  - Tabela com correlações entre pares de variáveis.
- Propriedades:
  - Diagonal = 1 (variável consigo mesma)
  - Simétrica (r(X,Y) = r(Y,X))
- Uso:
  - Ver relações entre múltiplas variáveis
  - Avaliar multicolinearidade





Tabela de frequência
Representação gráf

Distribuição de frequência

- Tabela que mostra classes ou intervalos de dados com uma contagem do número de entradas em cada classe
- A frequência, *f*, de uma classe é o número de entradas de dados na classe

Classe	Frequência, *f*
1 – 5	5
6 – 10	8
11 – 15	6
16 – 20	8
21 – 25	5
26 – 30	4

Tamanho da classe 6 – 1 = 5

Limite inferior da classe

Limite superior da classe

Distribuição de frequência

Decida o número de classes.

- Geralmente entre 5 e 20; do contrário, pode ser difícil detectar padrões

Encontre o tamanho da classe.

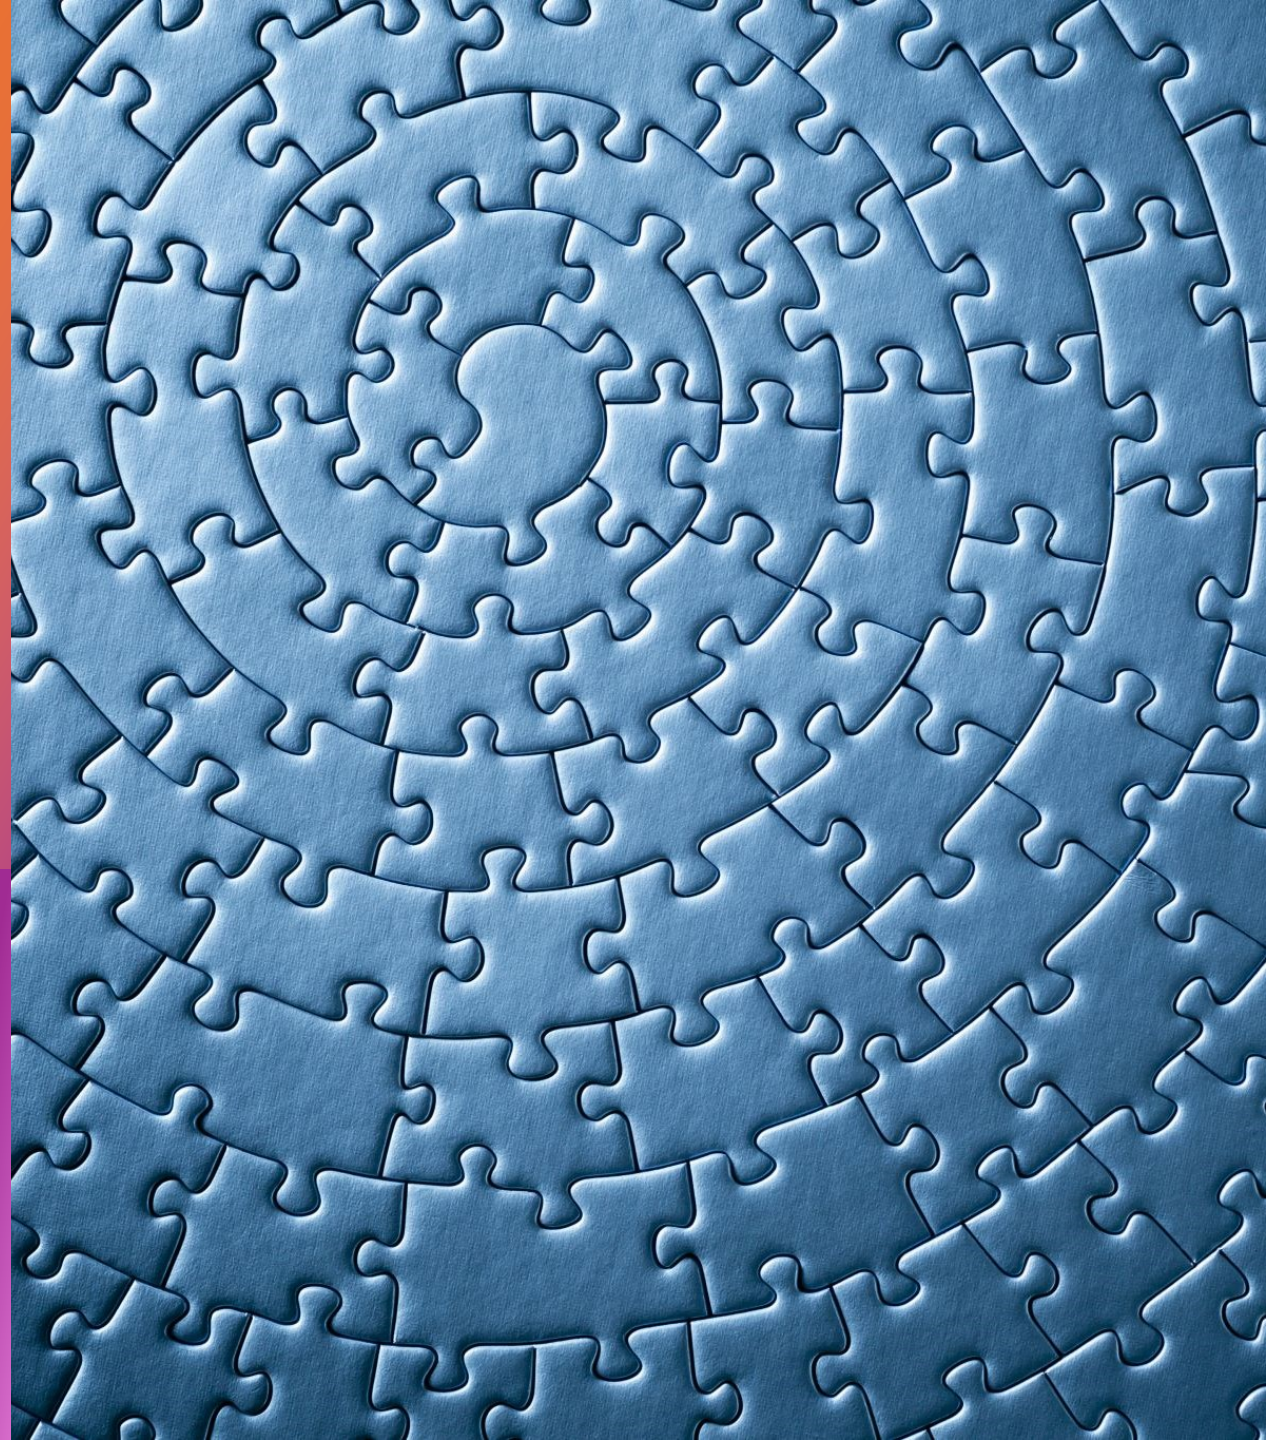
- Determinar a variação dos dados
- Dividir a variação pelo número de classes
- Arredondar para cima para o próximo número conveniente

Encontre os limites da classe.

- Pode-se usar a entrada de menor valor como o limite inferior da primeira classe
- Encontrar os limites inferiores remanescentes (adicione o tamanho da classe ao limite inferior da classe precedente)
- Encontrar o limite superior da primeira classe.
- Encontrar os limites superiores remanescentes

Fazer um registro para cada entrada de dados na fileira da classe apropriada.

Contar os registros para encontrar a frequência total f para cada classe.



Exemplo

Vamos fazer a tabela de distribuição?

50 40 41 17 11 7 22 44
28 21 19 23 37 51 54 42
86 41 78 56 72 56 17 7
69 30 80 56 29 33 46 31
39 20 18 29 34 59 73 77
36 39 30 62 54 67 39 31
53 44

Resposta

7, 7, 11, 17, 17,
18, 19, 20, 21, 22,
23, 28, 29, 29, 30,
30, 31, 31, 33, 34,
36, 37, 39, 39, 39,
40, 41, 41, 42, 44,
44, 46, 50, 51, 53,
54, 54, 56, 56, 59,
62, 67, 69, 72, 73,
77, 78, 80, 86

Tamanho da Classe:

$$\frac{maior\ valor - menor\ valor}{número\ de\ classes} = \frac{86 - 7}{7} = 11{,}29$$

Valor aproximado: 12

Classe	Registro	Frequência, f
7 – 18	IIII I	6
19 – 30	IIII IIII	10
31 – 42	IIII IIII III	13
43 – 54	IIII III	8
55 – 66	IIII	5
67 – 78	IIII I	6
79 – 90	II	2

Resposta

- Ponto médio de uma classe
- Frequência relativa de uma classe
- Frequência acumulada de uma classe
- Fronteiras de classes

$\Sigma f = 50$

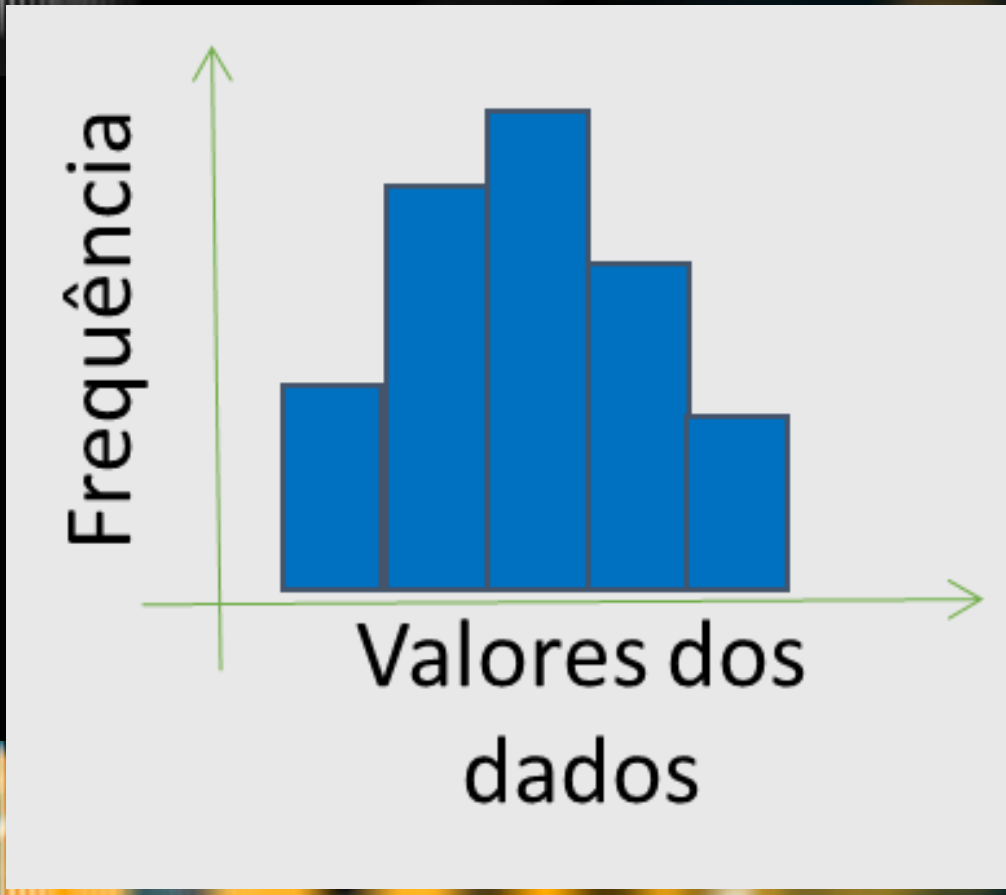
$\sum \frac{f}{n} = 1$

Classe	Fronteira de classe	Frequência, f	Ponto médio	Frequência relativa	Frequência acumulada
7 – 18	6,5 – 18,5	6	12.5	0.12	6
19 – 30	18-6 – 30,5	10	24.5	0.20	16
31 – 42	30,5 – 42,5	13	36.5	0.26	29
43 – 54	42,5 – 54,5	8	48.5	0.16	37
55 – 66	54,5 – 66,5	5	60.5	0.10	42
67 – 78	66,5 – 78,5	6	72.5	0.12	48
79 – 90	78,5 – 90,5	2	84.5	0.04	50

Gráficos

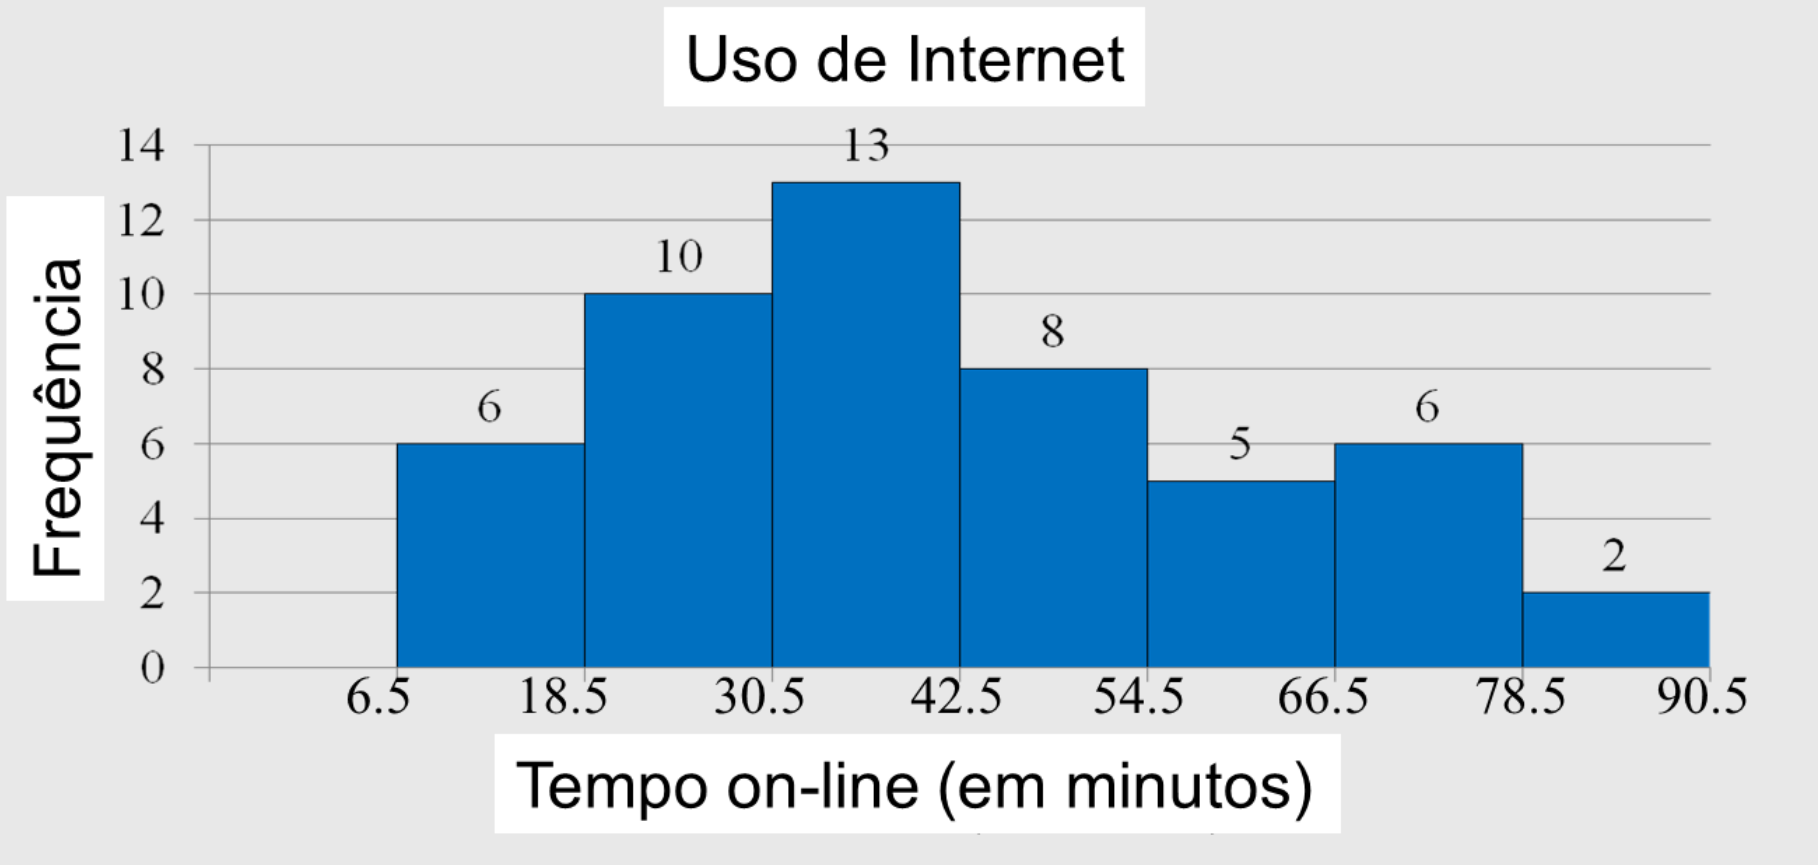
- Histograma de frequência

- Gráfico de barras que representa a distribuição da frequência
  - O eixo horizontal é quantitativo e mede os valores dos dados
  - O eixo vertical mede as frequências das classes
  - Barras consecutivas precisam se tocar



Gráficos

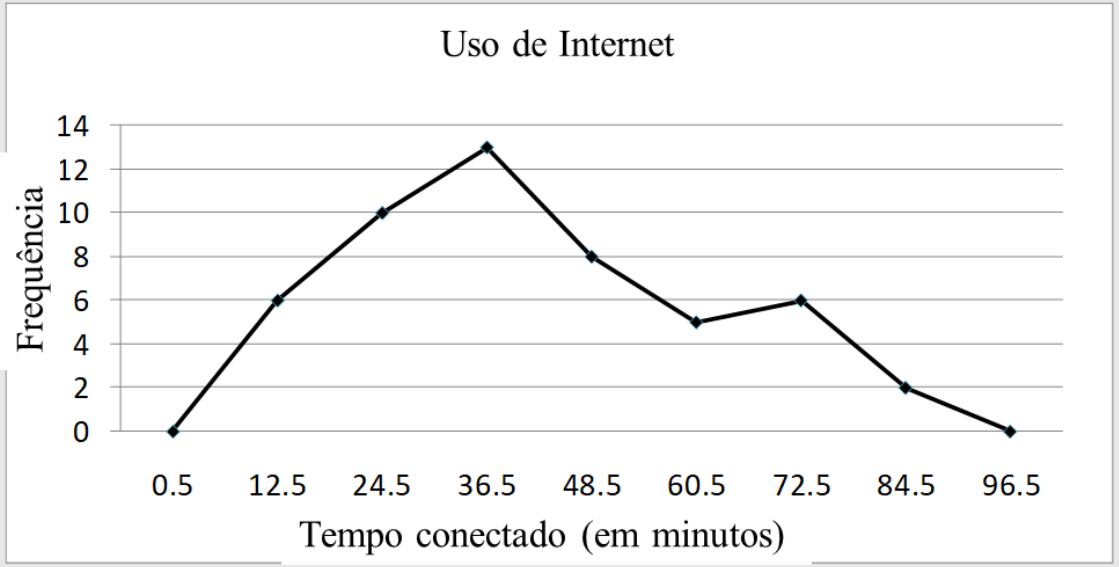
- Histograma de frequência



Gráficos

- Polígono de frequência

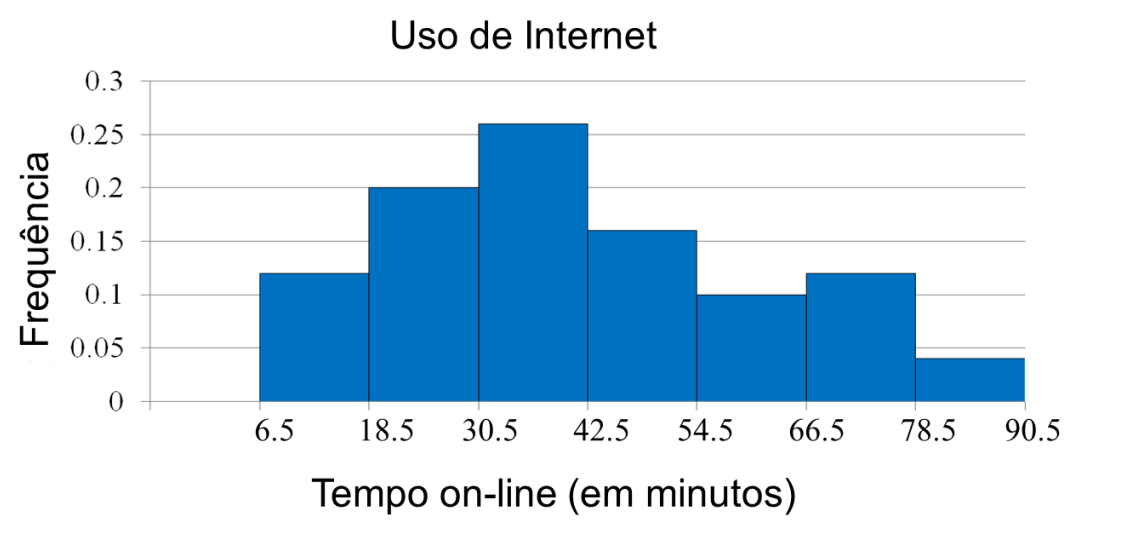
- Gráfico em linha que enfatiza a mudança contínua nas frequências.
- Inicia e termina sempre no eixo x.



Gráficos

- Histograma de frequência relativa

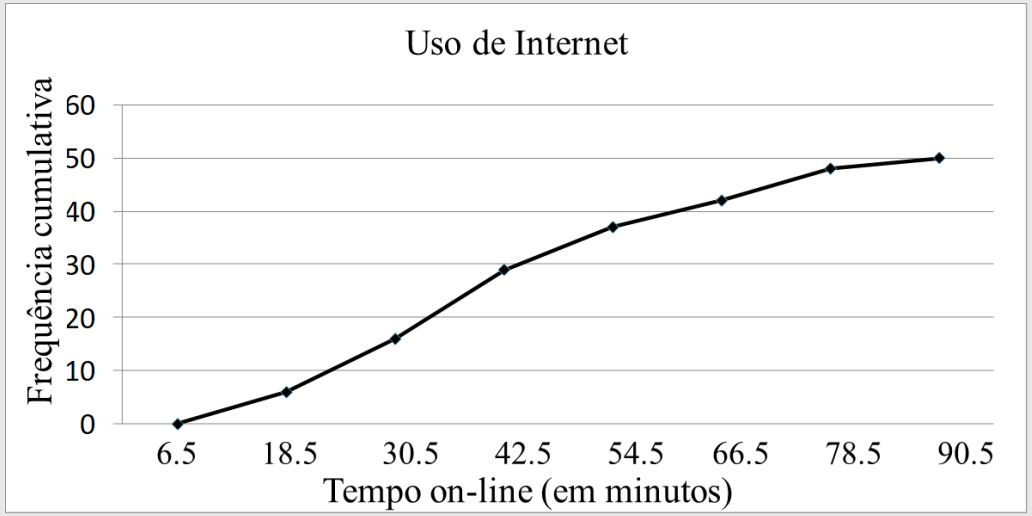
- Tem o mesmo formato e eixo horizontal que o histograma de frequência correspondente
- O eixo vertical mede as frequências relativas e não as frequências



Gráficos

- Gráfico de frequências cumulativas ou ogiva

- Gráfico de linhas que demonstra a frequência cumulativa de cada classe em sua fronteira superior
  - As fronteiras superiores são demarcadas no eixo horizontal
  - As frequências cumulativas são demarcadas no eixo vertical



Gráficos

- Diagrama de ramos-e-folhas

- Cada número é separado em um ramo e uma folha
- Similar a um histograma
- Ainda contém os valores dos dados originais

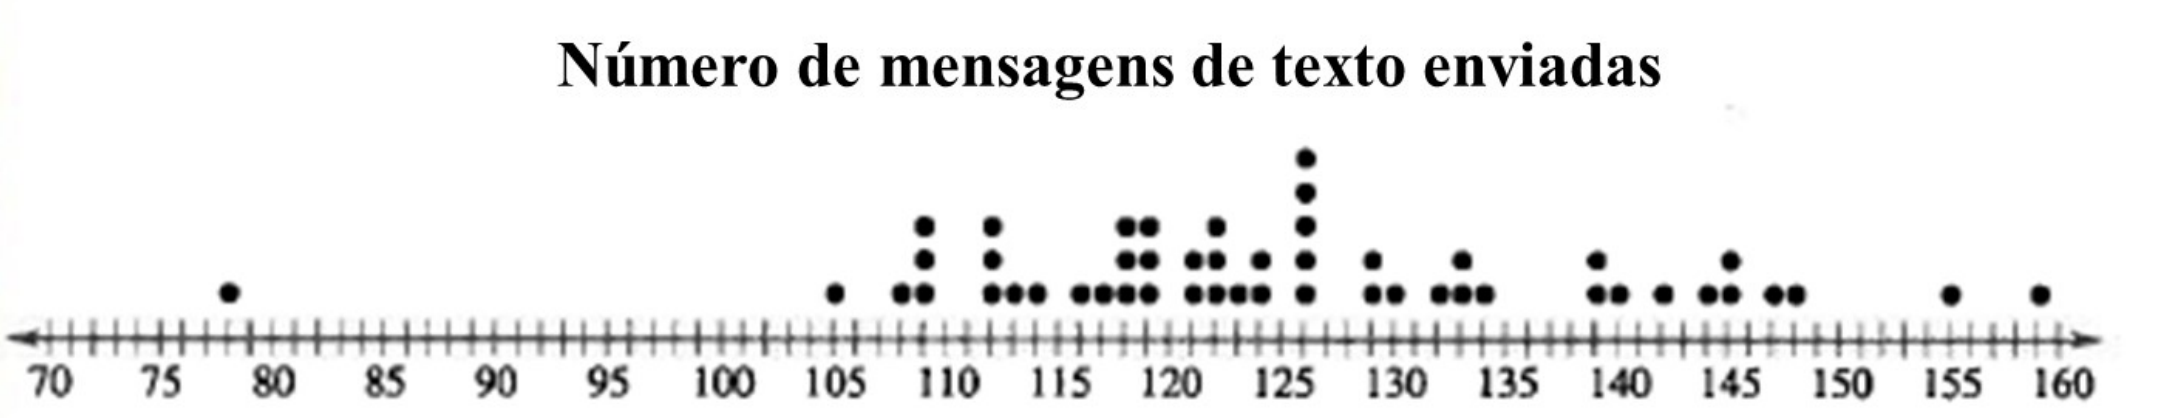
21	25	25	26	27
28	30	36	36	45



Gráficos

- Diagrama de pontos

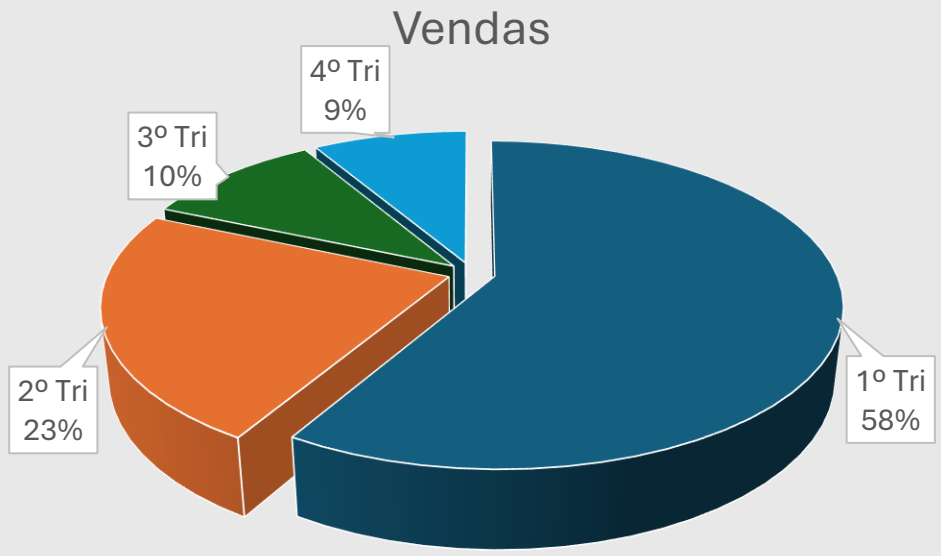
- Cada entrada de dados é posta usando um ponto acima de um eixo horizontal.



Gráficos

- Gráfico de pizza

- Um círculo é dividido em vários setores, que representam categorias
- A área de cada setor é proporcional à frequência de cada categoria

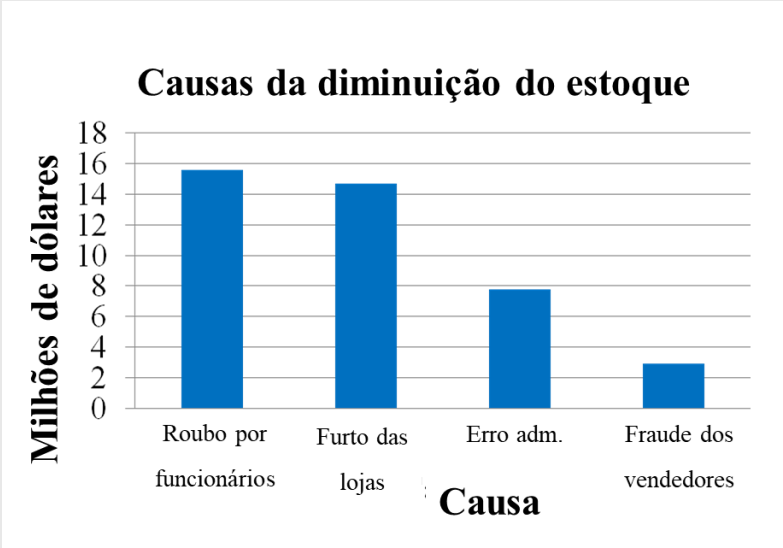


Gráficos

- Gráfico de Pareto (para dados Qualitativos)

- Gráfico de barras verticais no qual a altura de cada barra representa uma frequência ou uma frequência relativa
- As barras são posicionadas por ordem decrescente de altura; a barra mais alta é posicionada à esquerda

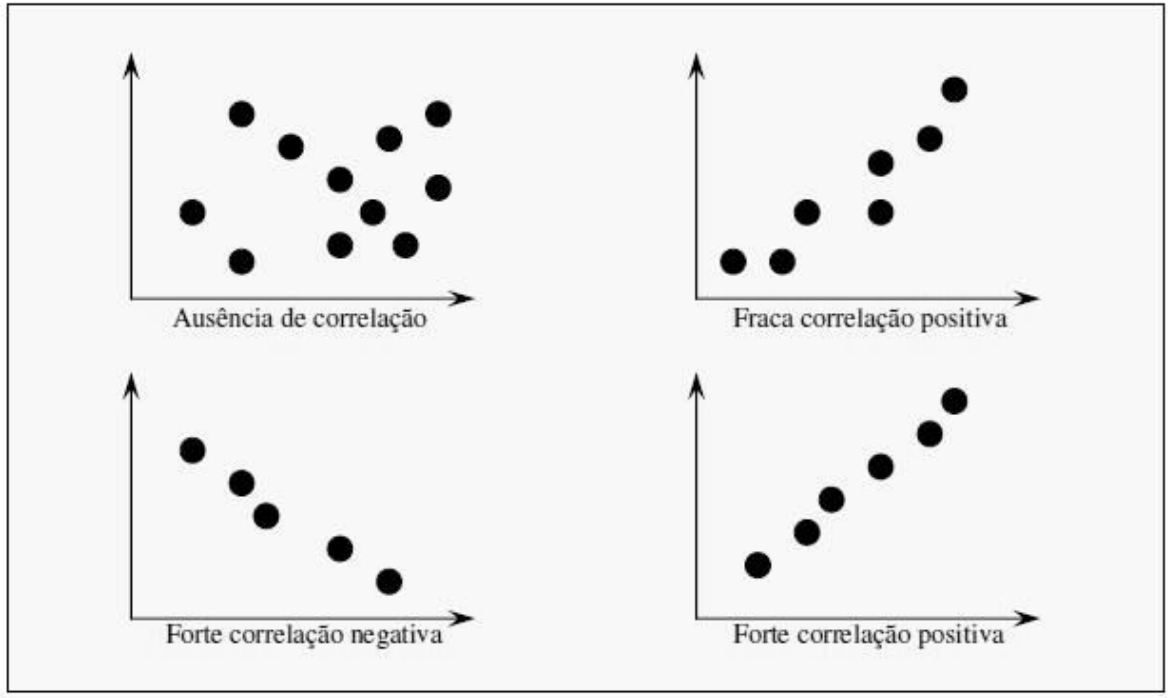
Causa	US$ (em milhões)
Erro adm.	7,8
Roubo por funcionários	15,6
Furto das lojas	14,7
Fraude dos vendedores	2,9



Gráficos

- **Scatterplot (Gráfico de Dispersão)**

- Gráfico que mostra pares de valores (X,Y) como pontos em um plano.
- Objetivo:
  - Visualizar relação entre variáveis
  - Ver padrão (linearidade, curvatura, dispersão)
- Componentes:
  - Eixo X = variável independente
  - Eixo Y = variável dependente

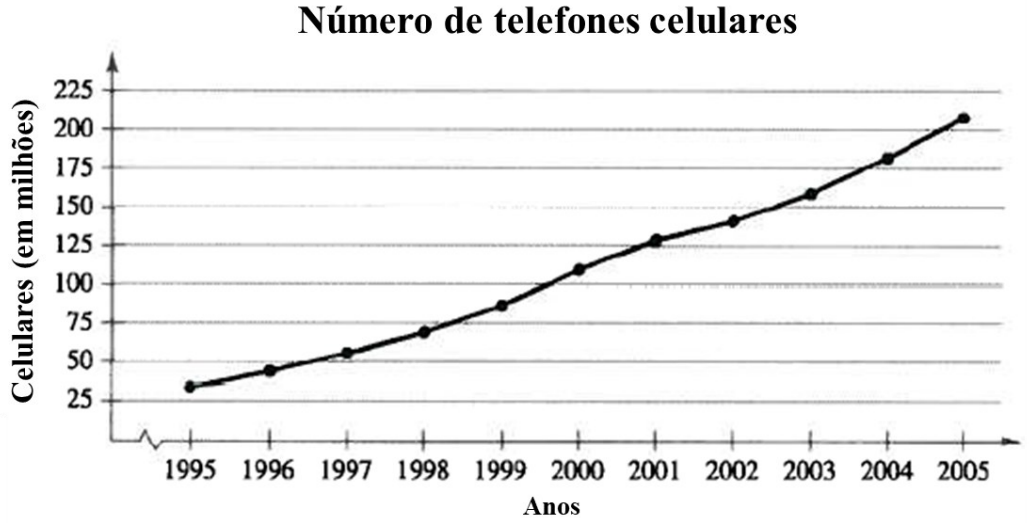


Diagramas de Dispersão.

Gráficos

- Série temporal

- Conjuntos de dados são compostos de entradas quantitativas tomadas em intervalos regulares em um período de tempo
- Usa um gráfico de períodos de tempo

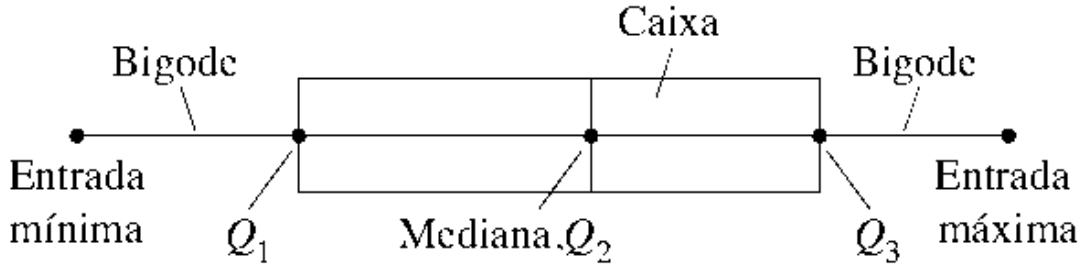


Ano	Usuários (em milhões)
1995	33.8
1996	44.0
1997	55.3
1998	69.2
1999	86.0
2000	109.5
2001	128.4
2002	140.8
2003	158.7
2004	182.1
2005	207.9

Gráficos

- Gráfico de caixa-e-bigodes

- Ferramenta exploratória de análise de dados
- Destaca qualidades importantes do conjunto de dados
- Requer (sumário de cinco números):
- Entrada mínima
- Primeiro quartil Q1
- Mediana Q2
- Terceiro quartil Q3
- Entrada máxima



Distribuição de Dados e Amostragem



Passo a passo

Definição do problema

Planejamento

Coleta de dados

Crítica dos dados

Apuração dos dados.

Apresentação dos dados

Análise e interpretação dos dados

Planejamento

Pra quê?

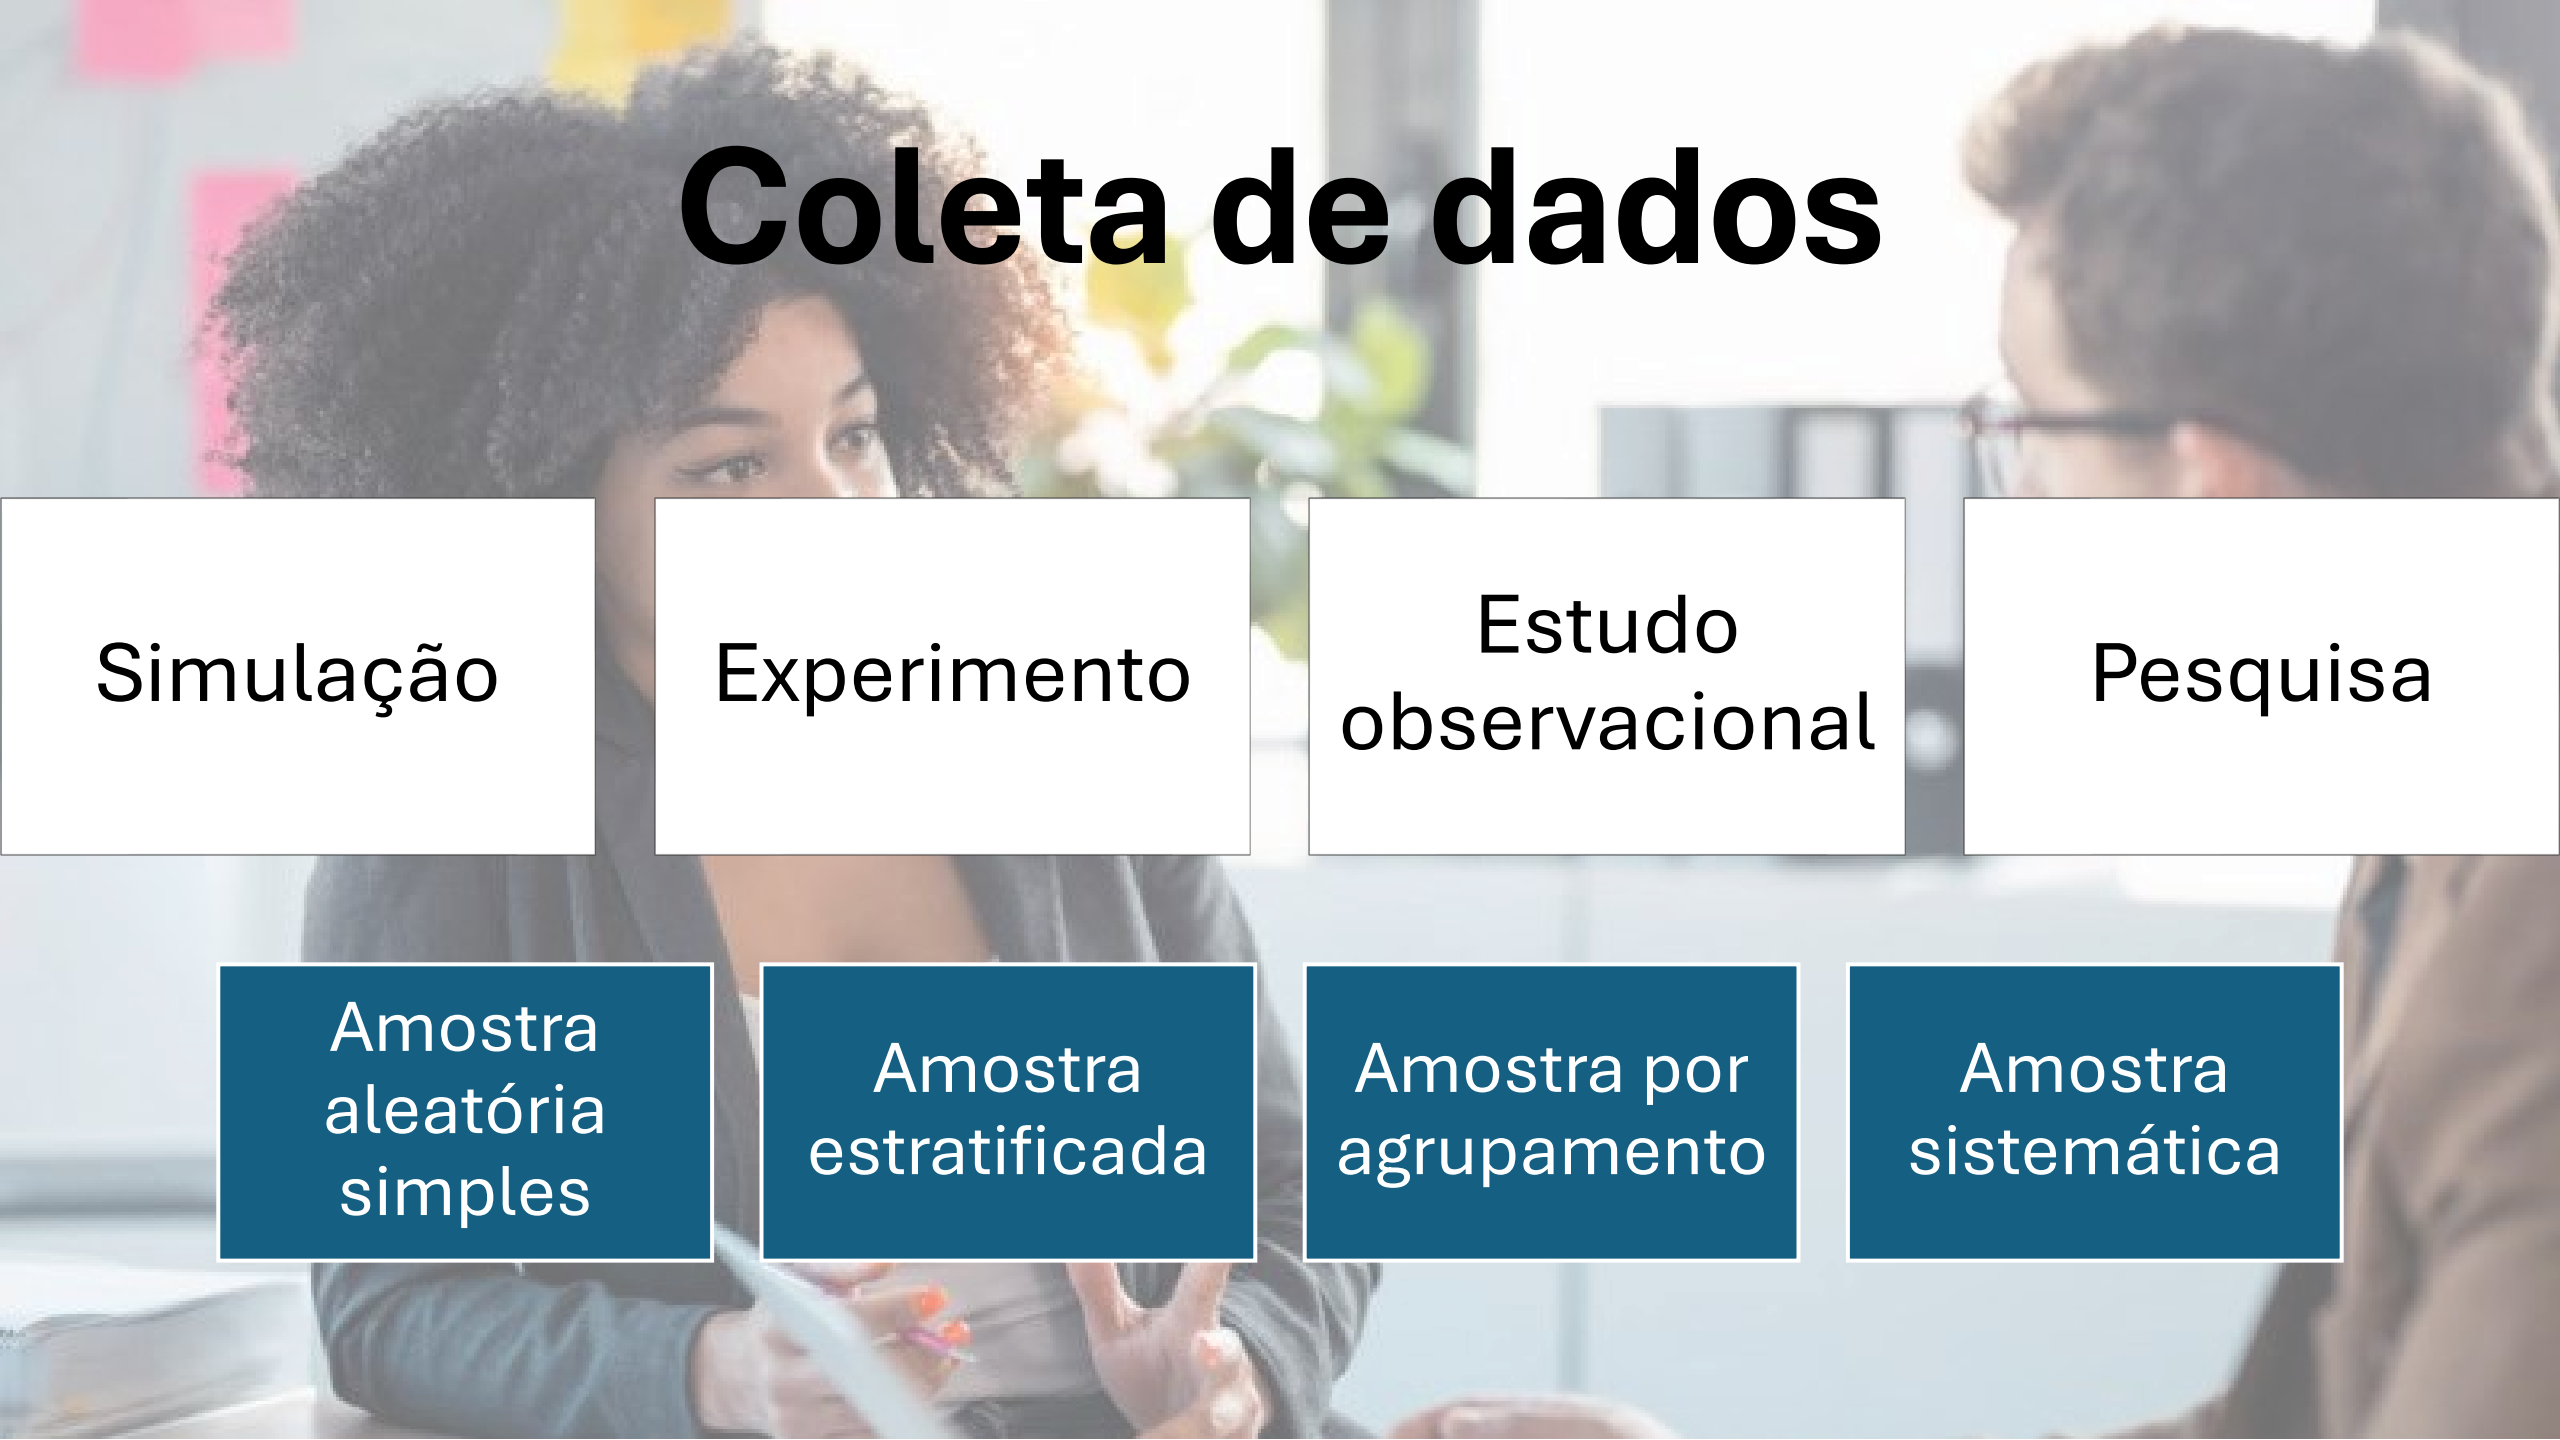
- Entender padrões e tendências.
- Detectar outliers e erros.
- Formular hipóteses.
- Preparar dados para modelagem.

Planejamento





População x Amostra
Parâmetro x Estatística



Coleta de dados

Simulação	Experimento	Estudo observacional	Pesquisa
Amostra aleatória simples	Amostra estratificada	Amostra por agrupamento	Amostra sistemática

Alguns erros comuns

- **Viés de Seleção**

Ocorre quando certos grupos da população têm maior ou menor chance de serem incluídos na amostra.

Resultados não representam a população, mesmo com amostra grande.

- **Amostragem Conveniente (ou de Conveniência)**

Escolher elementos que são mais fáceis de acessar, e não aleatoriamente.

O grupo escolhido pode não refletir as características da população-alvo.

Alguns erros comuns

- **Subcobertura**

Quando uma parte da população não tem chance de ser selecionada.

- **Supercobertura (ou Duplicidade)**

Alguns elementos podem ser incluídos mais de uma vez na amostra.

- **Não-resposta**

Indivíduos selecionados para a amostra não respondem ou se recusam a participar.

Se quem não responde for diferente dos que respondem, há viés.

Alguns erros comuns

- **Viés de Auto-seleção**

Pessoas se oferecem para participar (voluntariado).

Resultados tendem a exagerar opiniões ou comportamentos de grupos engajados.

- **Erro Acidental/Humano**

Erros durante a coleta ou registro dos dados.

- **Erro de Cobertura**

Quando a definição da população está incorreta ou incompleta.

Anota aí:
Dicas para Evitar Erros de Amostragem

- Sempre definir claramente a população-alvo.
- Utilizar métodos de amostragem probabilística (aleatória simples, estratificada, sistemática, etc.).
- Garantir cobertura ampla e acessibilidade para todos os grupos relevantes.
- Fazer análise de não-resposta e ajustar os resultados se necessário.
- Documentar cuidadosamente como foi feita a coleta dos dados.



Reamostragem e Bootstrap

Reamostragem: técnica onde criamos novas amostras a partir da amostra original (com reposição).

Bootstrap: método computacional de reamostragem para estimar a variabilidade de uma estatística quando fórmulas exatas são complicadas ou desconhecidas.

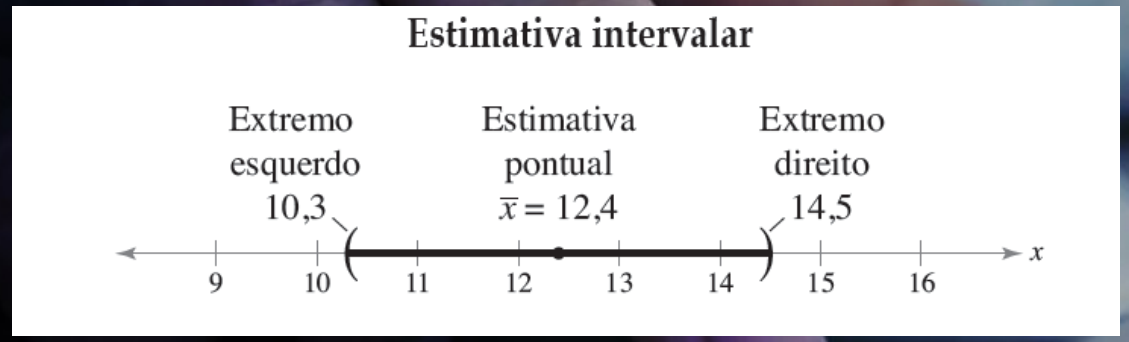
Estimativa pontual

- Um valor único estimado para um parâmetro populacional
- A estimativa pontual menos tendenciosa de uma média populacional μ é a média amostral $\overline{x}$.

Parâmetro de estimativa populacional	**Com amostra estatística**
Média: μ	$\overline{x}$

Estimativa intervalar

- Um intervalo, ou amplitude de valores, usado para estimar um parâmetro populacional.





Erro Padrão

- O erro padrão mede a variação da média amostral em relação à média populacional.

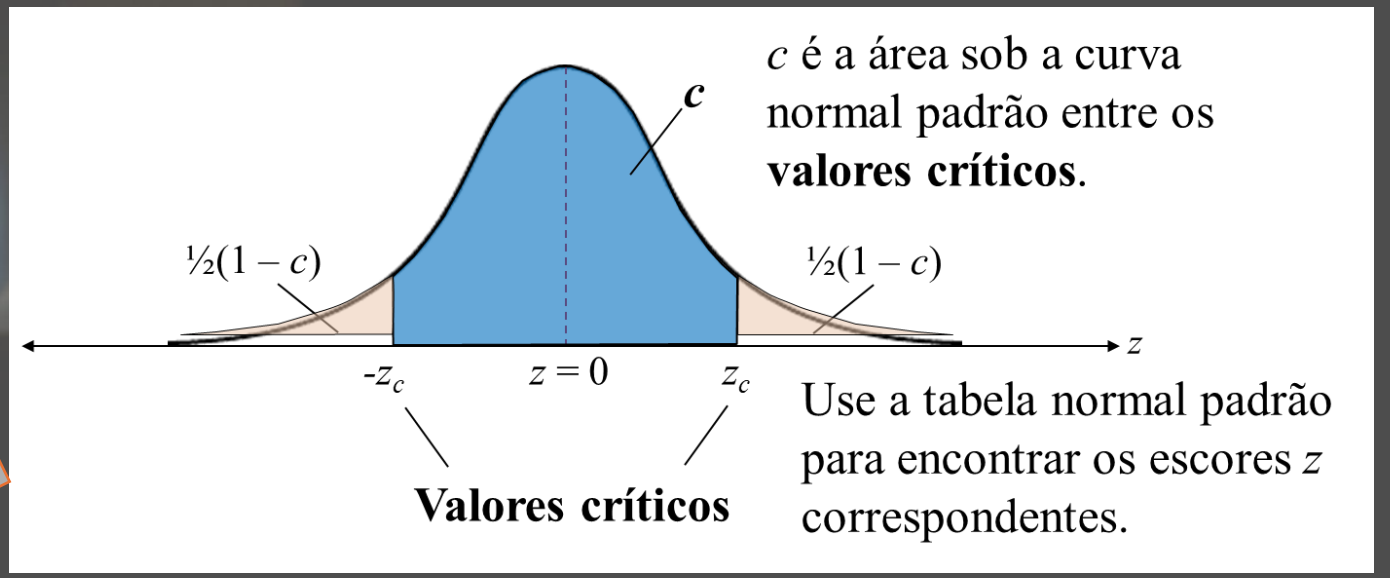
$$erro = \frac{\sigma}{\sqrt{n}}$$

Distribuições de Probabilidade

- Uma distribuição de probabilidade descreve como os valores de uma variável aleatória estão distribuídos – ou seja, qual a chance de observar cada valor possível.
- Por que é importante? Ajuda a modelar fenômenos reais, estimar riscos, fazer previsões e calcular probabilidades.

Nível de confiança c

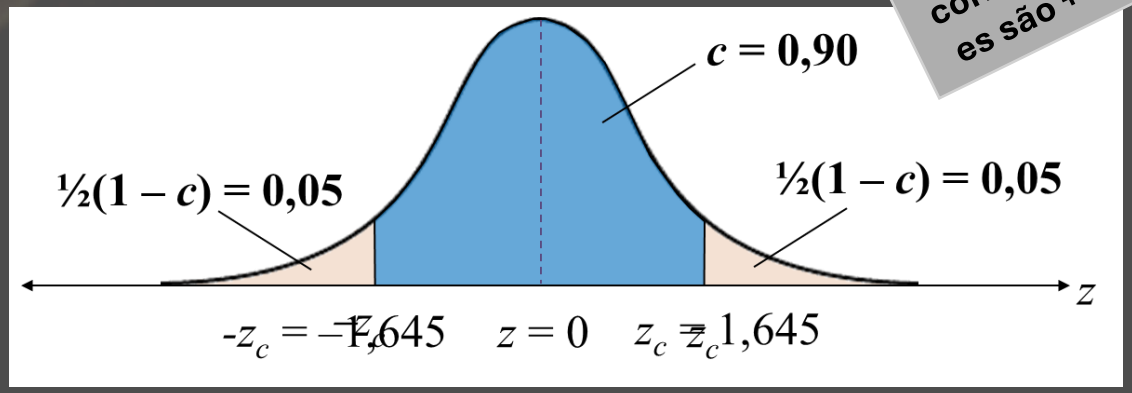
- A probabilidade de que o intervalo estimado contenha o parâmetro populacional.



A área restante nas caudas é 1 – c .

Nível de confiança c

- Se o nível de confiança é 90%, isso significa que temos 90% de certeza que o intervalo contém a média populacional μ





Erro de amostragem

- Diferença entre a estimativa pontual e o valor do parâmetro populacional real

Para μ:

- O erro de amostragem é a diferença x_m – μ
- μ geralmente é desconhecido
- x_m varia de amostra para amostra

Margem de erro

- Maior distância possível entre o ponto de estimativa e o valor do parâmetro que está estimando para um dado nível de confiança, c.
- Às vezes chamado de erro máximo ou tolerância de erro.
- Denotado por E:

$$E = z_c \sigma_x = z_c \frac{\sigma}{\sqrt{n}}$$

Quando $n \geq 30$, o desvio padrão da amostra, s, pode ser usado para σ.



Intervalos de confiança

Para a média populacional

- Um intervalo de confiança c para a média populacional μ é:
- $\overline{x} - E < \mu < \overline{x} + E$
- A probabilidade de que o intervalo de confiança contenha μ é c.
- $E = z_c \frac{\sigma}{\sqrt{n}}$

Construindo intervalos de confiança para μ

Ordem	Descrição	Ação
1	Encontre a estatística amostral n e $\overline{x}$.	$\overline{x} = \frac{\sum x}{n}$
2	Especifique σ, se for conhecido. Caso contrário, encontre o desvio padrão amostral s e use-o como uma estimativa para σ.	$s = \sqrt{\frac{\sum(x - \overline{x})^2}{n - 1}}$
3	Encontre o valor crítico z_c que corresponda ao nível de confiança dado.	Use a tabela normal padrão.
4	Encontre a margem de erro E.	$E = z_c \frac{\sigma}{\sqrt{n}}$
5	Encontre os extremos esquerdo e direito e forme o intervalo de confiança.	$\overline{x} - E < \mu < \overline{x} + E$

Construindo intervalos de confiança para μ

Tabela - Normal Padrão de 0 a z



$P(0 \leq Z \leq z)$

z	Segunda casa decimal de z									
Parte inteira e primeira casa decimal de Z	0	1	2	3	4	5	6	7	8	9
0,0	0,0000	0,0040	0,0080	0,0120	0,0160	0,0199	0,0239	0,0279	0,0319	0,0359
0,1	0,0398	0,0438	0,0478	0,0517	0,0557	0,0596	0,0636	0,0675	0,0714	0,0753
0,2	0,0793	0,0832	0,0871	0,0910	0,0948	0,0987	0,1026	0,1064	0,1103	0,1141
0,3	0,1179	0,1217	0,1255	0,1293	0,1331	0,1368	0,1406	0,1443	0,1480	0,1517
0,4	0,1554	0,1591	0,1628	0,1664	0,1700	0,1736	0,1772	0,1808	0,1844	0,1879
0,5	0,1915	0,1950	0,1985	0,2019	0,2054	0,2088	0,2123	0,2157	0,2190	0,2224
0,6	0,2257	0,2291	0,2324	0,2357	0,2389	0,2422	0,2454	0,2486	0,2517	0,2549
0,7	0,2580	0,2611	0,2642	0,2673	0,2704	0,2734	0,2764	0,2794	0,2823	0,2852
0,8	0,2881	0,2910	0,2939	0,2967	0,2995	0,3023	0,3051	0,3078	0,3106	0,3133
0,9	0,3159	0,3186	0,3212	0,3238	0,3264	0,3289	0,3315	0,3340	0,3365	0,3389
1,0	0,3413	0,3438	0,3461	0,3485	0,3508	0,3531	0,3554	0,3577	0,3599	0,3621
1,1	0,3643	0,3665	0,3686	0,3708	0,3729	0,3749	0,3770	0,3790	0,3810	0,3830
1,2	0,3849	0,3869	0,3888	0,3907	0,3925	0,3944	0,3962	0,3980	0,3997	0,4015
1,3	0,4032	0,4049	0,4066	0,4082	0,4099	0,4115	0,4131	0,4147	0,4162	0,4177
1,4	0,4192	0,4207	0,4222	0,4236	0,4251	0,4265	0,4279	0,4292	0,4306	0,4319
1,5	0,4332	0,4345	0,4357	0,4370	0,4382	0,4394	0,4406	0,4418	0,4429	0,4441
1,6	0,4452	0,4463	0,4474	0,4484	0,4495	0,4505	0,4515	0,4525	0,4535	0,4545
1,7	0,4554	0,4564	0,4573	0,4582	0,4591	0,4599	0,4608	0,4616	0,4625	0,4633
1,8	0,4641	0,4649	0,4656	0,4664	0,4671	0,4678	0,4686	0,4693	0,4699	0,4706
1,9	0,4713	0,4719	0,4726	0,4732	0,4738	0,4744	0,4750	0,4756	0,4761	0,4767
2,0	0,4772	0,4778	0,4783	0,4788	0,4793	0,4798	0,4803	0,4808	0,4812	0,4817
2,1	0,4821	0,4826	0,4830	0,4834	0,4838	0,4842	0,4846	0,4850	0,4854	0,4857
2,2	0,4861	0,4864	0,4868	0,4871	0,4875	0,4878	0,4881	0,4884	0,4887	0,4890
2,3	0,4893	0,4896	0,4898	0,4901	0,4904	0,4906	0,4909	0,4911	0,4913	0,4916
2,4	0,4918	0,4920	0,4922	0,4925	0,4927	0,4929	0,4931	0,4932	0,4934	0,4936
2,5	0,4938	0,4940	0,4941	0,4943	0,4945	0,4946	0,4948	0,4949	0,4951	0,4952
2,6	0,4953	0,4955	0,4956	0,4957	0,4959	0,4960	0,4961	0,4962	0,4963	0,4964
2,7	0,4965	0,4966	0,4967	0,4968	0,4969	0,4970	0,4971	0,4972	0,4973	0,4974
2,8	0,4974	0,4975	0,4976	0,4977	0,4977	0,4978	0,4979	0,4979	0,4980	0,4981
2,9	0,4981	0,4982	0,4982	0,4983	0,4984	0,4984	0,4985	0,4985	0,4986	0,4986
3,0	0,4987	0,4987	0,4987	0,4988	0,4988	0,4989	0,4989	0,4989	0,4990	0,4990
3,1	0,4990	0,4991	0,4991	0,4991	0,4992	0,4992	0,4992	0,4992	0,4993	0,4993
3,2	0,4993	0,4993	0,4994	0,4994	0,4994	0,4994	0,4994	0,4995	0,4995	0,4995
3,3	0,4995	0,4995	0,4995	0,4996	0,4996	0,4996	0,4996	0,4996	0,4996	0,4997
3,4	0,4997	0,4997	0,4997	0,4997	0,4997	0,4997	0,4997	0,4997	0,4997	0,4998
3,5	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998
3,6	0,4998	0,4998	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999
3,7	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999
3,8	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999
3,9	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000
4,0	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000

Interpretando os resultados

- μ é um número fixo. Ou é um intervalo de confiança ou não.
- Incorreto: “Existe uma probabilidade de 90% que a média real esteja no intervalo (22,3, 23,5).”
- Correto: “Se um número grande de amostras é coletado e um intervalo de confiança é criado para cada uma, aproximadamente 90% desses intervalos conterão μ.

Tamanho da amostra

- Dado um nível de confiança c e uma margem de erro E, o tamanho amostral mínimo n necessário para estimar a média populacional μ é:

$$n = \left(z_c \frac{\sigma}{E}\right)^2$$

- Se σ é desconhecido, você pode estimar seu valor usando s, caso tenha uma amostra preliminar de pelo menos 30 membros.

Distribuição T

- Quando o desvio padrão da população é desconhecido, o tamanho da amostra é menor que 30, e a variável x é normalmente distribuída; ela segue uma **distribuição t:**

$$t = \frac{\overline{x} - \mu}{\frac{s}{\sqrt{n}}}$$

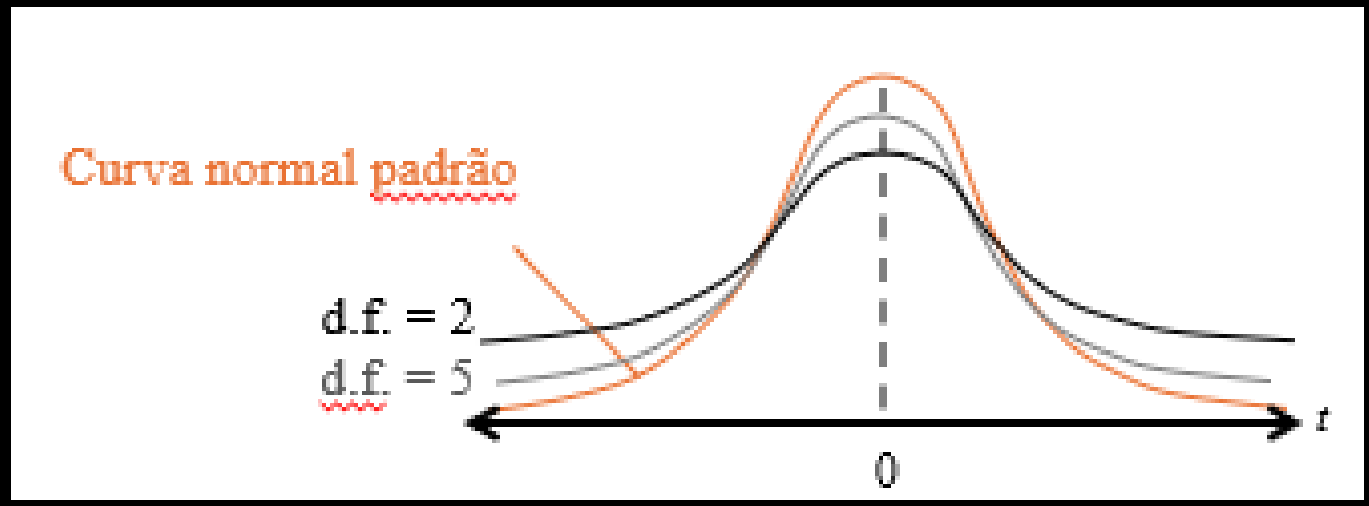
- Valores críticos de t são denotados por t_c

Distribuição T

1. A distribuição t tem formato de sino e é simétrica em relação à média.
    - A distribuição t é uma família de curvas, cada uma determinada por um parâmetro chamado de graus de liberdade.
        - Os graus de liberdade são o número de escolhas livres deixadas depois que uma amostra estatística, como $\overline{x}$, é calculada.
        - Quando usamos a distribuição t para estimar a média da população, os graus de liberdade são iguais ao tamanho da amostra menos um.
            - g.l. = n – 1 Graus de liberdade

Propriedades da distribuição T

- A área total sob a curva t é 1 ou 100%.
- A média, a mediana e a moda da distribuição t são iguais a zero.
- Conforme os graus de liberdade aumentam, a distribuição t aproxima-se da distribuição normal. Depois de 30 g.l., a distribuição t está muito próxima da distribuição normal padrão z. A amostra é 15.



As caudas na distribuição *t* são "mais grossas" que aquelas da distribuição normal padrão.

Propriedades da distribuição T

Para a média populacional

$$\overline{x} - E < \mu < \overline{x} + E$$

Onde $E = t_c \frac{s}{\sqrt{n}}$.

A probabilidade de que o intervalo de confiança contenha μ é c.

Intervalos de confiança e a distribuição t

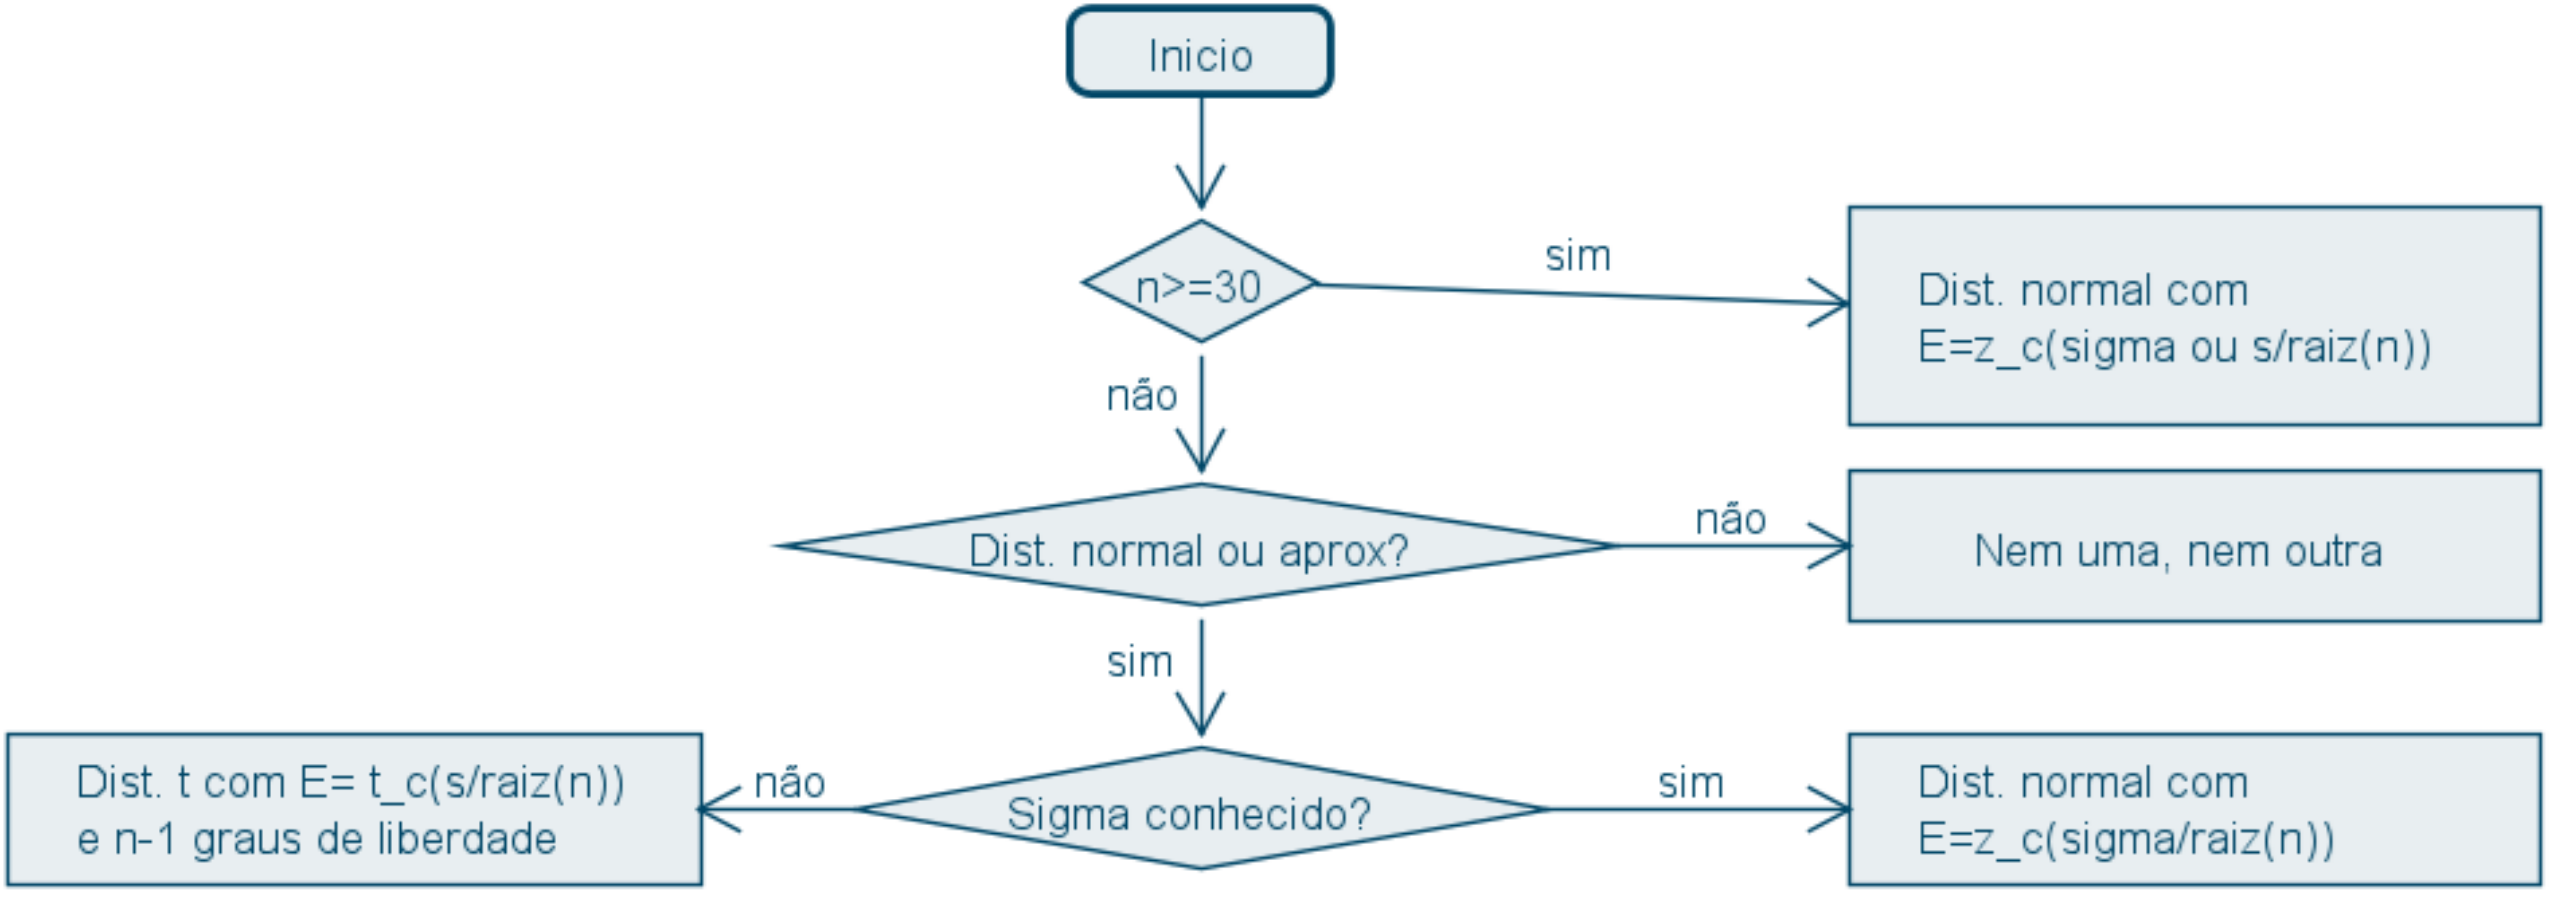
Ordem	Descrição	Ação
1	Identifique as amostras estatísticas n, $\overline{x}$ e s.	$\overline{x} = \frac{\sum x}{n} \therefore s = \sqrt{\frac{\sum (x-\overline{x})^2}{n-1}}$
2	Identifique os graus de liberdade, o nível de confiança c e o valor crítico t_c.	$g.l. = n - 1$
3	Encontre a margem de erro E.	$E = t_c \frac{s}{\sqrt{n}}$
5	Encontre os extremos esquerdo e direito e forme o intervalo de confiança.	$\overline{x} - E < \mu < \overline{x} + E$

Tabela T

Distribuição t-Student: valores **tc** tais que P(-**tc** ≤ t ≤ **tc**) = 1 - p

Graus de Liberdade	p ►	90%	80%	70%	60%	50%	40%	30%	20%	10%	8%	6%	5%	4%	2%	1%	0,2%	0,1
	1	0,158	0,325	0,510	0,727	1,000	1,376	1,963	3,078	6,314	7,916	10,579	12,706	15,895	31,821	63,657	318,309	636,6
	2	0,142	0,289	0,445	0,617	0,816	1,061	1,386	1,886	2,920	3,320	3,896	4,303	4,849	6,965	9,925	22,327	31,5
	3	0,137	0,277	0,424	0,584	0,765	0,978	1,250	1,638	2,353	2,605	2,951	3,182	3,482	4,541	5,841	10,215	12,9
	4	0,134	0,271	0,414	0,569	0,741	0,941	1,190	1,533	2,132	2,333	2,601	2,776	2,999	3,747	4,604	7,173	8,6
	5	0,132	0,267	0,408	0,559	0,727	0,920	1,156	1,476	2,015	2,191	2,422	2,571	2,757	3,365	4,032	5,893	6,86
	6	0,131	0,265	0,404	0,553	0,718	0,906	1,134	1,440	1,943	2,104	2,313	2,447	2,612	3,143	3,707	5,208	5,95
	7	0,130	0,263	0,402	0,549	0,711	0,896	1,119	1,415	1,895	2,046	2,241	2,365	2,517	2,998	3,499	4,785	5,40
	8	0,130	0,262	0,399	0,546	0,706	0,889	1,108	1,397	1,860	2,004	2,189	2,306	2,449	2,896	3,355	4,501	5,04
	9	0,129	0,261	0,398	0,543	0,703	0,883	1,100	1,383	1,833	1,973	2,150	2,262	2,398	2,821	3,250	4,297	4,78
	10	0,129	0,260	0,397	0,542	0,700	0,879	1,093	1,372	1,812	1,948	2,120	2,228	2,359	2,764	3,169	4,144	4,58
	11	0,129	0,260	0,396	0,540	0,697	0,876	1,088	1,363	1,796	1,928	2,096	2,201	2,328	2,718	3,106	4,025	4,43
	12	0,128	0,259	0,395	0,539	0,695	0,873	1,083	1,356	1,782	1,912	2,076	2,179	2,303	2,681	3,055	3,930	4,31
	13	0,128	0,259	0,394	0,538	0,694	0,870	1,079	1,350	1,771	1,899	2,060	2,160	2,282	2,650	3,012	3,852	4,22
	14	0,128	0,258	0,393	0,537	0,692	0,868	1,076	1,345	1,761	1,887	2,046	2,145	2,264	2,624	2,977	3,787	4,14
	15	0,128	0,258	0,393	0,536	0,691	0,866	1,074	1,341	1,753	1,878	2,034	2,131	2,249	2,602	2,947	3,733	4,07
	16	0,128	0,258	0,392	0,535	0,690	0,865	1,071	1,337	1,746	1,869	2,024	2,120	2,235	2,583	2,921	3,686	4,01
	17	0,128	0,257	0,392	0,534	0,689	0,863	1,069	1,333	1,740	1,862	2,015	2,110	2,224	2,567	2,898	3,646	3,96
	18	0,127	0,257	0,392	0,534	0,688	0,862	1,067	1,330	1,734	1,855	2,007	2,101	2,214	2,552	2,878	3,610	3,92
	19	0,127	0,257	0,391	0,533	0,688	0,861	1,066	1,328	1,729	1,850	2,000	2,093	2,205	2,539	2,861	3,579	3,88
	20	0,127	0,257	0,391	0,533	0,687	0,860	1,064	1,325	1,725	1,844	1,994	2,086	2,197	2,528	2,845	3,552	3,85
	21	0,127	0,257	0,391	0,532	0,686	0,859	1,063	1,323	1,721	1,840	1,988	2,080	2,189	2,518	2,831	3,527	3,81
	22	0,127	0,256	0,390	0,532	0,686	0,858	1,061	1,321	1,717	1,835	1,983	2,074	2,183	2,508	2,819	3,505	3,79
	23	0,127	0,256	0,390	0,532	0,685	0,858	1,060	1,319	1,714	1,832	1,978	2,069	2,177	2,500	2,807	3,485	3,76
	24	0,127	0,256	0,390	0,531	0,685	0,857	1,059	1,318	1,711	1,828	1,974	2,064	2,172	2,492	2,797	3,467	3,74
	25	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,316	1,708	1,825	1,970	2,060	2,167	2,485	2,787	3,450	3,72
	26	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,315	1,706	1,822	1,967	2,056	2,162	2,479	2,779	3,435	3,70
	27	0,127	0,256	0,389	0,531	0,684	0,855	1,057	1,314	1,703	1,819	1,963	2,052	2,158	2,473	2,771	3,421	3,69
	28	0,127	0,256	0,389	0,530	0,683	0,855	1,056	1,313	1,701	1,817	1,960	2,048	2,154	2,467	2,763	3,408	3,67
	29	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,311	1,699	1,814	1,957	2,045	2,150	2,462	2,756	3,396	3,65
	30	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,310	1,697	1,812	1,955	2,042	2,147	2,457	2,750	3,385	3,64
	31	0,127	0,256	0,389	0,530	0,682	0,853	1,054	1,309	1,696	1,810	1,952	2,040	2,144	2,453	2,744	3,375	3,63
	32	0,127	0,255	0,389	0,530	0,682	0,853	1,054	1,309	1,694	1,808	1,950	2,037	2,141	2,449	2,738	3,365	3,62
	33	0,127	0,255	0,389	0,530	0,682	0,853	1,053	1,308	1,692	1,806	1,948	2,035	2,138	2,445	2,733	3,356	3,61
	34	0,127	0,255	0,389	0,529	0,682	0,852	1,052	1,307	1,691	1,805	1,946	2,032	2,136	2,441	2,728	3,348	3,60
	35	0,127	0,255	0,388	0,529	0,682	0,852	1,052	1,306	1,690	1,803	1,944	2,030	2,133	2,438	2,724	3,340	3,59
	36	0,127	0,255	0,388	0,529	0,681	0,852	1,052	1,306	1,688	1,802	1,942	2,028	2,131	2,434	2,719	3,333	3,58
	37	0,127	0,255	0,388	0,529	0,681	0,851	1,051	1,305	1,687	1,800	1,940	2,026	2,129	2,431	2,715	3,326	3,57
	38	0,127	0,255	0,388	0,529	0,681	0,851	1,051	1,304	1,686	1,799	1,939	2,024	2,127	2,429	2,712	3,319	3,56
	39	0,126	0,255	0,388	0,529	0,681	0,851	1,050	1,304	1,685	1,798	1,937	2,023	2,125	2,426	2,708	3,313	3,55
	40	0,126	0,255	0,388	0,529	0,681	0,851	1,050	1,303	1,684	1,796	1,936	2,021	2,123	2,423	2,704	3,307	3,55
	45	0,126	0,255	0,388	0,528	0,680	0,850	1,049	1,301	1,679	1,791	1,929	2,014	2,115	2,412	2,690	3,281	3,52
	50	0,126	0,255	0,388	0,528	0,679	0,849	1,047	1,299	1,676	1,787	1,924	2,009	2,109	2,403	2,678	3,261	3,49
	55	0,126	0,255	0,387	0,527	0,679	0,848	1,046	1,297	1,673	1,784	1,920	2,004	2,104	2,396	2,668	3,245	3,47
	60	0,126	0,254	0,387	0,527	0,679	0,848	1,045	1,296	1,671	1,781	1,917	2,000	2,099	2,390	2,660	3,232	3,46
	70	0,126	0,254	0,387	0,527	0,678	0,847	1,044	1,294	1,667	1,776	1,912	1,994	2,093	2,381	2,648	3,211	3,43
	80	0,126	0,254	0,387	0,526	0,678	0,846	1,043	1,292	1,664	1,773	1,908	1,990	2,088	2,374	2,639	3,195	3,41
	90	0,126	0,254	0,387	0,526	0,677	0,846	1,042	1,291	1,662	1,771	1,905	1,987	2,084	2,368	2,632	3,183	3,40
	100	0,126	0,254	0,386	0,526	0,677	0,845	1,042	1,290	1,660	1,769	1,902	1,984	2,081	2,364	2,626	3,174	3,39
	110	0,126	0,254	0,386	0,526	0,677	0,845	1,041	1,289	1,659	1,767	1,900	1,982	2,078	2,361	2,621	3,166	3,38
	120	0,126	0,254	0,386	0,526	0,677	0,845	1,041	1,289	1,658	1,766	1,899	1,980	2,076	2,358	2,617	3,160	3,37
	∞	0,126	0,253	0,385	0,524	0,674	0,842	1,036	1,282	1,645	1,751	1,881	1,960	2,054	2,326	2,576	3,090	3,29

Usar curva normal ou distribuição T?



Para proporções populacionais

- **Proporção populacional**
- Probabilidade de sucesso em uma única tentativa de um experimento binomial e é denotado por p
- **Estimativa pontual para p**
- A proporção de sucessos em uma amostra é dado por: $\hat{p} = \frac{x}{n}$. Onde x é o número de sucessos e n, o número de exemplos.
  - Leia como “p chapéu”

Para proporções populacionais

- **Proporção populacional**
- Probabilidade de sucesso em uma única tentativa de um experimento binomial e é denotado por p
- **Estimativa pontual para p (sucesso)**
- A proporção de sucessos em uma amostra é dado por: $\hat{p} = \frac{x}{n}$. Onde x é o número de sucessos e n, o número de exemplos.
  - Leia como “p chapéu”

Parâmetro populacional estimado	**Com amostra estatística**
Proporção: p	$\hat{p}$

Proporção de falhas ($\hat{q}$)
$\hat{q} = 1 - \hat{p}$

Para proporções populacionais

- $\hat{p} - E < p < \hat{p} + E$
- Onde $E = z_c \sqrt{\frac{\hat{p}\hat{q}}{n}}$.
- A probabilidade de que o intervalo de confiança contenha p é c.

Construindo intervalos de confiança para p

Ordem	Descrição	Ação
1	Encontre a estatística amostral n e x.	
2	Encontre a estimativa pontual $\hat{p}$.	$\hat{p} = \frac{x}{n}$
3	Verifique se a distribuição amostral de $\hat{p}$ pode ser aproximada por distribuição normal.	$n\hat{p} \geq 5, n\hat{q} \geq 5$
4	Encontre o valor crítico z_c que corresponda ao dado nível de confiança c.	Use a tabela normal padrão
5	Encontre a margem de erro E.	$E = z_c \sqrt{\frac{\hat{p}\hat{q}}{n}}$
6	Encontre os extremos esquerdo e direito e forme o intervalo de confiança.	$\hat{p} - E < p < \hat{p} + E$

Tamanho da amostra

- Dado um nível de confiança c e uma margem de erro E, o tamanho mínimo da amostra n necessário para estimar p é:
- $n = \hat{p}\hat{q}\left(\frac{z_c}{E}\right)^2$
- Essa fórmula assume que você tem uma estimativa para $\hat{p}$ e $\hat{q}$
- Se não, use $\hat{p} = 0{,}5$ e $\hat{q} = 0{,}5$.

Para variância e desvio padrão

- **A distribuição qui-quadrado**
  - A **estimativa pontual** para σ^2 é s^2.
  - A **estimativa pontual** para σ é s.
  - s^2 é a estimativa menos tendenciosa para σ^2.
- Pode-se usar uma **distribuição qui-quadrado** para construir um intervalo de confiança para a variância e desvio padrão.

Distribuição qui-quadrado

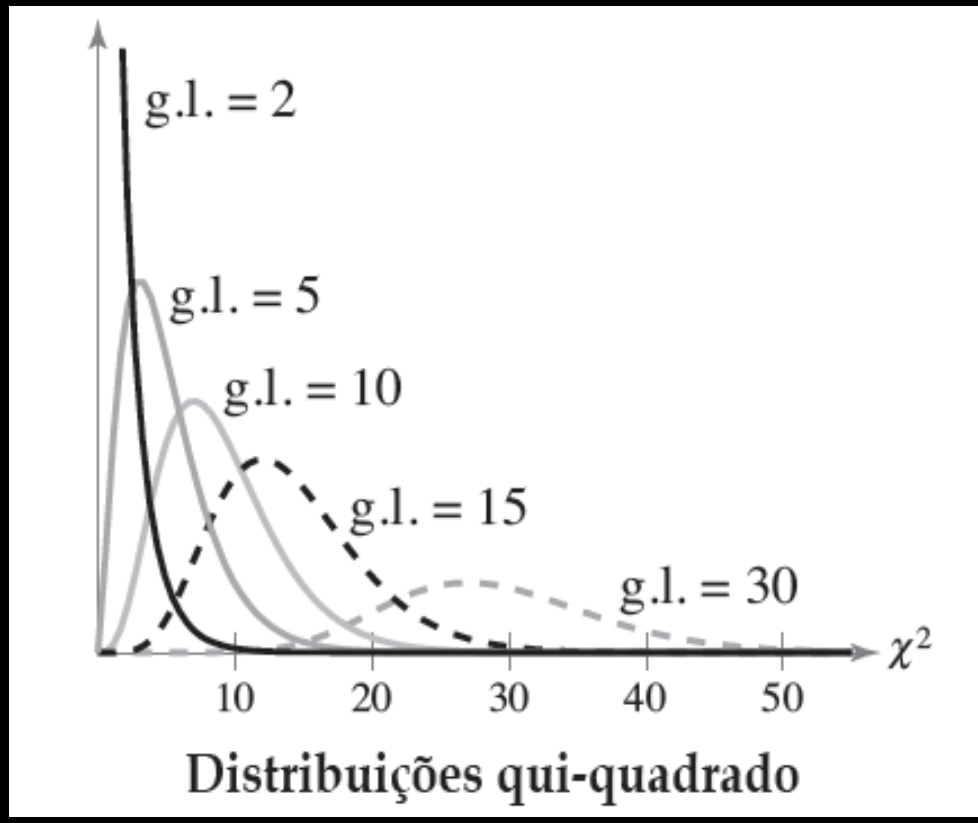
- Se a variável aleatória x tem distribuição normal, então a distribuição de:

$$\chi^2 = \frac{(n-1)s^2}{\sigma^2}$$

  - Forma uma **distribuição qui-quadrado** para amostras de qualquer tamanho n > 1

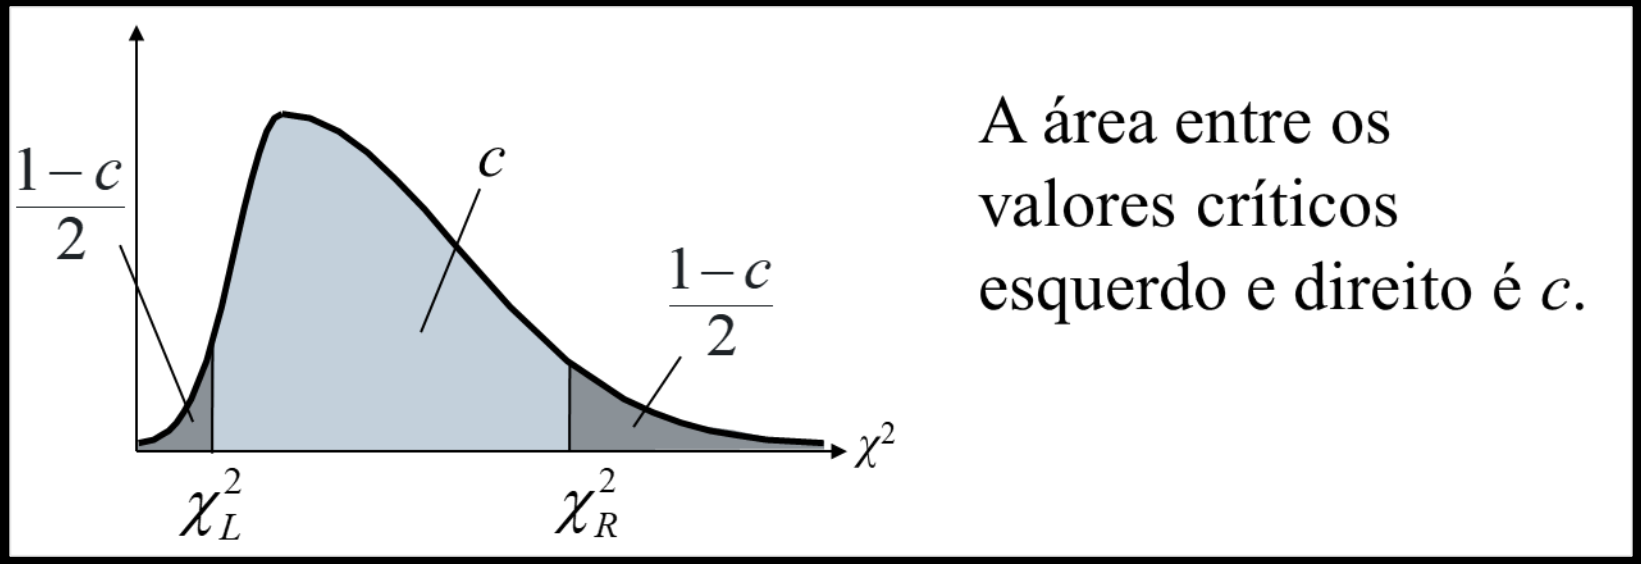
Distribuição qui-quadrado (propriedades)

- Todos valores qui-quadrado χ^2 são maiores ou iguais a zero.
- A distribuição qui-quadrado é uma família de curvas, cada uma determinada pelos graus de liberdade.
  - Para formar um intervalo de confiança para σ^2, use a distribuição x^2 com graus de liberdade iguais a um a menos do que o tamanho da amostra.
  - g.l. = n – 1 Graus de liberdade
- A área abaixo da curva da distribuição qui-quadrado é igual a um.
- As distribuições qui-quadrado são assimétricas positivas.



Valores críticos de χ^2

- Há dois valores críticos para cada nível de confiança.
- O valor χ^2_R representa o valor crítico da cauda direita
- O valor χ^2_L representa o valor crítico da cauda esquerda.



Intervalos de confiança para σ^2 e σ

σ^2	$\frac{(n-1)s^2}{\chi_R^2} < \sigma^2 < \frac{(n-1)s^2}{\chi_L^2}$
σ	$\sqrt{\frac{(n-1)s^2}{\chi_R^2}} < \sigma < \sqrt{\frac{(n-1)s^2}{\chi_L^2}}$

A probabilidade de que o intervalo de confiança contenha σ2 ou σ é c.

Intervalos de confiança

Ordem	Descrição	Ação
1	Verifique se a população tem uma distribuição normal.	
2	Identifique a amostra estatística n e os graus de liberdade.	$g.l. = n - 1$
3	Encontre a estimativa pontual s^2.	$s^2 = \frac{\sum(x - \overline{x})^2}{n - 1}$
4	1.Encontre o valor crítico χ^2_R e χ^2_L que corresponda ao dado nível de confiança c.	Use a tabela
5	Encontre os extremo esquerdo e direito e forme o intervalo de confiança para a variância populacional.	$\frac{(n-1)s^2}{\chi^2_R} < \sigma^2 < \frac{(n-1)s^2}{\chi^2_L}$
6	Encontre o intervalo de confiança para o desvio padrão da população tomando a raiz quadrada de cada extremo.	$\sqrt{\frac{(n-1)s^2}{\chi^2_R}} < \sigma < \sqrt{\frac{(n-1)s^2}{\chi^2_L}}$

Tabela χ^2

Distribuição Qui-Quadrado - Unicaudal à Direita										
Graus de Liberdade	p ►	99,5%	99%	97,5%	95%	90%	10%	5%	2,5%	1%	0,5%
	1	0,000	0,000	0,001	0,004	0,016	2,706	3,841	5,024	6,635	7,879
	2	0,010	0,020	0,051	0,103	0,211	4,605	5,991	7,378	9,210	10,597
	3	0,072	0,115	0,216	0,352	0,584	6,251	7,815	9,348	11,345	12,838
	4	0,207	0,297	0,484	0,711	1,064	7,779	9,488	11,143	13,277	14,860
	5	0,412	0,554	0,831	1,145	1,610	9,236	11,070	12,833	15,086	16,750
	6	0,676	0,872	1,237	1,635	2,204	10,645	12,592	14,449	16,812	18,548
	7	0,989	1,239	1,690	2,167	2,833	12,017	14,067	16,013	18,475	20,278
	8	1,344	1,646	2,180	2,733	3,490	13,362	15,507	17,535	20,090	21,955
	9	1,735	2,088	2,700	3,325	4,168	14,684	16,919	19,023	21,666	23,589
	10	2,156	2,558	3,247	3,940	4,865	15,987	18,307	20,483	23,209	25,188
	11	2,603	3,053	3,816	4,575	5,578	17,275	19,675	21,920	24,725	26,757
	12	3,074	3,571	4,404	5,226	6,304	18,549	21,026	23,337	26,217	28,300
	13	3,565	4,107	5,009	5,892	7,042	19,812	22,362	24,736	27,688	29,819
	14	4,075	4,660	5,629	6,571	7,790	21,064	23,685	26,119	29,141	31,319
	15	4,601	5,229	6,262	7,261	8,547	22,307	24,996	27,488	30,578	32,801
	16	5,142	5,812	6,908	7,962	9,312	23,542	26,296	28,845	32,000	34,267
	17	5,697	6,408	7,564	8,672	10,085	24,769	27,587	30,191	33,409	35,718
	18	6,265	7,015	8,231	9,390	10,865	25,989	28,869	31,526	34,805	37,156
	19	6,844	7,633	8,907	10,117	11,651	27,204	30,144	32,852	36,191	38,582
	20	7,434	8,260	9,591	10,851	12,443	28,412	31,410	34,170	37,566	39,997
	21	8,034	8,897	10,283	11,591	13,240	29,615	32,671	35,479	38,932	41,401
	22	8,643	9,542	10,982	12,338	14,041	30,813	33,924	36,781	40,289	42,796
	23	9,260	10,196	11,689	13,091	14,848	32,007	35,172	38,076	41,638	44,181
	24	9,886	10,856	12,401	13,848	15,659	33,196	36,415	39,364	42,980	45,559
	25	10,520	11,524	13,120	14,611	16,473	34,382	37,652	40,646	44,314	46,928
	26	11,160	12,198	13,844	15,379	17,292	35,563	38,885	41,923	45,642	48,290
	27	11,808	12,879	14,573	16,151	18,114	36,741	40,113	43,195	46,963	49,645
	28	12,461	13,565	15,308	16,928	18,939	37,916	41,337	44,461	48,278	50,993
	29	13,121	14,256	16,047	17,708	19,768	39,087	42,557	45,722	49,588	52,336
	30	13,787	14,953	16,791	18,493	20,599	40,256	43,773	46,979	50,892	53,672
	31	14,458	15,655	17,539	19,281	21,434	41,422	44,985	48,232	52,191	55,003
	32	15,134	16,362	18,291	20,072	22,271	42,585	46,194	49,480	53,486	56,328
	33	15,815	17,074	19,047	20,867	23,110	43,745	47,400	50,725	54,776	57,648
	34	16,501	17,789	19,806	21,664	23,952	44,903	48,602	51,966	56,061	58,964
	35	17,192	18,509	20,569	22,465	24,797	46,059	49,802	53,203	57,342	60,275
	36	17,887	19,233	21,336	23,269	25,643	47,212	50,998	54,437	58,619	61,581
	37	18,586	19,960	22,106	24,075	26,492	48,363	52,192	55,668	59,893	62,883
	38	19,289	20,691	22,878	24,884	27,343	49,513	53,384	56,896	61,162	64,181
	39	19,996	21,426	23,654	25,695	28,196	50,660	54,572	58,120	62,428	65,476
	40	20,707	22,164	24,433	26,509	29,051	51,805	55,758	59,342	63,691	66,766
	45	24,311	25,901	28,366	30,612	33,350	57,505	61,656	65,410	69,957	73,166
	50	27,991	29,707	32,357	34,764	37,689	63,167	67,505	71,420	76,154	79,490
	55	31,735	33,570	36,398	38,958	42,060	68,796	73,311	77,380	82,292	85,749
	60	35,534	37,485	40,482	43,188	46,459	74,397	79,082	83,298	88,379	91,952
	70	43,275	45,442	48,758	51,739	55,329	85,527	90,531	95,023	100,425	104,215
	80	51,172	53,540	57,153	60,391	64,278	96,578	101,879	106,629	112,329	116,321
	90	59,196	61,754	65,647	69,126	73,291	107,565	113,145	118,136	124,116	128,299
	100	67,328	70,065	74,222	77,929	82,358	118,498	124,342	129,561	135,807	140,169
	110	75,550	78,458	82,867	86,792	91,471	129,385	135,480	140,917	147,414	151,948
	120	83,852	86,923	91,573	95,705	100,624	140,233	146,567	152,211	158,950	163,648
	130	92,222	95,451	100,331	104,662	109,811	151,045	157,610	163,453	170,423	175,278

Distribuições de probabilidade discreta

- Lista cada possível valor que a variável aleatória possa assumir, juntamente com sua probabilidade
- Precisa satisfazer as seguintes condições:

Em palavras	Simbologia
1. A probabilidade de cada valor da variável discreta aleatória precisa estar entre 0 e 1.	$0 \leq P(x) \leq 1$
2. A soma de todas as probabilidades tem de ser 1.	$\Sigma P(x) = 1$

Distribuições de probabilidade discreta

- Seja x uma variável discreta aleatória com resultados possíveis x1, x2, ... , xn.

Faça uma distribuição de frequências para os resultados possíveis.

Encontre a soma das frequências.

Encontre a probabilidade de cada resultado possível dividindo sua frequência pela soma das frequências.

Certifique-se de que cada probabilidade esteja entre 0 e 1 e que a soma seja 1.

Distribuições de probabilidade discreta

Média

- $\mu = \sum x\, P(x)$

Variância

- $\sigma^2 = \sum (x - \mu)^2\, P(x)$

Desvio Padrão

- $\sqrt{\sigma^2}$

Valor esperado de uma variável aleatória discreta

- Igual à média da variável aleatória
- E(x) = $\mu = \sum x\, P(x)$

Experimentos binomiais

O experimento é repetido para um número fixo de tentativas;

- Cada tentativa é independente das outras.

Há apenas dois resultados possíveis de interesse para cada tentativa.

- Os resultados podem ser classificados como sucesso (S) ou falha (F).

A probabilidade de um sucesso P(S) é a mesma para cada tentativa.

A variável aleatória x conta o número de tentativas bem-sucedidas.

Notações para experimentos binomiais

Símbolo	**Descrição**
n	Número de vezes que uma tentativa é repetida
p = P(s)	Probabilidade de sucesso em uma única tentativa
q = P(F)	Probabilidade de falha em uma única tentativa (q = 1 – p)
x	A variável aleatória representa a contagem do número de sucessos em n tentativas: x = 0, 1, 2, 3, … , n.

Fórmula de probabilidade binomial

- A probabilidade de exatamente x sucessos em n tentativas é:

$$P(x) = C_x^n p^x q^{n-x} = \frac{n!}{(n-x)!\,x!} p^x q^{n-x}$$

- Onde:
- n = número de tentativas
- p = probabilidade de sucesso
- q = 1 – p probabilidade de falha
- x = número de sucessos em n tentativas

Medidas de uma distribuição de probabilidade binomial

Média

- $\mu = \mathrm{n}P(x)$

Variância

- $\sigma^2 = \mathrm{nP(x)q}$

Desvio Padrão

- $\sqrt{\sigma^2}$

Outras distribuições de probabilidade

Geométrica

- Satisfaz as seguintes condições:
  - Uma tentativa é repetida até que um sucesso ocorra.
  - As tentativas repetidas são independentes umas das outras.
  - A probabilidade de sucesso p é constante para cada tentativa.
  - A probabilidade de que o primeiro sucesso ocorra na tentativa x é $P(x) = p(q)^{x-1}$, em que $q = 1 - p$.

Outras distribuições de probabilidade

Distribuição de Poisson

- Satisfaz as seguintes condições:
  - O experimento consiste em contar o número de vezes que um evento, x, ocorre em um dado intervalo.
    - O intervalo pode ser de tempo, área ou volume
  - A probabilidade de o evento ocorrer é a mesma para cada intervalo
  - O número de ocorrências em um intervalo independe do número de ocorrências em outros intervalos

Outras distribuições de probabilidade

Distribuição de Poisson

- Condições contínuas:
  - A probabilidade do evento ocorrer é a mesma para cada intervalo.
  - A probabilidade de exatamente x ocorrências em um intervalo é:

  - $\mathrm{P(x)} = \frac{\mu^{\mathrm{x}} \mathrm{e}^{-\mu}}{x!}$
  - onde $e \approx 2.71818$ e μ é o número médio de ocorrências.

Outras distribuições de probabilidade

Distribuição F

Condições contínuas:

- A Distribuição F é uma família de distribuições de probabilidade usadas para comparar razões de variâncias entre dois conjuntos de dados.
- Muito usada em testes estatísticos para saber se a diferença entre grupos é maior do que seria esperada só pelo acaso.
    - Usada em ANOVA e regressão
    - Parametrizada por dois graus de liberdade (numerador e denominador)

Outras distribuições de probabilidade

Distribuição F

- O F-statistic compara:
  - Variação entre as médias dos grupos (diferença real de tratamento)
  - Variação dentro de cada grupo (ruído, variação natural)

$$F = \frac{Variancia\ entre\ grupos}{variancia\ dentro\ dos\ grupos}$$

- Se o F calculado for muito maior que 1, indica que as diferenças entre grupos são grandes em relação à variação dentro dos grupos, sugerindo um efeito real do tratamento.

Outras distribuições de probabilidade

Tabela F

TABELA 1 – Limites unilaterais de F ao nível de 5% de probabilidade.

n_2 \ n_1	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	20	24	30	40	60	120	∞
1	161,4	199,5	215,7	224,6	230,2	234,0	236,8	238,9	240,5	241,9	243,0	243,9	244,4	245,0	245,9	246,0	248,0	249,1	250,1	251,1	252,2	253,3	254,3
2	18,51	19,00	19,16	19,25	19,30	19,33	19,35	19,37	19,38	19,40	19,40	19,41	19,42	19,42	19,43	19,43	19,45	19,45	19,46	19,47	19,48	19,49	19,50
3	10,13	9,55	9,28	9,12	9,01	8,94	8,89	8,85	8,81	8,79	8,76	8,74	8,72	8,71	8,70	8,69	8,66	8,64	8,62	8,59	8,57	8,55	8,53
4	7,71	6,94	6,59	6,39	6,26	6,16	6,09	6,04	6,00	5,96	5,93	5,91	5,89	5,87	5,86	5,84	5,80	5,77	5,75	5,72	5,69	5,66	5,63
5	6,61	5,79	5,41	5,19	5,05	4,95	4,88	4,82	4,77	4,74	4,70	4,68	4,66	4,64	4,62	4,60	4,56	4,53	4,50	4,46	4,43	4,40	4,36
6	5,99	5,14	4,76	4,53	4,39	4,28	4,21	4,15	4,10	4,06	4,03	4,00	3,98	3,96	3,94	3,92	3,87	3,84	3,81	3,77	3,74	3,70	3,67
7	5,59	4,74	4,35	4,12	3,97	3,87	3,79	3,73	3,68	3,64	3,60	3,57	3,55	3,52	3,51	3,49	3,44	3,41	3,38	3,34	3,30	3,27	3,23
8	5,32	4,46	4,07	3,84	3,69	3,58	3,50	3,44	3,39	3,35	3,31	3,28	3,25	3,23	3,22	3,20	3,15	3,12	3,08	3,04	3,01	2,97	2,93
9	5,12	4,26	3,86	3,63	3,48	3,37	3,29	3,23	3,18	3,14	3,10	3,07	3,04	3,02	3,01	2,98	2,94	2,90	2,86	2,83	2,79	2,75	2,71
10	4,96	4,10	3,71	3,48	3,33	3,22	3,14	3,07	3,02	2,98	2,94	2,91	2,88	2,86	2,85	2,82	2,77	2,74	2,70	2,66	2,62	2,58	2,54
11	4,84	3,98	3,59	3,36	3,20	3,09	3,01	2,95	2,90	2,85	2,82	2,79	2,76	2,74	2,72	2,70	2,65	2,61	2,57	2,53	2,49	2,45	2,40
12	4,75	3,89	3,49	3,26	3,11	3,00	2,91	2,85	2,80	2,75	2,72	2,69	2,66	2,64	2,62	2,60	2,54	2,51	2,47	2,43	2,38	2,34	2,30
13	4,67	3,81	3,41	3,18	3,03	2,92	2,83	2,77	2,71	2,67	2,63	2,60	2,57	2,55	2,53	2,51	2,46	2,42	2,38	2,34	2,30	2,25	2,21
14	4,60	3,74	3,34	3,11	2,96	2,85	2,76	2,70	2,65	2,60	2,56	2,53	2,50	2,48	2,46	2,44	2,39	2,35	2,31	2,27	2,22	2,18	2,13
15	4,54	3,68	3,29	3,06	2,90	2,79	2,71	2,64	2,59	2,54	2,51	2,48	2,45	2,43	2,40	2,39	2,33	2,29	2,25	2,20	2,16	2,11	2,07
16	4,49	3,63	3,24	3,01	2,85	2,74	2,66	2,59	2,54	2,49	2,45	2,42	2,39	2,37	2,35	2,33	2,28	2,24	2,19	2,15	2,11	2,06	2,01
17	4,45	3,59	3,20	2,96	2,81	2,70	2,61	2,55	2,49	2,45	2,41	2,38	2,35	2,33	2,31	2,29	2,23	2,19	2,15	2,10	2,06	2,01	1,96
18	4,41	3,55	3,16	2,93	2,77	2,66	2,58	2,51	2,46	2,41	2,37	2,34	2,31	2,29	2,27	2,25	2,19	2,15	2,11	2,06	2,02	1,97	1,92
19	4,38	3,52	3,13	2,90	2,74	2,63	2,54	2,48	2,42	2,38	2,34	2,31	2,28	2,26	2,23	2,21	2,16	2,11	2,07	2,03	1,98	1,93	1,88
20	4,35	3,49	3,10	2,87	2,71	2,60	2,51	2,45	2,39	2,35	2,31	2,28	2,25	2,23	2,20	2,18	2,12	2,08	2,04	1,99	1,95	1,90	1,84
21	4,32	3,47	3,07	2,84	2,68	2,57	2,49	2,42	2,37	2,32	2,28	2,25	2,22	2,20	2,18	2,15	2,10	2,05	2,01	1,96	1,92	1,87	1,81
22	4,30	3,44	3,05	2,82	2,66	2,55	2,46	2,40	2,34	2,30	2,26	2,23	2,20	2,18	2,15	2,13	2,07	2,03	1,98	1,94	1,89	1,84	1,78
23	4,28	3,42	3,03	2,80	2,64	2,53	2,44	2,37	2,32	2,27	2,24	2,20	2,17	2,14	2,13	2,10	2,05	2,01	1,96	1,91	1,86	1,81	1,76
24	4,26	3,40	3,01	2,78	2,62	2,51	2,42	2,36	2,30	2,25	2,22	2,18	2,15	2,13	2,11	2,09	2,03	1,98	1,94	1,89	1,84	1,79	1,73
25	4,24	3,39	2,99	2,76	2,60	2,49	2,40	2,34	2,28	2,24	2,20	2,16	2,13	2,11	2,09	2,06	2,01	1,96	1,92	1,87	1,82	1,77	1,71
26	4,23	3,37	2,98	2,74	2,59	2,47	2,39	2,32	2,27	2,22	2,18	2,15	2,12	2,10	2,07	2,05	1,99	1,95	1,90	1,85	1,80	1,75	1,69
27	4,21	3,35	2,96	2,73	2,57	2,46	2,37	2,31	2,25	2,20	2,16	2,13	2,10	2,08	2,06	2,03	1,97	1,93	1,88	1,84	1,79	1,73	1,67
28	4,20	3,34	2,95	2,71	2,56	2,45	2,36	2,29	2,24	2,19	2,15	2,12	2,09	2,06	2,04	2,02	1,96	1,91	1,87	1,82	1,77	1,71	1,65
29	4,18	3,33	2,93	2,70	2,55	2,43	2,35	2,28	2,22	2,18	2,14	2,10	2,07	2,05	2,03	2,00	1,94	1,90	1,85	1,81	1,75	1,70	1,64
30	4,17	3,32	2,92	2,69	2,53	2,42	2,33	2,27	2,21	2,16	2,12	2,09	2,06	2,04	2,01	1,99	1,93	1,89	1,84	1,79	1,74	1,68	1,62
40	4,08	3,23	2,84	2,61	2,45	2,34	2,25	2,18	2,12	2,08	2,04	2,00	1,97	1,95	1,92	1,90	1,84	1,79	1,74	1,69	1,64	1,58	1,51
60	4,00	3,15	2,76	2,53	2,37	2,25	2,17	2,10	2,04	1,99	1,95	1,92	1,89	1,86	1,84	1,81	1,75	1,70	1,65	1,59	1,53	1,47	1,39
120	3,92	3,07	2,68	2,45	2,29	2,17	2,09	2,02	1,96	1,91	1,86	1,83	1,80	1,77	1,75	1,73	1,66	1,61	1,55	1,50	1,43	1,35	1,25
∞	3,84	3,00	2,60	2,37	2,21	2,10	2,01	1,94	1,88	1,83	1,79	1,75	1,72	1,69	1,67	1,64	1,57	1,52	1,46	1,39	1,32	1,22	1,00

Outras distribuições de probabilidade

- **Distribuição F**

Exemplo prático: ANOVA

	Grupo A	Grupo B	Grupo C
Dados	20	19	25
	22	21	24
	23	20	23

Existe diferença significativa entre as médias dos grupos?

Outras distribuições de probabilidade

- **Distribuição F**

Exemplo prático: ANOVA

Calcular as médias

- Média A: (20+22+23)/3=21.67(20+22+23)/3=21.67
- Média B: (19+21+20)/3=20.00(19+21+20)/3=20.00
- Média C: (25+24+23)/3=24.00(25+24+23)/3=24.00
- Média da médias: (20+22+23+19+21+20+25+24+23)/9 =
  = 21.89(20+22+23+19+21+20+25+24+23)/9 = 21.89

Outras distribuições de probabilidade

- **Distribuição F**

Exemplo prático: ANOVA

Calcular a soma dos quadrados entre grupos (SQE)

$SQE = n_{grupo} \cdot \sum(\text{Média do grupo} - \text{Média das médias})^2$

$= 3 \cdot [(21.67 - 21.89)^2 + (20.00 - 21.89)^2 + (24.00 - 21.89)^2]$

$= 3 \cdot [(-0.22)^2 + (-1.89)^2 + (2.11)^2]$

$= 3 \cdot [0.0484 + 3.5721 + 4.4521]$

$= 3 \cdot 8.0726 = 24.2178$

Outras distribuições de probabilidade

- **Distribuição F**

Exemplo prático: ANOVA

Calcular a soma dos quadrados dentro dos grupos (SQD)

Para o grupo A:

$(20-21.67)^2+(22-21.67)^2+(23-21.67)^2=2.78+0.11+1.76=4.65$

Para o grupo B:

$(19-20)^2+(21-20)^2+(20-20)^2=1+1+0=2$

Para o grupo C:

$(25-24)^2 + (24-24)^2 + (23-24)^2 = 1+0+1 = 2$

SQD$=4.65+2+2=8.65$

Outras distribuições de probabilidade

- **Distribuição F**

Exemplo prático: ANOVA

Calcule os graus de liberdade

Entre grupos: $k-1=3-1=2$

Dentro dos grupos: $N-k=9-3=6$

Calcule os quadrados médios (QM)

$Qm_{entre} = SQE/(k-1) = 24.2178/2 = 12.11$

$Qm_{dentro} = SQD/(N-k) = 8.65/6 = 1.44$

Calcule o F

$F = Qm_{entre}/Qm_{dentro} = 12.11/1.44 \approx 8.41$

Comparar o F obtido com o F crítico da tabela F para 2 e 6 graus de liberdade, $\alpha = 0,05$.

Em geral, F crítico ≈ 5.14.

Como $8.41 > 5.14$, rejeitamos H_0: ao menos um grupo tem média diferente.

Distribuições de Cauda Longa

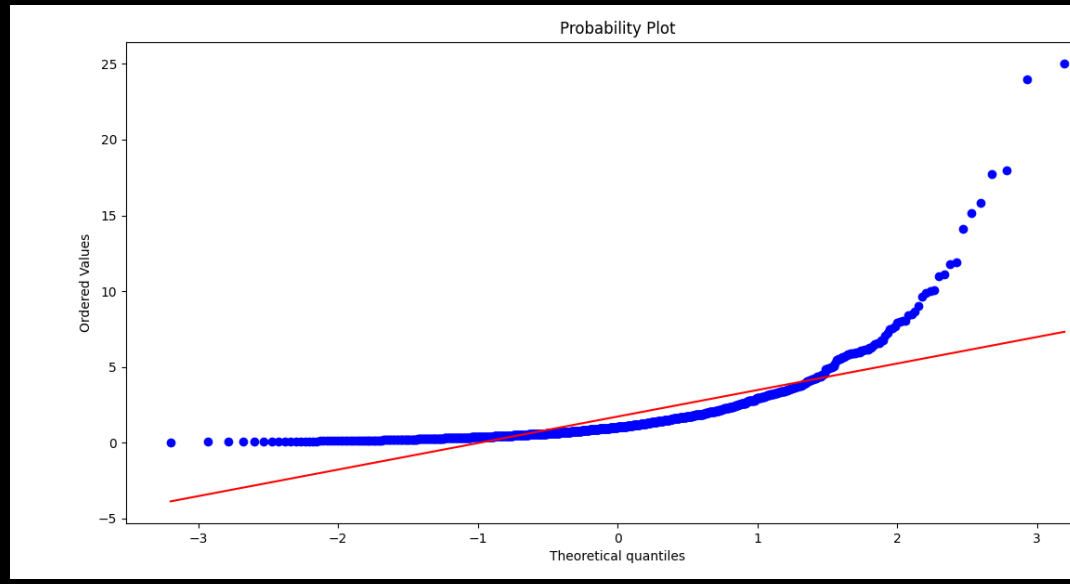
- Uma distribuição de cauda longa é aquela em que existem valores extremos (muito altos ou muito baixos) que ocorrem com mais frequência do que seria previsto pela distribuição normal (gaussiana).
- A “cauda” é a parte mais fina e esticada do gráfico da distribuição, onde aparecem valores muito distantes da média.
- Assimetria: Se uma cauda é mais longa que a outra (mais valores extremos de um lado), dizemos que a distribuição é assimétrica.

Por que dados reais costumam ser de cauda longa?

- A normal é simétrica e "curta nas pontas": em teoria, eventos extremos (outliers) são muito raros.
- Na prática, dados reais — como renda, visitas em sites, vendas, preços de ativos financeiros, etc. — têm muitos outliers (valores fora do comum), ou seja, eventos raros, porém não impossíveis.
- Isso significa que, em muitos contextos, é mais fácil observar algo "absurdo" do que a normal sugeriria.

Como detectar uma cauda longa

- QQ-Plot: É um gráfico que compara os quantis dos dados com os quantis de uma distribuição normal.
  - Se os pontos acompanham uma reta (principalmente nas extremidades), os dados são normais.
  - Se os pontos fogem da reta nas extremidades (caindo muito abaixo ou subindo muito acima), indica cauda longa (ou assimetria).

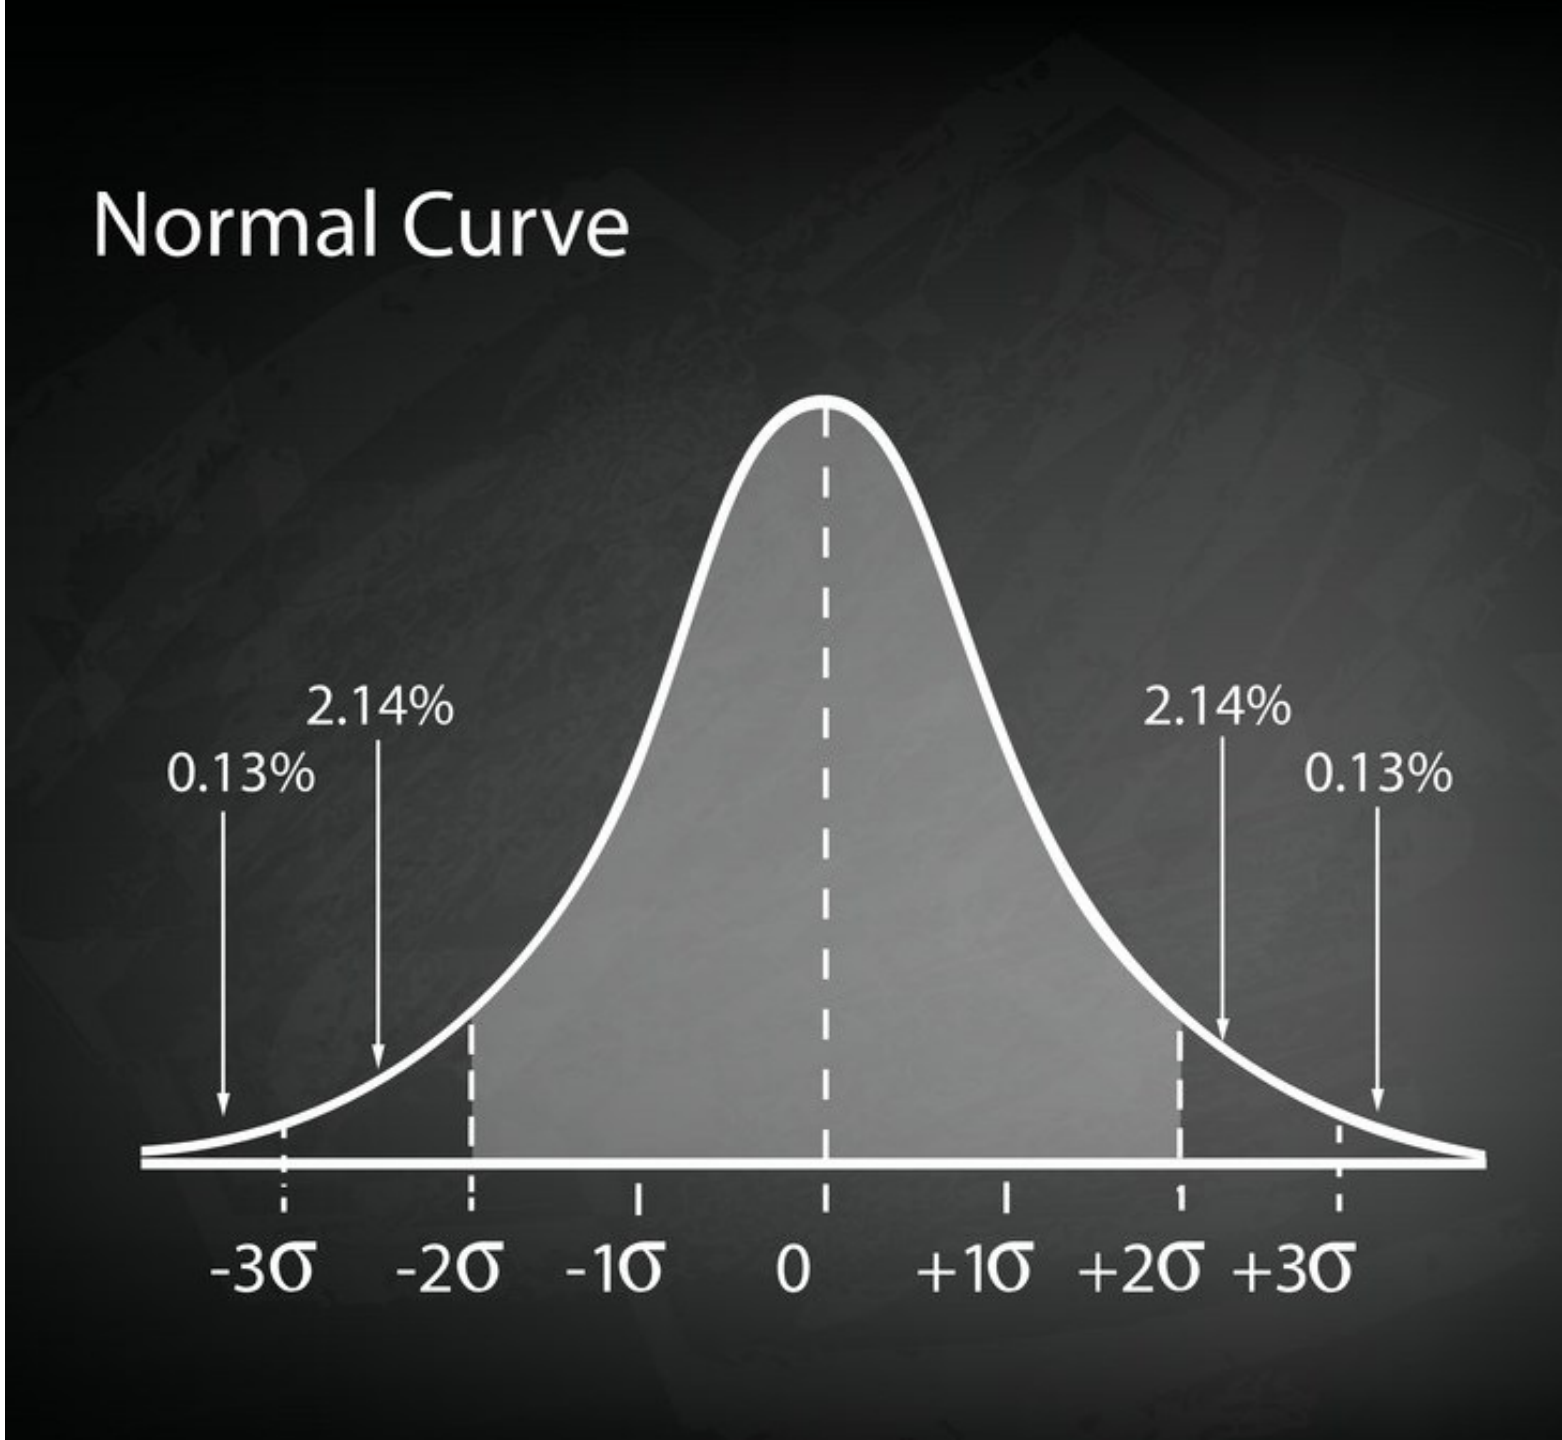


Modelando caudas longas

- Em vez da normal, usamos outras distribuições:
  - Log-normal (renda, vendas);
  - Pareto (renda, cidades);
  - Exponencial (tempo até próximo evento raro);
  - Poisson (contagem de eventos raros por intervalo);
  - Distribuições de potência, etc.

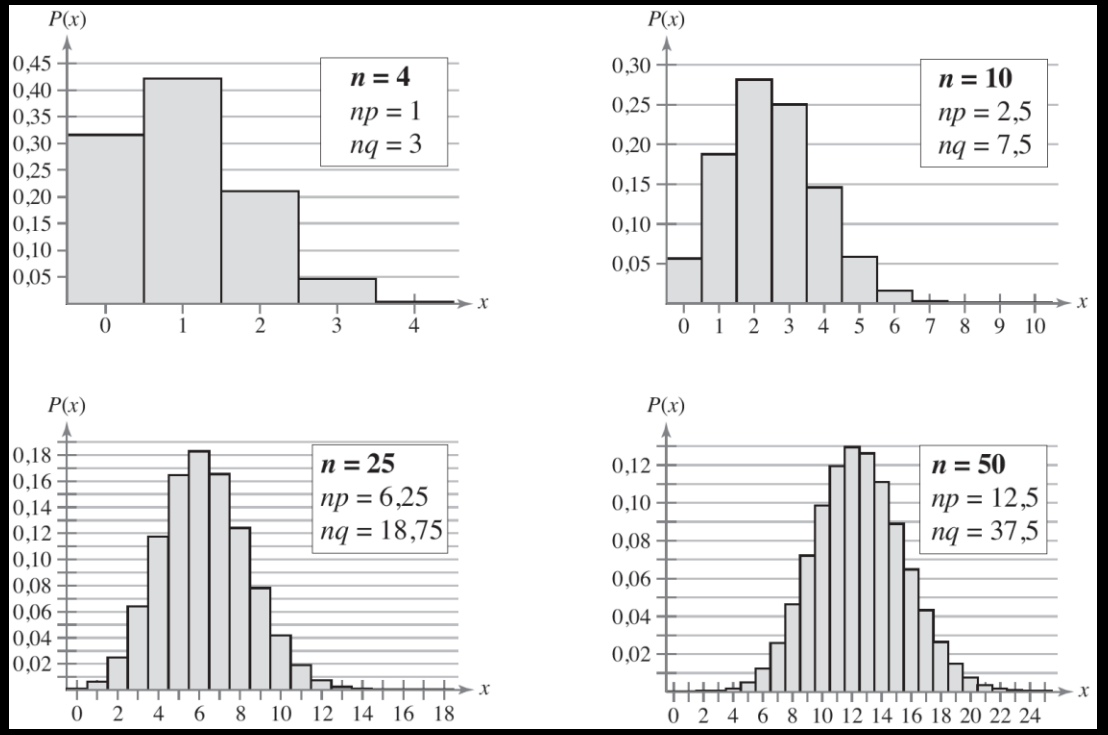
Teorema Central do Limite (TCL)

- Mesmo que os dados originais não sejam normais, a distribuição das médias amostrais será aproximadamente normal, se o tamanho da amostra for suficientemente grande.
- Isso justifica o uso da distribuição normal em muitos testes estatísticos.



Aproximação normal para uma distribuição binomial

- A distribuição normal é usada para aproximar a distribuição binomial quando não seria prático usar a distribuição binomial para encontrar uma probabilidade.
- Se $np \geq 5$ e $nq \geq 5$, então a variável aleatória binomial x é aproximadamente distribuída com média $\mu = np$ e desvio padrão $\sigma = \sqrt{npq}$.



Aproximação normal para uma distribuição binomial

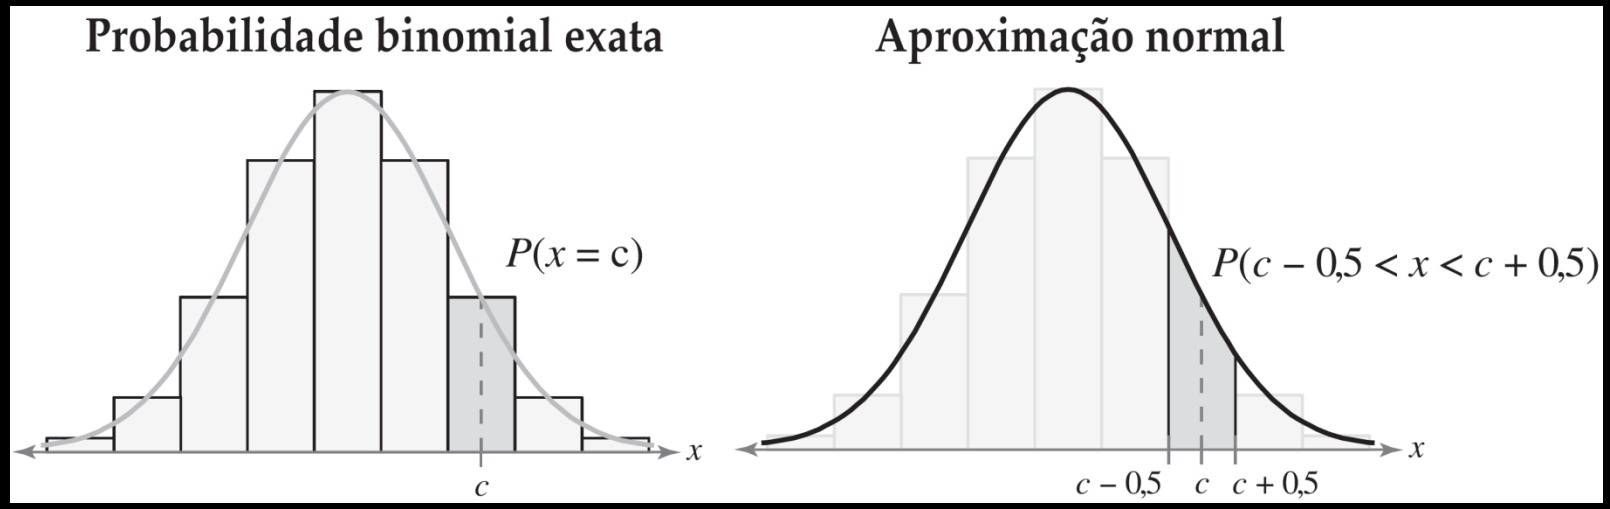
Correção pela continuidade

- A distribuição binomial é discreta e pode ser representada pelo histograma de probabilidade.
- Para calcular as probabilidades binomiais exatas, a fórmula binomial é usada para cada valor de x e os resultados são somados.
- Isso corresponde geometricamente a somar as áreas das barras no histograma de probabilidade.

Aproximação normal para uma distribuição binomial

Correção pela continuidade

- Quando você usa uma distribuição normal contínua para aproximar uma probabilidade binomial, você precisa mover 0,5 unidade para a esquerda e para a direita do ponto médio para incluir todos os possíveis valores x no intervalo (correção pela continuidade).



Aproximação normal para uma distribuição binomial

Ordem	Descrição	Ação
1	Verifique se a distribuição binomial se aplica.	Especifique n, p e q.
2	Determine se você pode usar a distribuição binomial para aproximar x, a variável binomial.	$np \geq 5$ e $nq \geq 5$?
3	Encontre a média μ e o desvio padrão σ para a distribuição.	$\mu = np$ $\sigma = \sqrt{npq}$
4	Aplique a correção pela continuidade apropriada. Sombreie a área correspondente sob a curva.	Some ou subtraia 0,5 dos pontos finais.
5	Encontre o(s) escore(s) z correspondente(s).	$z = \frac{x-\mu}{\sigma}$
6	Encontre a probabilidade.	Use a tabela normal padrão.

Experimentos Estatísticos e Testes de Significância



Experimentos Estatísticos

- Procedimento controlado para comparar grupos ou tratamentos
- Mede o efeito de uma variável (tratamento) sobre outra (resultado)
- Usa aleatorização e grupo controle sempre que possível
- Experimentos permitem comparar grupos ou tratamentos para descobrir se alguma diferença observada é real ou fruto do acaso.

Hipóteses Estatísticas

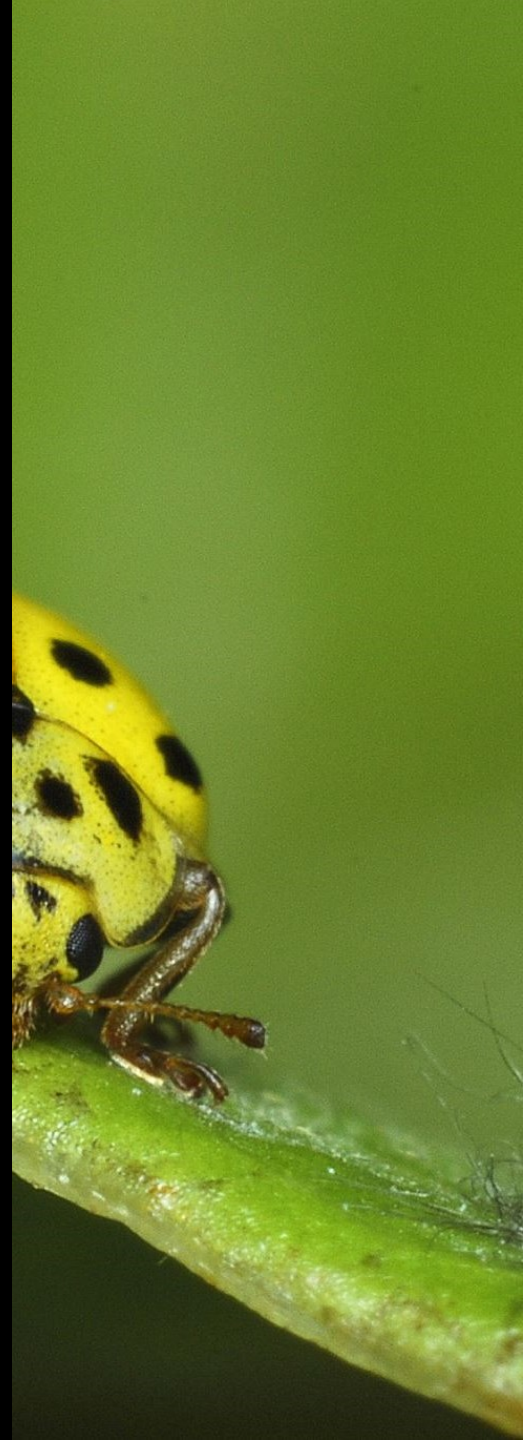
- Hipótese nula (H_0): afirma que não há diferença ou efeito.
  - Exemplo: “O novo remédio NÃO é melhor que o padrão.”
- Hipótese alternativa (H_1): afirma que existe diferença/efeito.
  - Exemplo: “O novo remédio É melhor que o padrão.”
- O teste avalia se os dados coletados dão suporte à rejeição da H_0

Tipos de testes: unilateral e bilateral

- Unilateral: Só importa um lado (ex: apenas se o novo é melhor).
- Bilateral: Importa qualquer diferença (ex: novo pode ser melhor ou pior).

Erros Tipo I e II, Poder Estatístico

- Erro Tipo I (α): Rejeitar H_0 quando ela é verdadeira (falso positivo)
- Erro Tipo II (β): Não rejeitar H_0 quando H_1 é verdadeira (falso negativo)
- Poder estatístico: Probabilidade de detectar um efeito real (1−β), idealmente acima de 80%.
  - Importância de escolher α e calcular tamanho amostral



P-valor

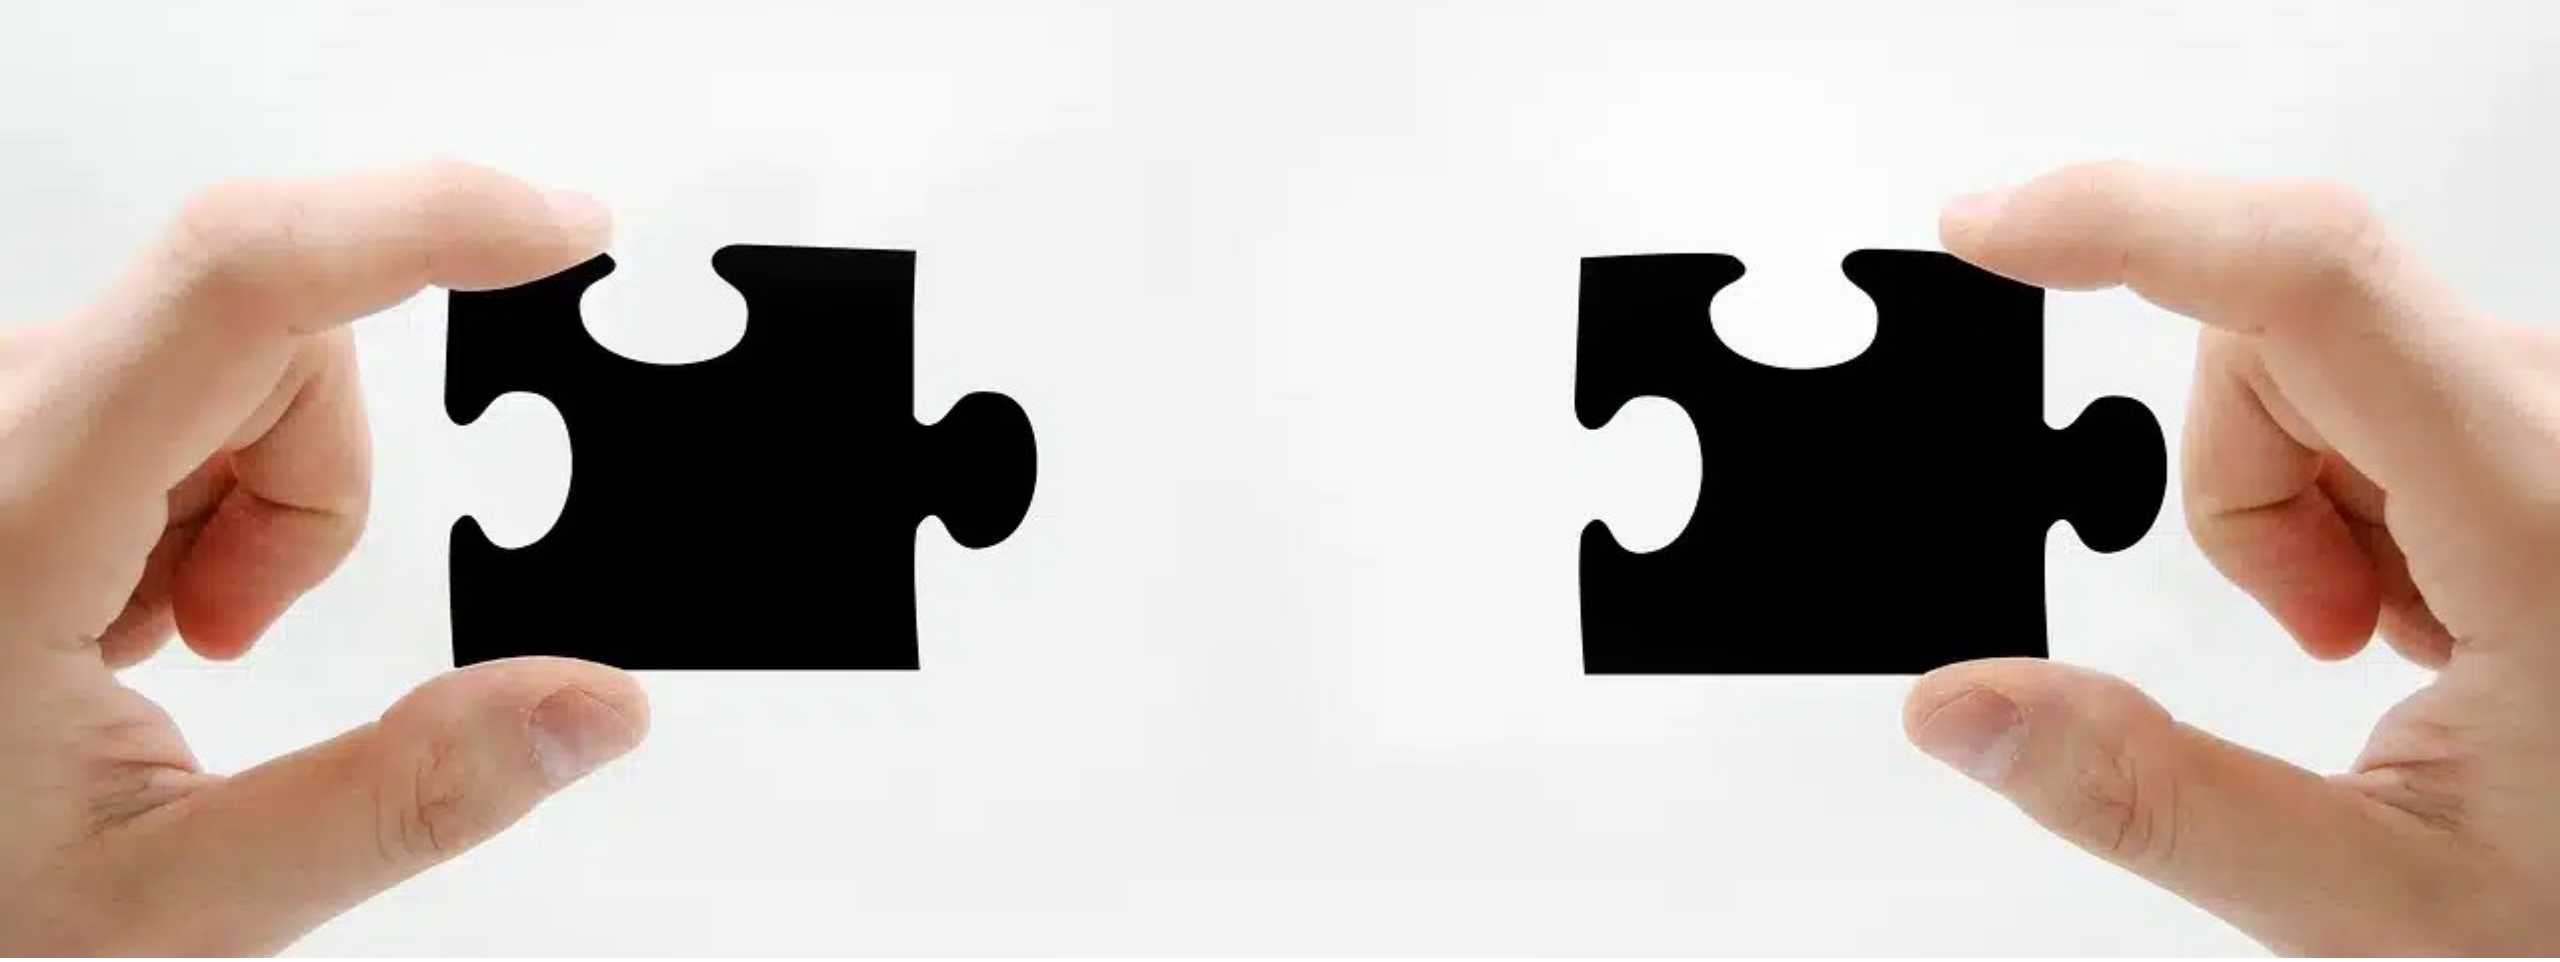
- Probabilidade de obter um resultado tão extremo quanto o observado, assumindo H_0 verdadeira
- p pequeno → evidência contra H_0
- Limite comum: $\alpha = 0,05$
- Exemplo: Se p-valor = 0,03 e α = 0,05, rejeitamos H_0 (diferença considerada significativa).



Experimentos Estatísticos

- **Formule H_0 e H_1**
- **Escolha do teste** (t, χ^2, ANOVA, permutação, etc)
- **Defina α** (nível de significância)
- **Realize o experimento e colete dados**
- **Calcule estatística de teste e p-valor**
- **Decida: rejeitar ou não H_0**
- **Reporte efeito, p-valor, IC, limitações**





Testes A/B (e A/B/C...)

- A/B Testing

  Experimento clássico em web/negócios — divide usuários em dois (ou mais) grupos para testar diferentes versões de site, e-mails, etc.

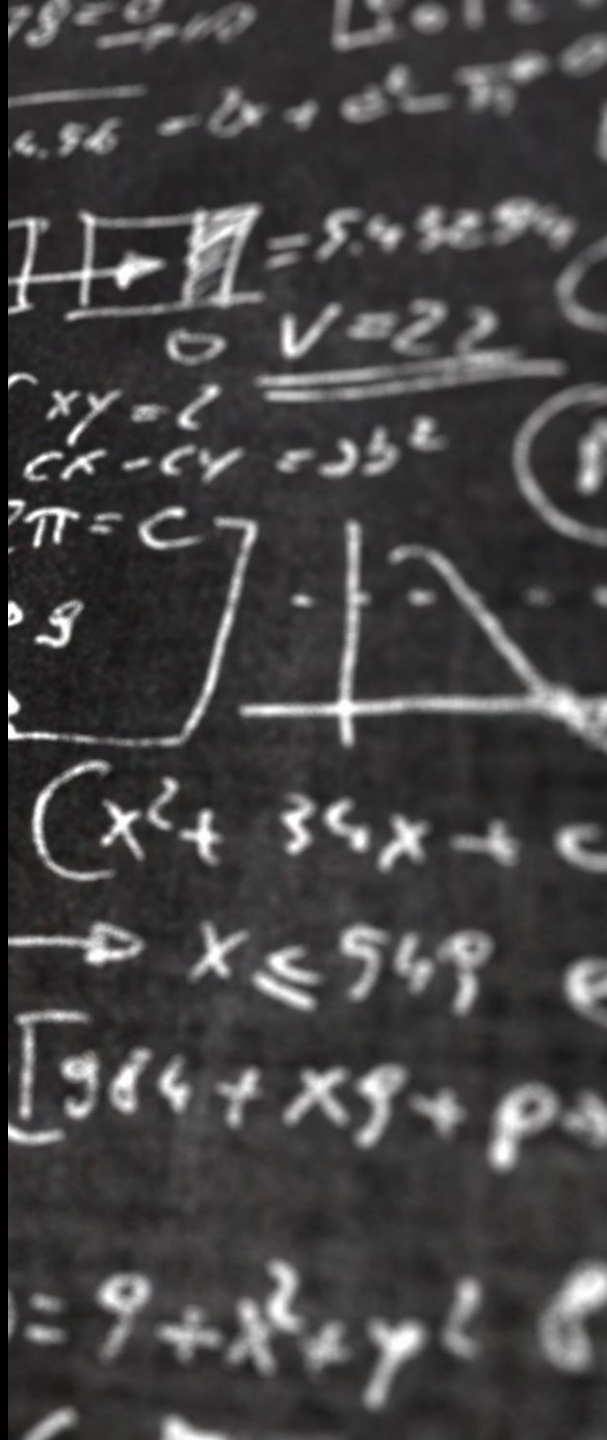
- Teste contínuo e rápido; resultados devem ser interpretados com rigor estatístico.



Testes clássicos (t, χ^2, ANOVA) e por permutação

- **t-teste:** Diferença de médias (dois grupos).
- **Qui-quadrado (χ^2):** Dados categóricos, frequência observada vs. esperada.
- **ANOVA:** Diferença entre médias de 3 ou mais grupos.
- **Teste de permutação:** Embaralha rótulos dos grupos e estima p-valor sem pressupor distribuição.

Exemplos



Teste z de uma média

Uma fábrica afirma que a massa média de suas barras de cereal é 50g. Um fiscal coleta 25 barras e encontra média amostral de 51g, com desvio padrão amostral de 2g. O lote está dentro do padrão?

1. **H_0:** $\mu = 50g$ **H_1:** $\mu \neq 50g$ (teste bilateral)
2. $\boldsymbol{erro_P = \frac{s}{\sqrt{n}} = \frac{2}{\sqrt{25}} = 0,4}$
3. $\boldsymbol{z_{score} = \frac{\bar{x} - \mu}{erro_P} = \frac{51 - 50}{0,4} = 2,5}$
4. $\boldsymbol{p_{valor} = (na\ tabela\ z) = P(z > 2,5) = 2 * 0,0062 = 0,0124}$
5. **$p < 0,05 \Rightarrow$ rejeite H_0:** há evidência de que a média é diferente de 50g.

Teste t de duas amostras independentes

Dois métodos de ensino, nota de 5 alunos por método:

Método 1	7	8	6	9	7
Método 2	6	6	7	5	6

1. **H_0:** médias iguais **H_1:** médias diferentes
2. **Médias e desvios padrão:**

   Média 1: (7+8+6+9+7)/5 = 7,4 Desvio 1 ≈ 1.14

   Média 2: (6+6+7+5+6)/5 = 6,0 Desvio 2 ≈ 0.707
3. **Erro padrão da diferença:**

$$erro_P = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} = \sqrt{\frac{1{,}14^2}{5} + \frac{0{,}707^2}{5}} = 0{,}6$$

Teste t de duas amostras independentes

Dois métodos de ensino, nota de 5 alunos por método:

Método 1	7	8	6	9	7
Método 2	6	6	7	5	6

4. **t calculado:**

$$t = \frac{7,4 - 6,0}{0,6} = 2,33$$

5. Tabela t para gl=8, α=0,05 (bilateral): valor crítico ≈ 2,31
6. Como t > 2,31, rejeitamos H_0: diferença significativa.

Qui-quadrado (χ^2) para tabelas

Preferência de cor (vermelho/azul) por gênero.

	Vermelho	**Azul**	**Total**
Homens	20	10	30
Mulheres	10	20	30

1. **H_0:** cor preferida independe do gênero.
2. **Esperados:**
   - Total vermelho: 30, azul: 30
   - Esperado para cada célula = (linha × coluna)/total
   - Homens-vermelho: (30 × 30) / 60 = 15
   - Homens-azul: 15; Mulheres-vermelho: 15; Mulheres-azul: 15

Qui-quadrado (χ^2) para tabelas

Preferência de cor (vermelho/azul) por gênero.

	Vermelho	**Azul**	**Total**
Homens	20	10	30
Mulheres	10	20	30

3. $\chi^2 = \sum \frac{(x_i - E)^2}{E} = 6{,}67$
4. **Graus de liberdade:** (2−1)×(2−1) = 1
5. **Tabela χ^2 para gl=1, α=0,05:** valor crítico = 3,84
6. **Como 6,67 > 3,84, rejeitamos H_0:** há associação entre cor e gênero.

ANOVA (Comparação de 3+ médias)

Três métodos de estudo, notas de 3 alunos por grupo:

Método A	6	8	7
Método B	5	6	6
Método C	9	8	8

1. **H_0:** Todas as médias são iguais
2. **Médias dos grupos:**

   A: 7,0; B: 5,67; C: 8,33

   Média global: (6+8+7+5+6+6+9+8+8)/9 = 7
3. **Soma dos quadrados entre grupos (SQE):**

$$SQE=3\times[(7-7)^2+(5.67-7)^2+(8.33-7)^2]=3\times[0+1.77+1.77]=3\times3.54=10.62$$

ANOVA (Comparação de 3+ médias)

Três métodos de estudo, notas de 3 alunos por grupo:

Método A	6	8	7
Método B	5	6	6
Método C	9	8	8

4. **Soma dos quadrados dentro dos grupos (SQD):**
   (6-7)^2 + (8-7)^2 + (7-7)^2 = 1 + 1 + 0 = 2 (A)
   (5-5.67)^2 + (6-5.67)^2 + (6-5.67)^2 = 0.45 + 0.11 + 0.11 = 0.67 (B)
   (9-8.33)^2 + (8-8.33)^2 + (8-8.33)^2 = 0.45 + 0.11 + 0.11 = 0.67 (C)
   SQD = 2 + 0.67 + 0.67 = 3.34
5. **Graus de liberdade:**
   Entre grupos: $k-1 = 3-1 = 2$
   Dentro dos grupos: $N-k = 9-3 = 6$

ANOVA (Comparação de 3+ médias)

Três métodos de estudo, notas de 3 alunos por grupo:

Método A	6	8	7
Método B	5	6	6
Método C	9	8	8

6. **Quadrado médio:**
   QM entre = SQE/2 = 5.31
   QM dentro = SQD/6 = 0.56
7. **F calculado:**
   $F = 5.31 \approx 9.48$
   $F = 0.56 \approx 9.48$
4. Valor crítico F (gl=2,6, α=0,05) ≈ 5.14
5. Como 9.48 > 5.14, rejeitamos H_0: ao menos um grupo tem média diferente.

Permutação

Um pesquisador quer avaliar a eficácia de um novo fertilizante no crescimento de plantas. Ele seleciona 7 plantas idênticas e as divide aleatoriamente em dois grupos:

- **Grupo A (Tratamento):** 4 plantas recebem o novo fertilizante.
- **Grupo B (Controle):** 3 plantas não recebem fertilizante.

Após um mês, ele mede o crescimento das plantas em centímetros. Os resultados foram:

- **Crescimento do Grupo A (Tratamento):** {18, 21, 22, 15}
- **Crescimento do Grupo B (Controle):** {12, 16, 11}

Pergunta: Há evidência estatística para afirmar que o fertilizante é eficaz, ou seja, que o crescimento médio no Grupo A é maior que no Grupo B? Use um nível de significância de $\alpha=0.10$.

Permutação

- Hipótese Nula (H0): O fertilizante não tem efeito. A diferença de crescimento observada entre os grupos é meramente fruto do acaso da divisão dos grupos. Se H0 é verdadeira, as etiquetas "Tratamento" e "Controle" são intercambiáveis.
- Hipótese Alternativa (H1): O fertilizante é eficaz. O crescimento médio do Grupo A é maior que o do Grupo B. (Este é um teste unicaudal).

Permutação

- Média do Grupo A (Tratamento):

$$\hat{x}_a = 19cm$$

- Média do Grupo B (Controle):

$$\hat{x}_b = 13cm$$

- Diferença Observada:

$$\Delta_{obs} = \hat{x}_a - \hat{x}_b = 6cm$$

Quantas maneiras diferentes existem para escolher 4 plantas (para o Grupo A) de um total de 7?

$$C_{n_a}^{N} = C_4^7 = 35$$

Permutação

- Aqui temos um problema. Será necessário calcular a diferença observada para cada uma das possibilidades de permutação:
- Ex(incompleto, o certo é fazer com as 35 possibilidades):

•**Permutação 1 (A Original):**
Grupo A: {18, 21, 22, 15} -> x_A = 19
Grupo B: {12, 16, 11} -> x_B = 13
Diferença (Δ_1): 19−13=6

•**Permutação 2 (Trocando 15 por 12):**
Grupo A: {18, 21, 22, 12} -> x_A =18.25
Grupo B: {15, 16, 11} -> x_B=14
Diferença (Δ_2): 18.25−14=4.25

Permutação 3 (Um caso mais extremo, com os maiores valores em A):
•Grupo A: {18, 21, 22, 16} -> x_A=19.25
•Grupo B: {15, 12, 11} -> x_B=12.67
•Diferença (Δ_3): 19.25−12.67=6.58

•**Permutação 4 (Um caso oposto, com os menores valores em A):**
•Grupo A: {11, 12, 15, 16} -> x_A=13.5
•Grupo B: {18, 21, 22} -> x_B=20.33
•Diferença (Δ_4): 13.5−20.33=−6.83
•...

Permutação

- Para calcular o p-valor, precisamos comparar nossa diferença observada (Δ_{obs}=6) com as diferenças de todas as 35 permutações possíveis.
- O **p-valor** será a proporção de permutações que resultaram em uma diferença de médias igual ou maior que a que observamos.

$$p = \frac{quantidade\ das\ permutações\ com\ \Delta_{perm} \geq \Delta_{obs}}{quantidade\ total\ das\ permutações}$$

- Terão que confiar, neste momento que acontece 2 vezes apenas(ou então calcule para as 35 possibilidades manualmente, rs).

$$p = \frac{2}{35}\ aprox. \Rightarrow 0{,}057$$

Permutação

- Como $p < a = 0,10$ (ou 10% de significância), rejeitamos a hipótese nula e por isso:
- Com um nível de significância de 10%, há evidência estatística suficiente para concluir que o novo fertilizante é eficaz.
- A probabilidade de obter uma diferença de crescimento tão grande ou maior que 6 cm apenas por acaso é de aproximadamente 5.7%, o que é considerado um evento suficientemente raro para justificar a rejeição da hipótese de que não há efeito.

Permutação

- Mas como pode percebido, este método (calcular cada uma das possibilidades das 35 combinações) pode ser dispendioso até para uso computacional (imagine um problema com mais de 1000 combinações, por exemplo).
- Então, temos duas observações a fazer:

1. Este método é um método naturalmente computacional
2. Utilizamos outro método de apoio, chamado método Monte Carlo
    - Iremos mostrar um passo a passo de sua execução, sem entrar em grandes detalhes.

Permutação com Monte Carlo

Mas como pode percebido, este método (calcular cada uma das possibilidades das 35 combinações) pode ser dispendioso até para uso computacional (imagine um problema com mais de 1000 combinações, por exemplo).

Então, temos duas observações a fazer:

- Este método é um método naturalmente computacional
- Utilizamos outro método de apoio, chamado método Monte Carlo

Iremos mostrar um passo a passo de sua execução, sem entrar em grandes detalhes.

Permutação com Monte Carlo

Passo 0: Importar o Módulo random

Passo 1: Definir os Dados e Calcular a Diferença Observada

Passo 2: Preparar a Simulação

Passo 3: O Loop de Monte Carlo (O Coração da Simulação)

Passo 4: Calcular o P-Valor e Interpretar o Resultado

Regressão

Objetivo: Realização projeções de valores, a partir de histórico de dados correlacionados.

Importante: Coef. de correlação

$$\sum \frac{(x_i - \bar{x})(y_i - \bar{y})}{(n-1)s_x s_y}$$

Regressão

Resposta:

- Preditor, variável dependente, y, alvo, objetivo

Registro:

- Linha, caso, instância, exemplo

Coeficiente de Correlação(β_1 ou b_1):

- Inclinação, peso, estimativa

Intercepto (β_0 ou b_0):

- Cruza eixo y quando x = 0

Valor Ajustado:

- Resposta $\hat{y}$

Resíduo:

- Erro

Método dos mínimos Quadrados

Técnica matemática fundamental em estatística e otimização, usada para encontrar a linha ou curva que melhor se ajusta a um conjunto de pontos de dados.

$$Y = b_0 + b_1 X$$
$$Y_i = b_0 + b_1 X_i + erro$$
$$\hat{Y} = \hat{b}_0 + \hat{b}_1 X_i$$
$$\hat{e}_i = Y_i - \hat{Y}_i$$

Método dos mínimos Quadrados

Determinação dos valores de b:

$$b_0 \Rightarrow onde\ o\ Y = 0$$

$$b_1 = \frac{n\sum xy\ - \sum x \sum y}{n\sum x^2 - (\sum x)^2}$$

Regressão Linear Multipla

- Inclui várias variáveis independentes:

$$Y = b_0 + b_1X_1 + b_2X_2 + \cdots + b_nX_n + erro$$

- Avalia efeitos simultâneos e controle de variáveis.
- Usada para modelagem mais realista de fenômenos complexos.

Avaliando Modelos de Regressão

Root Mean Square Error:

Raiz do Erro Quadrático Médio:

O quão, em média, distantes as previsões de um modelo estão dos valores reais. Ele representa o desvio padrão dos resíduos (os "erros" de previsão).

$$RMSE = \sqrt{\frac{\sum_i^n \left(Y_i - \hat{Y}_i\right)^2}{n}}$$

Avaliando Modelos de Regressão

Residual Standard Error (RSE),:

Erro Padrão Residual:

Medida que quantifica a dispersão dos pontos de dados em torno de uma linha de regressão.

$$RSE = \sqrt{\frac{\sum_i^n \left(Y_i - \hat{Y}_i\right)^2}{n - p - 1}}$$

A única diferença para o RMSE é que o denominador são os **graus de liberdade**, em vez do **número de registros.**

Avaliando Modelos de Regressão

RSS – Residual Squared Sum

Soma dos quadrados dos resíduos ou MMQ

$$RSS = \sum \left(Y_i - \hat{Y}\right)^2$$

$$RSS = \sum \left(Y_i - (\hat{b}_0 + \hat{b}_1 X_i)\right)^2$$

$$* \, TSS = \sum (Y_i - \bar{Y})^2$$

Coef. de determinação:

$$R^2 = 1 - \frac{RSS}{TSS}$$

Avaliando Modelos de Regressão

Área	R^2 típico considerado bom
Ciências sociais	0,3 a 0,5 já é aceitável
Ciências da saúde	0,5+ costuma ser bom
Física/engenharias	0,9+ é comum e esperado
Finanças/economia real	0,2 já pode ter valor

Valor R^2	
<0,3	Fraco
0,3~0,5	Moderado
0,5~0,7	Bom
0,7 ~0,9	Muito bom
> 0,9	Excelente

Avaliando Modelos de Regressão

R^2 ajustado:

$$R^2_{ajustado} = 1 - \frac{\frac{RSS}{n-k-1}}{\frac{TSS}{n-1}}$$

Onde:

n = número de observações

k = número de variáveis independentes



Tópicos avançados em regressão



Cross-Validation

- **Definição:** Técnica de validação que mede a capacidade preditiva de um modelo ao aplicar divisões sistemáticas dos dados em subconjuntos de treino e teste.
- **Objetivo:** Avaliar a performance do modelo de forma mais realista, reduzindo o risco de overfitting.

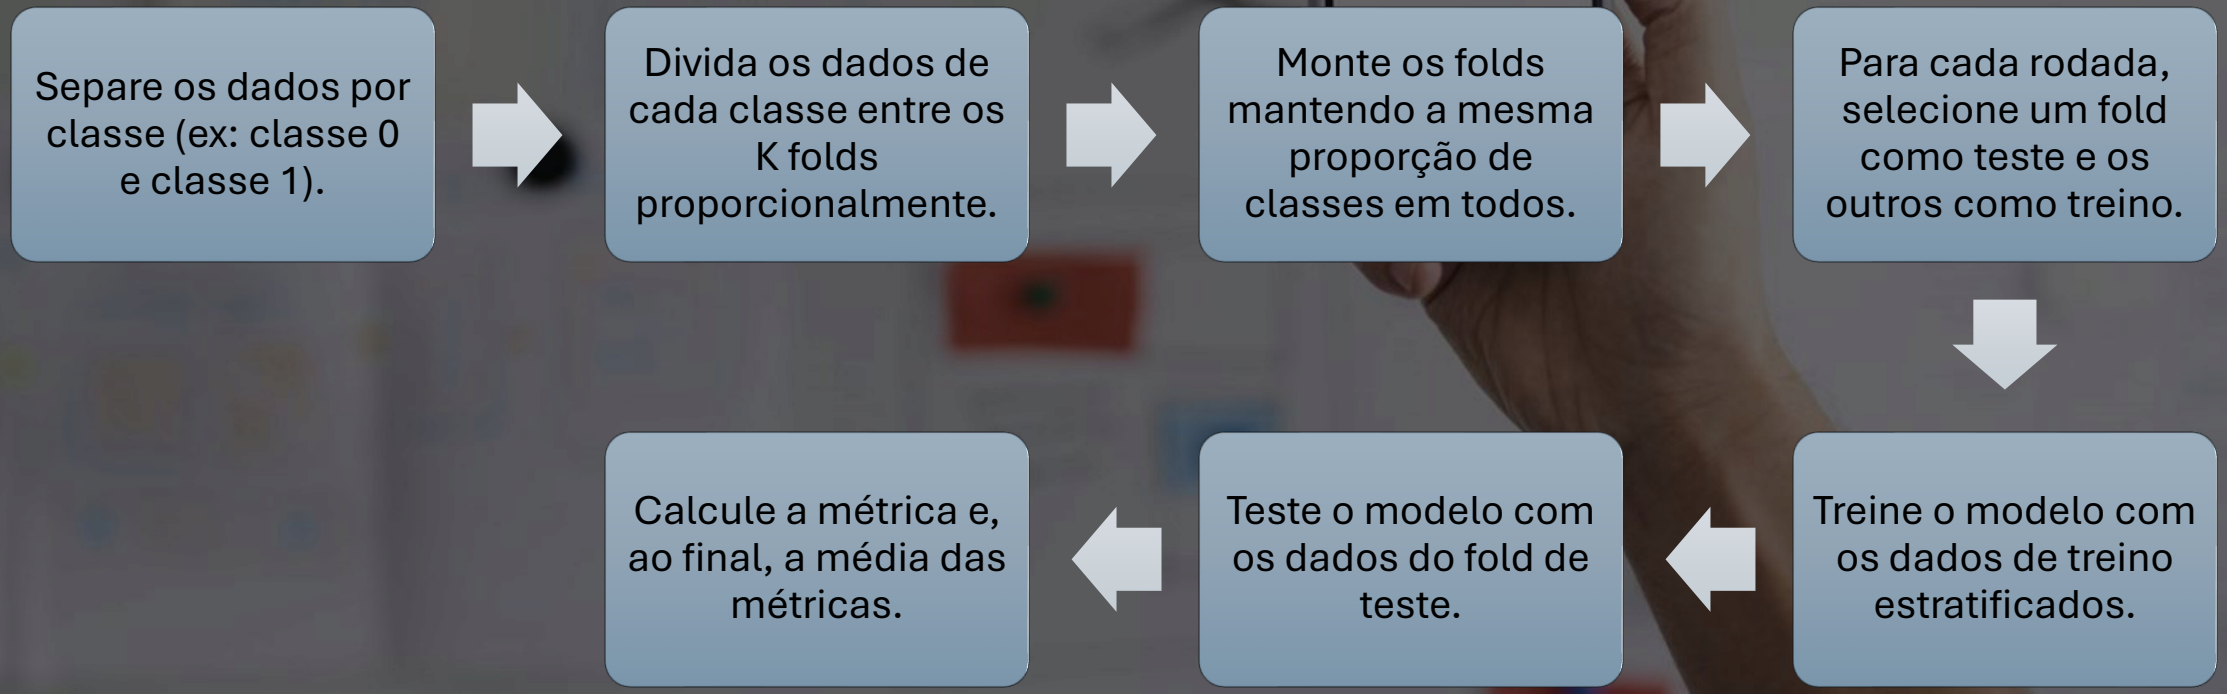
Cross-Validation



Cross-Validation Stratified

- **Objetivo:**
  Avaliar o desempenho de um modelo garantindo que **cada subconjunto (fold)** de validação tenha **a mesma proporção de classes** que o conjunto original.

Cross-Validation Stratified



Seleção de Modelo e Regressão Passo a Passo

Model Selection → Seleção de Modelo

- Processo de escolher o melhor conjunto de variáveis preditoras para explicar uma variável resposta, com equilíbrio entre **precisão** e **simplicidade**.

Stepwise Regression → Regressão Passo a Passo

- Método automatizado para incluir ou excluir variáveis de um modelo de regressão com base em critérios estatísticos (como R^2 ajustado, AIC, etc.).

Seleção de Modelo e Regressão Passo a Passo

Objetivo

- Escolher o melhor subconjunto de variáveis preditoras para um modelo de regressão, equilibrando ajuste ao dado e complexidade do modelo.

Por que selecionar variáveis?

- Variáveis irrelevantes aumentam o ruído.
- Modelos complexos têm maior risco de overfitting.
- Queremos explicações simples e eficientes.